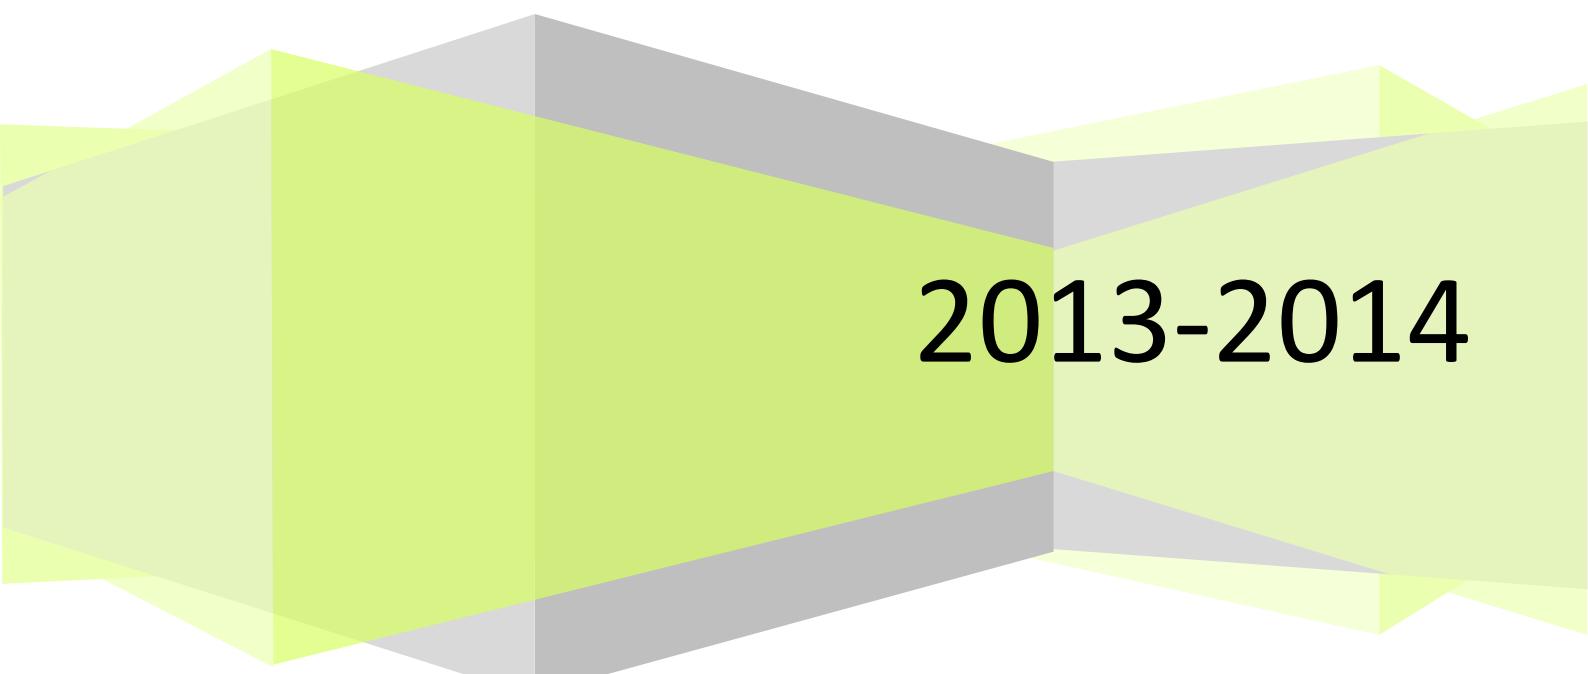


Snijtand Segmentatie

Computer Vision [H02K5a]: Finaal Project

Matthias Moulin (R0255811) & Milan Samyn (R0264118)



2013-2014

Abstract

Het doel van het finale project voor het vak Computer Vision in het schooljaar 2013-2014 aan de KU Leuven is het ontwikkelen van een modelgebaseerde procedure die in staat is om de boven en onder snijtanden in panoramische radiografieën te segmenteren. Hiervoor wordt er een Active Shape model (ASM) geconstrueerd voor elk van de acht snijtanden. In dit verslag komen de constructie, verantwoording en evaluatie van de ASM modellen, het preprocessen van de radiografieën om de fitting procedure te vergemakkelijken alsook de gebruikte fitting procedures en fitting functies aan bod.

Inhoud

Abstract	1
1 Inleiding	1
2 Active Shape Model constructie	2
2.1 Procrustes Analyse	2
2.2 Principal Component Analyse	3
3 Preprocess	3
4 Fitting	4
4.1 Constructie van de fitting functies	4
4.2 Single-Resolutie Active Shape Model's fitting procedure	6
4.3 Multi-Resolutie Active Shape Model's fitting procedure	6
4.4 Initialisatie	7
4.4.1 Manuele initialisatie	7
4.4.2 Automatische initialisatie	8
5 Resultaten	9
6 Conclusie	11
Appendices	12
Appendix A: Visualisaties van de gegeven trainingsamples	12
Appendix B: Visualisaties van de resultaten van de Procrustes Analyse	14
Appendix C: Visualisaties van de resultaten van de Principal Component Analyse	15
Appendix D: Visualisaties van de resultaten van het preprocessen	25
Appendix E: Visualisaties van de constructie van de fitting functies & resultaten fitting procedure (met manuele initialisatie)	31
Appendix F: Visualisaties van de resultaten van de fitting procedure (met automatische initialisatie)	42
Referenties	54

1 Inleiding

Het doel van het finale project voor het vak Computer Vision in het schooljaar 2013-2014 aan de KU Leuven is het ontwikkelen van een modelgebaseerde procedure die in staat is om de boven en onder snijtanden in panoramische radiografieën te segmenteren. Hiervoor wordt er een *Active Shape model* (ASM) geconstrueerd

voor elk van de acht snijtanden. Een Active Shape Model is een statistisch model met de vorm van een bepaald object dat tijdens een iteratief proces gedeformeerd zal worden om een instantie van dergelijke object te fitten in een nieuwe afbeelding.

In dit verslag komen de constructie, verantwoording en evaluatie van de ASM modellen (2), het preprocessen van de radiografieën om de fitting procedure te vergemakkelijken (3) alsook de gebruikte fitting procedures en fitting functies aan bod (4).

2 Active Shape Model constructie

In deze sectie wordt een Active Shape Model geconstrueerd voor elk van de 8 snijtanden. Mogelijke alternatieven zijn:

- Eén model dat elk van de 8 snijtanden modelleert. Op basis van de gegeven landmarks raden we dit op het eerste zicht af aangezien er duidelijke verschillen tussen de vorm van de voor- en ondertanden en tussen de vorm van de zij- en voortanden.
- Meerdere modellen die elk één of meerdere snijtanden modelleren.
- Eén model dat het geheel van de 8 snijtanden modelleert. Opnieuw, op basis van de gegeven landmarks raden we dit op het eerste zicht af aangezien er duidelijke verschillen zijn in de afstanden tussen de voor- en ondertanden.
- Meerdere modellen die elk één snijtand of meerdere snijtanden als geheel modelleren. Door modellen te construeren voor meerdere snijtanden als geheel kunnen bepaalde correlaties in rekening gebracht worden (*bv.: aangrenzende tanden die elkaar positie beïnvloeden*). Dit kan voordelig zijn tijdens de fitting procedure.
- Combinaties van de hiervoor genoemde alternatieven.

Wij opteren voor een apart model voor elk van de 8 snijtanden omdat dit de meest algemene aanpak is. De moeilijkheid van deze aanpak zal zich bevinden in het bepalen van startoplossingen voor het iteratieve fitting proces. Mits goed gekozen startoplossingen zou het fitting proces geen probleem mogen ondervinden van deze aanpak.

In een eerste subsectie wordt beschreven hoe alle tandvormen (beschreven door de gegeven landmarks) van de trainingsamples horende bij eenzelfde tand genormaliseerd worden via een *Procrustes Analyse*. Vervolgens wordt de variantie in vorm bestudeerd via een *Principal Component Analyse*. Merk op dat de modellen, die in de volgende subsecties geconstrueerd worden, enkel de variantie in de vorm beschrijven en niet de variantie in het voorkomen. Het voorkomen wordt pas in rekening gebracht bij de constructie van de fitting functies en bij het iteratieve fitting proces.

2.1 Procrustes Analyse

Alvorens een Active Shape Model te kunnen genereren, moeten alle tandvormen (beschreven door de gegeven landmarks) van de trainingsamples horende bij dezelfde tand gealigneerd worden in eenzelfde assenstelsel. Hiervoor maken we gebruik van een Procrustes Analyse waarbij we elke tandvorm van de trainingsamples horende bij dezelfde tand nu zo gaan aligneren opdat de som van de afstanden van elke gealigneerde tandvorm ten opzichte van de gemiddelde gealigneerde tandvorm geminimaliseerd wordt. [Cootes92], [Cootes00]

Dit is een iteratief proces. In elke iteratiestap wordt de gemiddelde gealigneerde tandvorm herberekend tot het verschil tussen twee opeenvolgende gemiddelde gealigneerde tandvormen in elke dimensie kleiner is dan 0,00001. Initieel maakten we gebruik van een grotere waarde. Doordat de convergentie reeds na één of twee iteratiestappen bereikt werd, kozen we voor een kleinere waarde (meer precisie). Met een factor van 0,00001 is er nu convergentie na gemiddeld drie iteratiestappen.

De bekomen modellen en modellandmarks voor elk van de 8 snijtanden zijn weergegeven samen met de landmarks voor elk van de 14 trainingsamples¹ in de model-coördinatenruimte (x', y') in figuur B.1 van appendix B. Merk op dat er voor het aligneren vrij een referentievorm gekozen mag worden wat betreft de rotatiecomponent en scaleringsscomponent. We hebben ervoor geopteerd om te aligneren met de tandvormen van trainingsample 1.

2.2 Principal Component Analyse

Na de Procrustes Analyse hebben we één modeltand voor elke van de 8 snijtanden bekomen in de model-coördinatenruimte (x', y'). Elk van deze modellen is een representant voor de gemiddelde vorm van elk van de overeenkomstige snijtanden. De gealigneerde tandvormen vormen een distributie in de $2n$ -dimensionale ruimte (met n het aantal landmarks). Deze distributie willen we nu modelleren.

We zouden bijvoorbeeld een basis kunnen genereren voor deze $2n$ -dimensionale ruimte om elke vector in deze ruimte te beschrijven als een $2n$ -dimensionale coëfficiëntenvector ($2n$ vormfactoren). Door een Principal Component Analyse toe te passen kunnen we proberen de dimensionaliteit te verlagen door de principale assen (waarbij de grootte bepaald wordt door de grootste eigenwaarden van de covariantiematrix en waarbij de richting bepaald wordt door de overeenkomstige eigenvectoren van de covariantiematrix) van de distributie te berekenen om zo de vectoren in deze $2n$ -dimensionale ruimte met minder vormfactoren te beschrijven.

Uit de resultaten van de Principal Component Analysis blijkt dat voor elk van de 8 snijtanden 5, 6 of 7 vormfactoren (versus $2n = 40$) volstaan om minstens 98%² van de variantie van de landmarkposities in de trainingset te beschrijven ten opzichte van het overeenkomstige gemiddelde model. Het aantal Principal Components voor elk van de 8 snijtanden is weergegeven in tabel 2.2.1.

Tand	1	2	3	4	5	6	7	8
#PCs	6	6	5	5	7	7	7	7

Tabel 2.2.1: Geeft het aantal Principal Components weer voor elk van de 8 snijtanden.

Door deze vormfactoren te laten variëren, kunnen we de vorm van de tand laten variëren. Nu moeten we bepaalde boven- en ondergrenzen voor deze variaties opleggen opdat we nog steeds geloofwaardige tanden bekomen. We laten ± 3 standaard deviaties ($\pm 3\sqrt{\lambda_i}$) ten opzichte van het gemiddelde model toe. Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) afwijkingen op elke vormparameter ten opzichte van het gemiddelde model voor de elk van de 8 snijtanden in de model-coördinatenruimte (x', y') is weergeven in figuren C.1-8 van appendix C.

3 Preprocess

De zone met de 8 snijtanden van de radiografieën die voor ons van tel is, is relatief klein ten opzichte van de volledige radiografieën. Daarom croppen we de radiografieën op basis van de minimale en maximale landmarkcoördinaten (met een extra linker, rechter, boven en onder veiligheidsmarge) van alle landmarks van alle trainingsamples. Deze aanpak is te verantwoorden aangezien de toestellen die deze radiografieën maken ervoor zorgen dat de voortanden gecentreerd worden en deze toestellen min of meer gestandaardiseerd (zouden moeten) zijn.

De gegeven radiografieën zijn inherent ruisachtige data. We gebruiken OpenCV's `fastNlMeansDenoising` functie om Gaussische witte ruis te verwijderen uit de afbeeldingen (met grijswaarden).

¹ We gebruiken voor de visualisaties van de eerste fasen de landmarks van alle 14 trainingsamples. Voor de evaluaties van de fitting procedure gebruiken we slechts de landmarks van 13 trainingsamples (de trainingset).

² Een alternatief bestaat erin het aantal vormfactoren zo te kiezen opdat elke trainingsample benaderd kan worden met een bepaalde accuraatheid.

Daarnaast zijn de intensiteitsverschillen soms klein, wat een nadelig effect kan hebben op fitting functies die werken met intensiteitsverschillen. We proberen het contrast nu uit te buiten om de intensiteitsverschillen op te hogen. Hiervoor testen we twee verschillende methoden: histogram equalization en (linear) contrast stretching.

$$I_{out} = H'(I_{in}) \text{ met } H'(x) = \sum_{0 \leq i < x} H(i)$$

Equalisatie houdt in een distributie (het huidige histogram $H(x)$) te mappen op een andere distributie (een wijdere en meer uniforme distributie van intensiteitswaarden). De mapping wordt verwezenlijkt door de cumulatieve distributie functie $H'(x)$ van het histogram $H(x)$. [Fisher00] , [OpenCV11]

$$I_{out} = (I_{in} - c) \left(\frac{b - a}{d - c} \right) + a$$

Contrast stretching heeft tot doel het contrast te verbeteren van een afbeelding door het bereik van intensiteitswaarden ($[c, d]$) (lineair) uit te rekken over een gewenst bereik van intensiteitswaarden ($[a, b] = [0, 255]$). Uitschieters in het huidige bereik van intensiteitswaarden kunnen de waarde van c en d nadelig beïnvloeden met een onrepresentatieve schaal tot gevolg. Daarom kiezen we c en d gelijk aan het 5^{de} en 95^{ste} percentiel van het histogram respectievelijk. [Fisher00]

De originele radiografieën voor de 14 trainingsamples na enkel croppen, de originele radiografieën voor de 14 trainingsamples na croppen en denoisen, de radiografieën voor de 14 trainingsamples na croppen en histogram equalization, de radiografieën voor de 14 trainingsamples na croppen, denoisen en histogram equalization, de radiografieën voor de 14 trainingsamples na croppen en (linear) contrast stretching en de radiografieën voor de 14 trainingsamples na croppen, denoisen en (linear) contrast stretching zijn weergegeven in figuur D.1 van appendix D.

In wat nu volgt, wordt steeds vertrokken van de radiografieën voor de 14 trainingsamples na croppen, denoisen en (linear) contrast stretching omdat deze afbeeldingen betere resultaten en convergentiepatronen opleveren. Dit is niet verder in detail onderzocht.³

4 Fitting

In deze sectie wordt eerst de keuze en constructie van de fitting functies uitgelegd, dewelke vervolgens in de fitting procedures gebruikt zullen worden. In de daaropvolgende subsectie worden de gebruikte iteratieve single- en multi-resolutie ASM fitting procedures uitgelegd alsook een procedure om manueel en automatisch een startoplossing te kunnen genereren als input voor de fitting procedures.

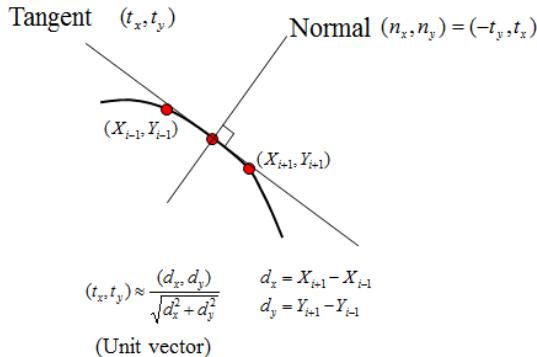
4.1 Constructie van de fitting functies

Om de vorm van een startoplossing te deformeren en te laten convergeren naar de snijtand in de afbeeldingsruimte maken we gebruik van een fitting functie. Een bepaalde zone rond de landmarks wordt in rekening gebracht tijdens elke iteratiestap. De fitting functie wordt gebruikt om de beste match voor de landmark in kwestie binnen deze zone te vinden.

Indien de landmarks gepositioneerd zijn op sterke randen, kunnen we op zoek gaan naar de sterkste rand in de omgeving. We wensen echter te leren van de trainingset naar wat we moeten zoeken in een gegeven

³ In de programmacode kan er eenvoudig gewisseld worden van gepreprocesste afbeeldingen door de methode globale parameter te wijzigen.

afbeelding. Dit verwezenlijken we door k punten te samplen aan weerszijden van elke modellandmark⁴ (plus de modellandmark zelf) in de richting van het profiel normaal t.o.v. de modelrand; 1D Profile ASM. Het bekomen van de richtingscoëfficiënt van het profiel normaal t.o.v. de modelrand is geïllustreerd in figuur 4.1.1. [Cootes92], [Cootes00], [Pei10]



Figuur 4.1.1: Berekening van de richtingscoëfficiënt van het profiel normaal t.o.v. de modelrand (n_x, n_y) en het profiel tangentieel t.o.v. de modelrand (t_x, t_y) door een modellandmark (X_i, Y_i) op basis van de twee naburige modellandmarks (X_{i-1}, Y_{i-1}) en (X_{i+1}, Y_{i+1}). [onbekend]

Om een robuustere (rij)vector \mathbf{g}_i met samplewaarden, die niet gevoelig zijn voor globale intensiteitsverschillen, te bekomen, samplen we de afgeleide (i.p.v. de intensiteitswaarden zelf) in de richting van het profiel normaal t.o.v. de modelrand. Deze (rij)vector \mathbf{g}_i wordt vervolgens genormaliseerd. Als fitting functie voor het landmark in kwestie wordt nu de Mahalanobisafstand gekozen:

$$f(\mathbf{g}_s) = (\mathbf{g}_s - \bar{\mathbf{g}}) \mathbf{S}_g^{-1} (\mathbf{g}_s - \bar{\mathbf{g}}) \text{ met } \bar{\mathbf{g}} = \frac{1}{n} \sum_{i=1}^n \mathbf{g}_i \text{ en } \mathbf{S}_g = \frac{1}{n} \sum_{i=1}^n (\mathbf{g}_s - \bar{\mathbf{g}})^T (\mathbf{g}_s - \bar{\mathbf{g}})$$

Hierbij stelt \mathbf{S}_g^{-1} de Moore-Penrose pseudo-inverse van de covariantiematrix \mathbf{S}_g voor. In totaal worden nu 160 (= 8 tandmodellen * 20 landmarks/tandmodel) fitting functies opgesteld. [Cootes92], [Cootes00], [Pei10]

Samplen in één enkele richting heeft mogelijks zijn tekortkomingen. Daarom besluiten we om zowel k punten (afgeleiden) te samplen aan weerszijden van elke modellandmark (plus de modellandmark zelf) in de richting van het profiel normaal t.o.v. de modelrand én in de richting van het profiel tangentieel t.o.v. de modelrand; 2D Profile ASM. Dit levert ons 320 fitting functies op. [Pei10]

De radiografieën voor de 14 trainingsamples na croppen, denoisen en (linear) contrast stretching met de modellandmarks en contouren van de 8 snijtandmodellen (gealigneerd met de overeenkomstige snijtand) samen met het profiel normaal t.o.v. de modelrand (met $k = 5$) en het profiel tangentieel t.o.v. de modelrand (met $k = 5$) weergegeven in de afbeelding-coördinatenruimte (x, y) zijn weergegeven in figuur E.2 van appendix E.

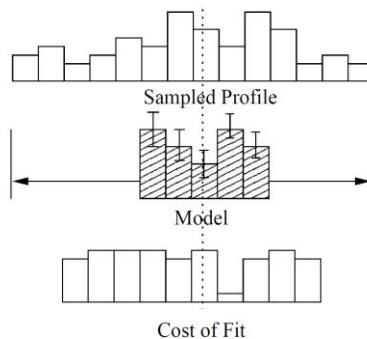
De Referentielandmarks en contouren als initiële startoplossing samen met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen en fitting functies die zowel het profiel normaal en tangentieel t.o.v. de modelranden in rekening nemen; zijn weergegeven in figuur E.3 van appendix E. Hieruit blijkt dat de fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen betere resultaten opleveren dan fitting functies die zowel het profiel normaal en tangentieel t.o.v. de modelranden in rekening nemen.

⁴ We aligneren de modeltand met de samplétand in de afbeeldingscoördinatenruimte en bekomen een goede benadering van de samplétand. Dit is weergegeven in figuur E.1 van appendix E. De samplétanden worden vervolgens niet meer gebruikt.

Een ander alternatief bestaat erin een volledige texture (patch) te samplen rond de modellandmarks. Hierbij moet men echter de berekening van de Moore-Penrose pseudo-inverse in het achterhoofd houden. Dit is niet verder onderzocht. [Pei10]

4.2 Single-Resolutie Active Shape Model's fitting procedure

Als we een initiele plaatsing hebben van een instantie van een tandmodel, kunnen we op een iteratieve manier deze instantie fitten met het algoritme beschreven in [Cootes00]. In een zone rond elke landmark (X_i, Y_i) zoeken we naar de beste landmark (X'_i, Y'_i) volgens de voorheen beschreven fitting functie(s). Hiervoor samplen we m punten (afgeleiden) aan weerszijden van elke modellandmark (plus de modellandmark zelf) in de richting van het profiel normaal t.o.v. de modelrand. Voor elk van de $2(m - k) + 1$ mogelijke vectoren \mathbf{g}_s van $2k + 1$ punten (afgeleiden) bepalen we de kwaliteit ervan aan de hand van de vooraf geconstrueerde fitting functies f . Het punt (X'_i, Y'_i) dat overeenkomt met de middelste component van de vector \mathbf{g}_s , die de laagste waarde van $f(\mathbf{g}_s)$ oplevert, wordt beschouwd als de nieuwe i^e landmark. Dit is weergeven in figuur 4.2.1.



Figuur 4.2.1: Zoek naar het beste grijswaardenmodel langs het gesamplede profiel. [Cootes00]

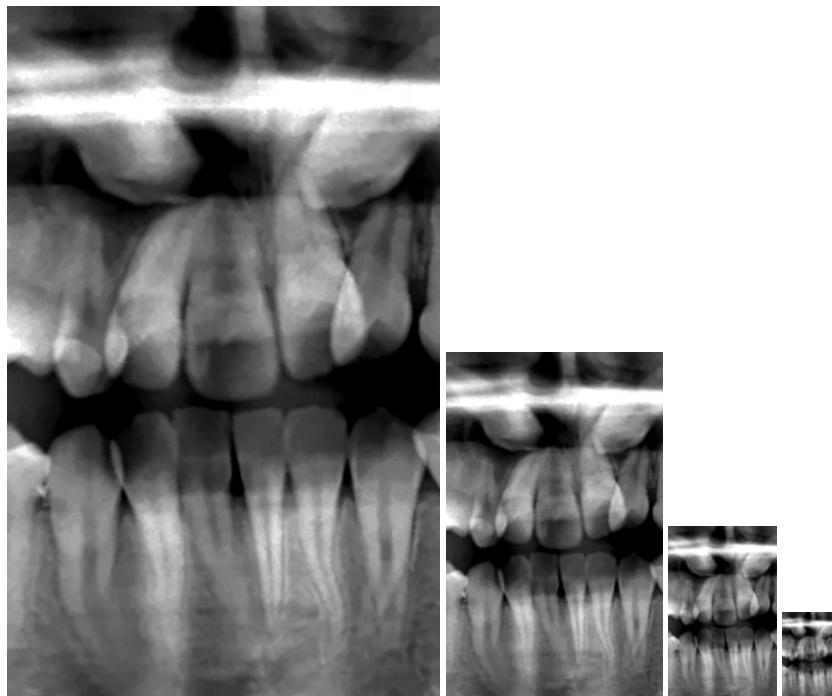
Na het updaten van alle landmarks, bepalen we de transformatieparameters (X_t, Y_t, s, θ) t.o.v. de modeltand in de model-coördinatenruimte en aligneren we de huidige tand in de afbeelding-coördinatenruimte met de modeltand in de model-coördinatenruimte door alle vormfactoren b_i te bepalen. Vervolgens corrigeren we indien een $|b_i|$ groter is dan drie standaarddeviaties ($3\sqrt{\lambda_i}$). Dit doen we opdat de vorm van de nieuwe tand niet te veel zou afwijken t.o.v. de modeltand. Vervolgens transformeren we de gecorrigeerde tand terug naar de afbeelding-coördinatenruimte. We bereiken convergentie en eindigen het algoritme als een uitgevoerde iteratie amper nog verandering teweeg brengt bij de transformatieparameters of vormfactoren, meer bepaald wanneer 90% van de gevonden landmarks hoogstens één pixel verschilt van de gevonden landmarks uit de vorige iteratie.

4.3 Multi-Resolutie Active Shape Model's fitting procedure

In [Cootes00] wordt een nieuw algoritme voorgesteld om de efficiëntie en robuustheid van het huidige algoritme te verbeteren. Het protocol heet *multi-resolutie search* en houdt in dat eerst gezocht wordt naar een instantie in een afbeelding met kleinere resolutie en daarna iteratief verder gezocht wordt door de resolutie te vergroten en dus meer detail te introduceren. Voor elke afbeelding uit de training- en testset stellen we een *Gaussische piramide* op. De onderste laag van zo'n piramide bevat de originele afbeelding en elke laag daarboven bevat een gesmoothed en gesubsamplede versie, d.i. de helft van de pixels in elke dimensie van de laag eronder. Met behulp van de functie `pyrDown` van OpenCV creëren we de Gaussische piramides. Figuur 4.3.1 illustreert de toepassing op één van de (voorbewerkte) radiografieën voor een Gaussische piramide met vier lagen.

De procedure is gelijkaardig aan de single-resolutie search. Telkens convergentie of een maximaal aantal iteraties bereikt wordt, starten we met de huidige oplossing op een lager niveau van de Gaussische piramide. Er moeten nu echter wel fitting functies opgesteld worden voor elk niveau van de Gaussische piramide. Hoe hoger het niveau, hoe groter de zones die door de fitting functies in rekening gebracht worden. De waarden m en k blijven hetzelfde voor alle niveaus. Tijdens het zoeken kunnen we dus grotere/grovere stappen maken (t.o.v. de huidige landmarks) op de hogere niveaus per iteratiestap en verfijnen we de huidige landmarks op de

lagere niveaus per iteratiestap. Dit leidt tot een algoritme dat sneller naar een goede oplossing convergeert (zelfs in het geval van een slechtere startoplossing) en minder waarschijnlijk vast raakt te zitten op een verkeerde structuur (bv. een andere tand) in de afbeelding door een combinatie van grovere en verfijnde stappen te gebruiken. We zullen beide algoritmes qua snelheid en werking kort evalueren in een volgende sectie.



Figuur 4.3.1: Vier niveaus in de Gaussische piramide.

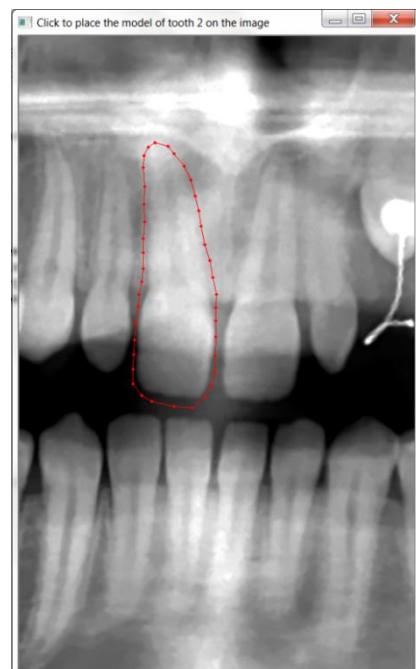
Alle iteraties op level 2, 1 en 0 van de multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen voor de 3^e tand van de 7^e radiografie zijn weergegeven in de model-coördinatenruimte (x',y') en in de afbeelding-coördinatenruimte (x,y) in figuur E.4 van appendix E.

4.4 Initialisatie

Deze sectie beschrijft het proces om een initiële benadering van de te zoeken snijtand te vinden alvorens deze mee te geven aan de fitting procedure (*single- of multi-resolutie search*). In een eerste subsectie wordt een manuele initialisatieprocedure beschreven en in een tweede subsectie worden mogelijke automatische initialisatieprocedures beschreven.

4.4.1 Manuele initialisatie

In de projectopgave wordt voorgesteld om eerst manueel de initiële oplossing van een tand op de afbeelding te plaatsen. Op die manier kan het fitting algoritme onafhankelijk van de initialisatie getest worden. De gekozen aanpak is vrij eenvoudig; we plaatsen de veertig landmarks handmatig rond de gekozen tand met behulp van de linkermuisknop zoals op afbeelding 4.4.1. Hierbij is het belangrijk dat we bij het plaatsen van de landmarks dezelfde mapping als de landmarks van de trainingsamples volgen, d.i. startend bovenaan en in tegenwijzerzin. Daarnaast proberen we de punten ook zo equidistant mogelijk te verdelen.



Figuur 4.4.1: Manuele initialisatie.

4.4.2 Automatische initialisatie

Het doel van het project is om een algoritme te schrijven dat de acht snijtanden automatisch segmenteert. We moeten dus een methode ontwikkelen die de startoplossing automatisch op de afbeelding (en liefst in de buurt van de te zoeken tand) plaatst.

Een eerste, misschien wel naïeve, aanpak is om de gemiddelde gealigneerde modeltand in de afbeeldingsruimte als startoplossing te nemen. Deze vorm bekomen we door eerst de gemiddelde transformatieparameters te berekenen om de modeltand te aligneren met alle trainingsamples in de afbeelding-coördinatenruimte. Deze methode is erg afhankelijk van de grootte (scaleringscomponent) en positie (translatiecomponenten) van de trainingtanden in de afbeelding-coördinatenruimte en levert bijgevolg niet altijd de gewenste resultaten op.

De modellandmarks en contouren als initiële startoplossing met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen zijn weergegeven in figuur F.1 van appendix F.

Voor de tweede aanpak zoeken we naar de bounding box rond respectievelijk de vier bovenste en vier onderste snijtanden. Een mogelijke procedure hiervoor vinden we terug in de opdracht rond gelaatsherkenning waarbij met behulp van een ‘Haar cascade classifier’ gezichten gedetecteerd kunnen worden [HaarClassifier13]. Om de classifiers te construeren (trainen) hebben we samples nodig, zowel positieve als negatieve, die we telkens uit de trainingset halen. We gebruiken 13 (variabele⁵) positieve en 30 (vaste) negatieve⁶ afbeeldingen. Een voorbeeld van een positieve en negatieve afbeelding is weergegeven in figuur 4.4.2. De 30 negatieve samples voor het trainen van de cascade classifiers van LBP (Local Binary Patterns) features zijn weergegeven in figuur F.2 van appendix F.



Figuur 4.4.2: Een positieve (links) en een negatieve afbeelding (rechts).

We gebruiken de tool `opencv_createsamples` die de positieve afbeeldingen (tekstbestanden met coördinaten) omzet naar een gecompileerd C++ VEC-bestand. De negatieve samples zijn gewoon de negatieve afbeeldingen. Met deze samples kunnen we onze classifier trainen. Hiervoor biedt OpenCV twee verschillende tools aan; `opencv_haartraining` (enkel Haar features) en `opencv_traincascade` (Haar features en LBP features). De tweede tool is een vernieuwde versie van de eerste die, naast de ondersteuning van Haar features, twee extra voordelen heeft:

- ze ondersteunt LBP (Local Binary Patterns) features waarmee zowel training als detectie veel sneller kunnen verlopen, afhankelijk van de trainingset mogelijk ten koste van mindere goede detectie.
- Daarnaast is ook multithreading mogelijk.

⁵ We construeren namelijk voor elk van de 14 radiografieën twee classifiers (voor de onder- en boven snijtanden respectievelijk) met behulp van de andere 13 radiografieën.

⁶ We hebben eveneens 200 extra negatieve afbeeldingen gebruikt die niets te maken hebben met tanden of radiografieën, maar dit heeft geen betere resultaten opgeleverd.

Daar de eerste tool veel tijd (*lees: dagen*) in beslag neemt, hebben we logischerwijs voor de tweede tool, met LBP features, geopteerd. Het resultaat is een XML-bestand die onze classifier bevat en waarmee we nu de bovenste of onderste rij van snijtanden kunnen detecteren.

De bekomen resultaten (bounding box rond boven- en ondertanden) van de 28 getrainde cascade classifiers van LBP (Local Binary Patterns) features op basis van 13 positieve en 30 negatieve samples waarbij 15 cascade stages getrained worden, zijn weergegeven in figuur F.3 van appendix F. De bekomen bounding boxes zijn grotendeels rommel. Dit is vermoedelijk het gevolg van het gebruik van veel te weinig positieve en negatieve samples om de cascade classifier te trainen.

Eens we de bounding box gevonden hebben, en in de veronderstelling dat die goed gepositioneerd is, kunnen we vervolgens de modeltand positioneren in het centrum van het juiste kwartaal in de bounding box en van hieruit het fitten starten.

De modellandmarks en contouren gecentreerd in het zwaartepunt van het overeenkomstige kwartaal van de bouding box rond de boven- of ondertanden als initiële startoplossing samen met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen, zijn weergegeven in figuur F.4 van appendix F. Aangezien we geen goede bounding boxes bekomen via onze cascade classifiers zijn we voor deze afbeeldingen vertrokken van de perfecte bounding box rond de onder- en boventanden, respectievelijk. We zien enerzijds een aantal goede tot zeer goede fits, maar anderzijds merken we op dat:

- De gemiddelde positie van het zwaartepunt van de modellen t.o.v. de bounding box beter zou geleerd worden uit de trainingset in plaats van het zwaartepunt te centreren. Dit is niet verder onderzocht.
- De tandmodellen beter zouden gescaleerd worden volgens de grenzen van de bounding box in plaats van gebruik te maken van de gemiddelde scaleringcomponent van de modellen na transformatie in de afbeeldings-coördinaattruimte. Dit is niet verder onderzocht.

De volgende sectie bevat de evaluatie en resultaten van dit proces.

5 Resultaten

We starten deze sectie met een vergelijking van de single- en multi-resolutie fitting procedure. De vergelijking is op basis van twee factoren; snelheid van convergentie en kwaliteit van de resulterende fit. Bij de multi-resolutie search werken we met Gaussische piramides van drie niveaus, niet meer, omdat de vierde laag te klein is (68×108 pixels) en hierdoor té veel informatie verloren gaat. We voeren beide algoritmes uit op de 8 snijtanden van de 2^e radiografie waarbij we telkens starten met de referentielandmarks van de overeenkomstige tand. De relevante parameters zijn:

- $\#levels = 3$ (*basis inbegrepen*),
- $k = 4$,
- $m = 8$,
- $max_it = 100, max_it_per_level = 33$.

Snijtand	Fitting SR (ms)	Fitting MR (ms)
#1	4262	4730
#2	1929	6888
#3	1128	8040
#4	3407	6826
#5	3938	5506
#6	5056	5287
#7	4197	1435
#8	3616	7217

Tabel 5: De snelheid van beide algoritmes (SR en MR).

De resultaatlandmarks verschillen niet zo heel erg veel en zijn daarom niet allebei apart in de appendices opgenomen. Het preprocessen van de trainingset neemt ongeveer drie keer meer tijd in beslag bij de multi-resolutie procedure (6495ms versus 2242ms). Dit is normaal aangezien we nu fitting functies voor ieder niveau moeten opstellen. Dit lijkt toch een vrij grote trade-off te zijn. Grottere stappen op hogere niveaus zouden sneller tot convergentie moeten leiden, maar dit valt uit de tabel niet af te leiden, integendeel. De single-resolutie procedure convergeert sneller omdat de startlandmarks zeer dicht in de buurt van de

resultaatlandmarks liggen. De multi-resolutie procedure zou beter tot zijn recht moeten komen bij minder goede startlandmarks.

Om de werking van het multi-resolutie algoritme te illustreren, verwijzen we naar figuur F.5 van appendix F, die een volledige run weergeeft voor de 3^e snijtand van de 7^e radiografie met de gemiddelde gealigneerde modeltand (niet de referentielandmarks) als startoplossing. Het uiteindelijke resultaat is weergegeven in figuur 5.

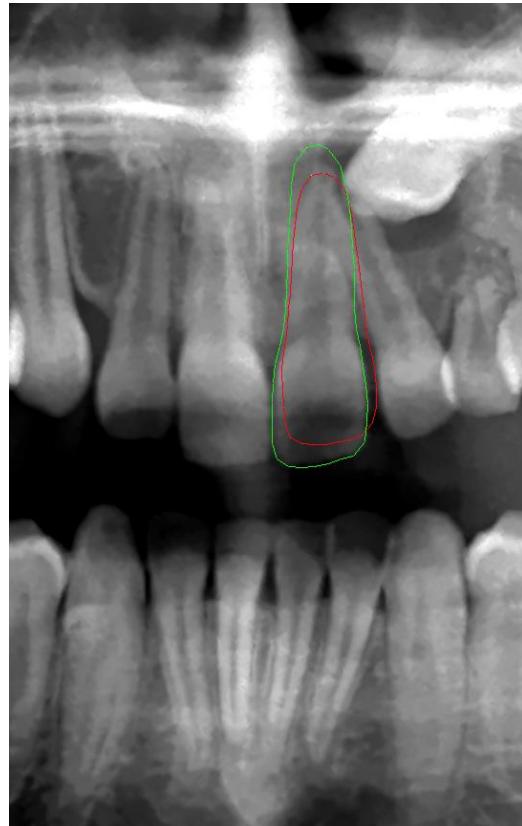
De referentielandmarks en contouren als initiële startoplossing samen met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen en fitting functies die zowel het profiel normaal en tangentieel t.o.v. de modelranden in rekening nemen; zijn weergegeven in figuur E.3 van appendix E. Hieruit blijkt dat de fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen betere resultaten opleveren dan fitting functies die zowel het profiel normaal en tangentieel t.o.v. de modelranden in rekening nemen. Hieruit blijkt eveneens dat de bekomen resultaatlandmarks heel dicht aansluiten bij de overeenkomstige referentielandmarks (geen divergentie weg van de startlandmarks). We besluiten dat mits goede startlandmarks de ASM fittingprocedures convergeren naar een zeer goede benadering van de referentielandmarks.

Bij de automatische initialisatie zijn de resultaten minder goed. Als we de landmarks en contouren van de gemiddelde gealigneerde modeltand in de afbeelding-ruimte als startlandmarks nemen, is deze startpositie vaak te ver afgelegen van de referentie, valt deze tussen twee tanden of is deze veel te groot in vergelijking met de referentie. Hierdoor convergeren beide algoritmes, op een aantal uitzonderingen na, meestal naar een vrij incorrecte oplossing. Resultaten hiervan zijn terug te vinden in figuur F.1 Van appendix F.

Ook de automatische initialisatie op basis van bounding boxen rond de boven- en ondersnijtanden werkt niet goed. Onze cascade classifiers detecteren te vaak betekenisloze zones. Ook de automatische initialisatie op basis van bounding boxen rond de boven- en ondersnijtanden werkt niet goed. Onze cascade classifiers detecteren te vaak betekenisloze zones. Dit is het gevolg van het gebruik van zowel te weinig positieve als negatieve samples om de cascade classifiers te trainen. Resultaten hiervan zijn terug te vinden in figuur F.3 van appendix F. Wat de negatieve samples betreft hebben we drie verschillende aanpakken uitgeprobeerd:

- 30 prentjes (o.a. delen van de schedel, andere tanden, etc.) te selecteren uit de trainingset die zeker geen groep snijtanden voorstellen. Resultaten hiervan zijn terug te vinden in figuur F.3 van appendix F. Deze zijn, zoals eerder al vermeld, absoluut niet bruikbaar.
- Een tweehonderdtal willekeurige afbeeldingen die niets met tanden te maken hebben. In dat geval wordt nooit iets gedetecteerd en krijgen we dus geen enkele bounding box terug.
- Voor de bovenste rij van snijtanden (en analoog voor de onderste rij) hebben we alle onderste rijen van snijtanden uit de trainingset als negatieve samples genomen. Omdat er nu heel wat features van de positieve samples terugkomen in de negatieve samples, is dit misschien geen goede aanpak. Toch levert dit, in zekere zin, de beste resultaten op.

Door een apart model voor elk van de 8 snijtanden te construeren is effectief gebleken dat de moeilijkheid van deze aanpak zich bevindt in het bepalen van startoplossingen voor het iteratieve fitting proces en mits goed gekozen startoplossingen ondervindt het fitting proces geen probleem van deze aanpak



Figuur 5: De contouren van de resulterende fit (groen) en van de startlandmarks (rood).

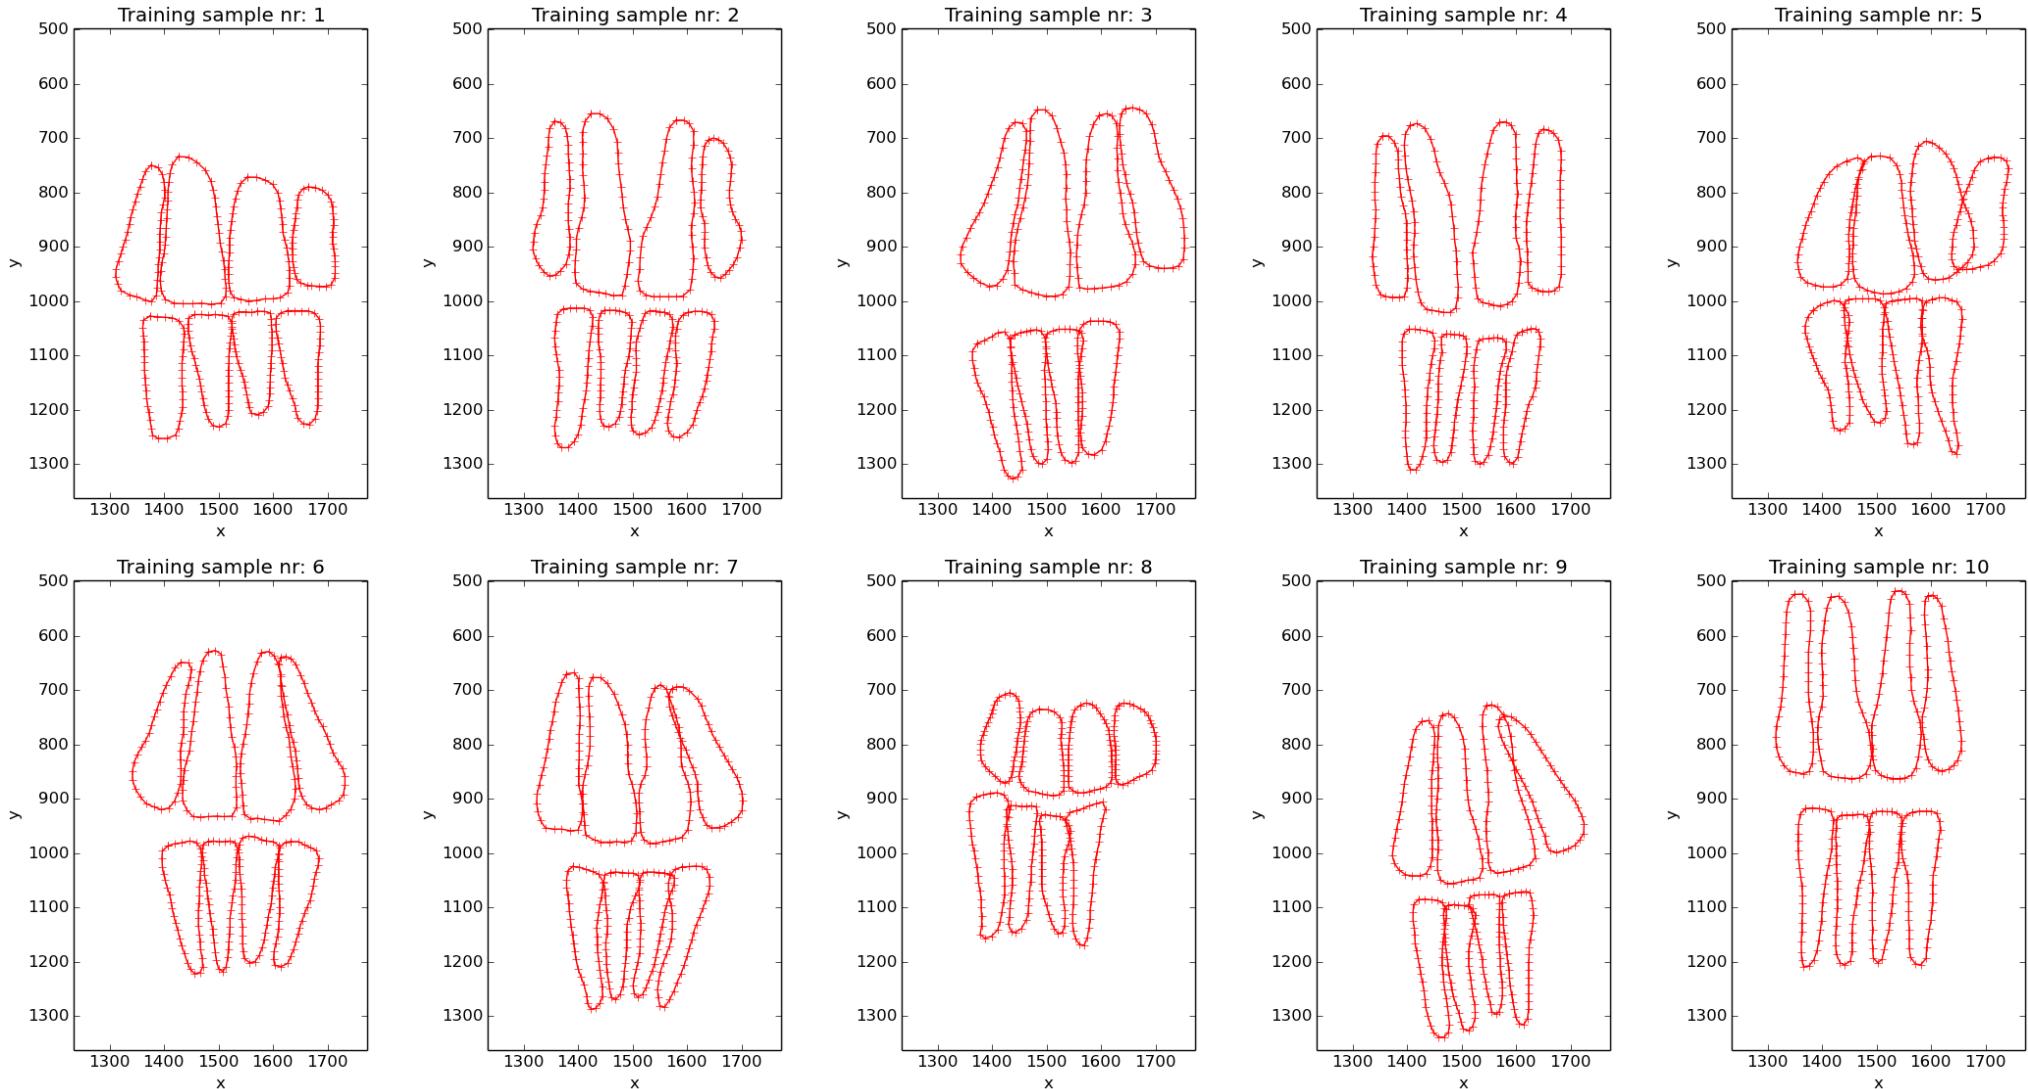
6 Conclusie

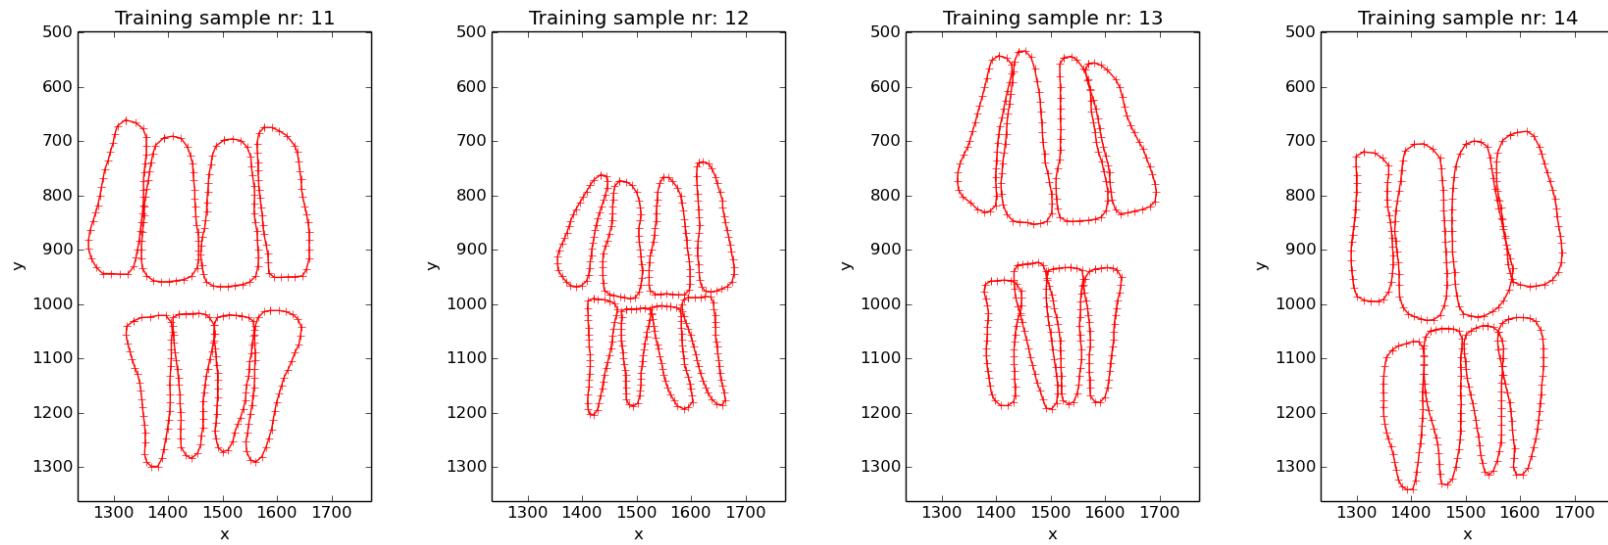
Een *Active Shape model* (ASM) is geconstrueerd voor elk van de acht snijtanden apart die in staat is om de boven en onder snijtanden in panoramische radiografieën te segmenteren. Dit zowel via een single-resolutie als multi-resolutie ASM fitting procedure met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen en fitting functies die zowel het profiel normaal en tangentieel t.o.v. de modelranden in rekening nemen. Hieruit is gebleken dat de fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing beter presteren.

Mits goede startlandmarks convergeren de ASM fittingprocedures naar een zeer goede benadering van de referentielandmarks. Verschillende automatische initialisatieprocedures zijn uitgeprobeerd, maar geen enkele levert algemeen een goede startoplossing op.

Appendices

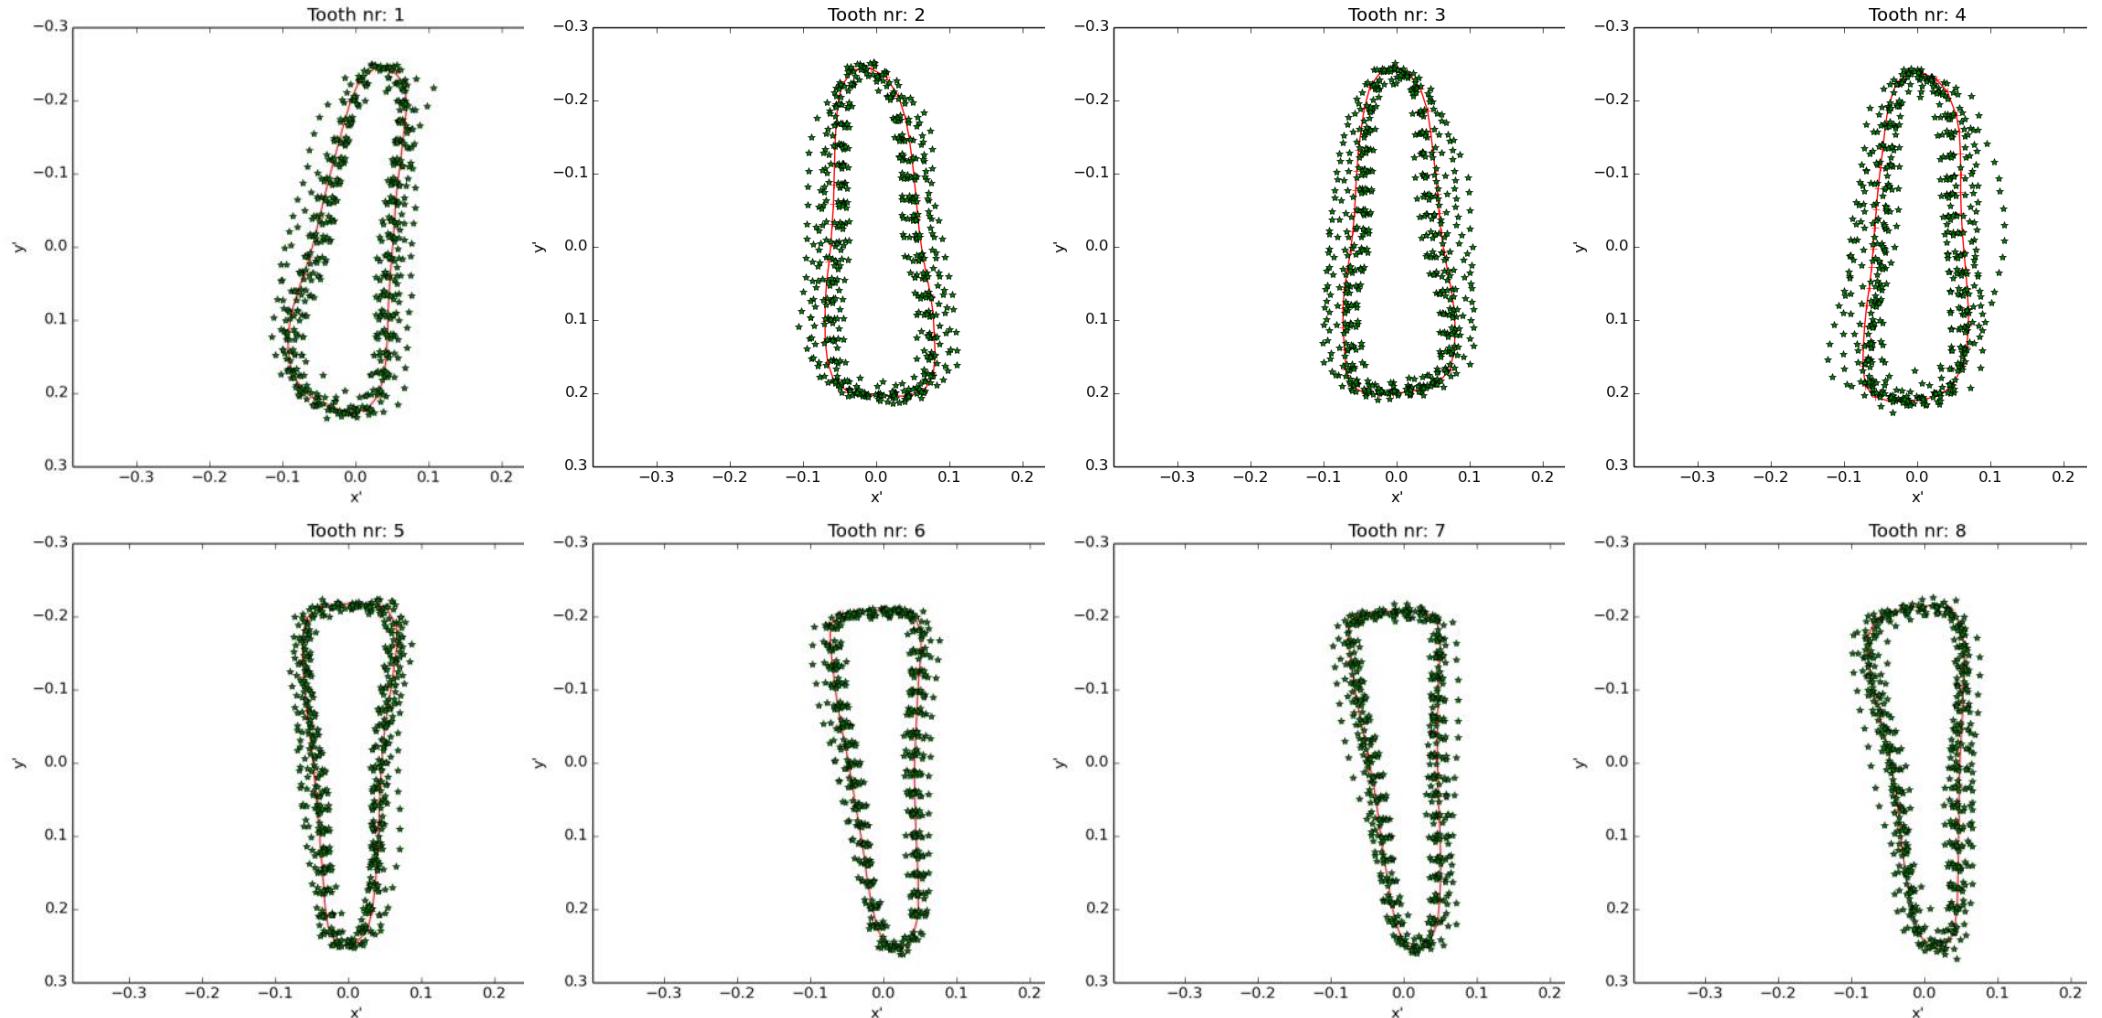
Appendix A: Visualisaties van de gegeven trainingsamples





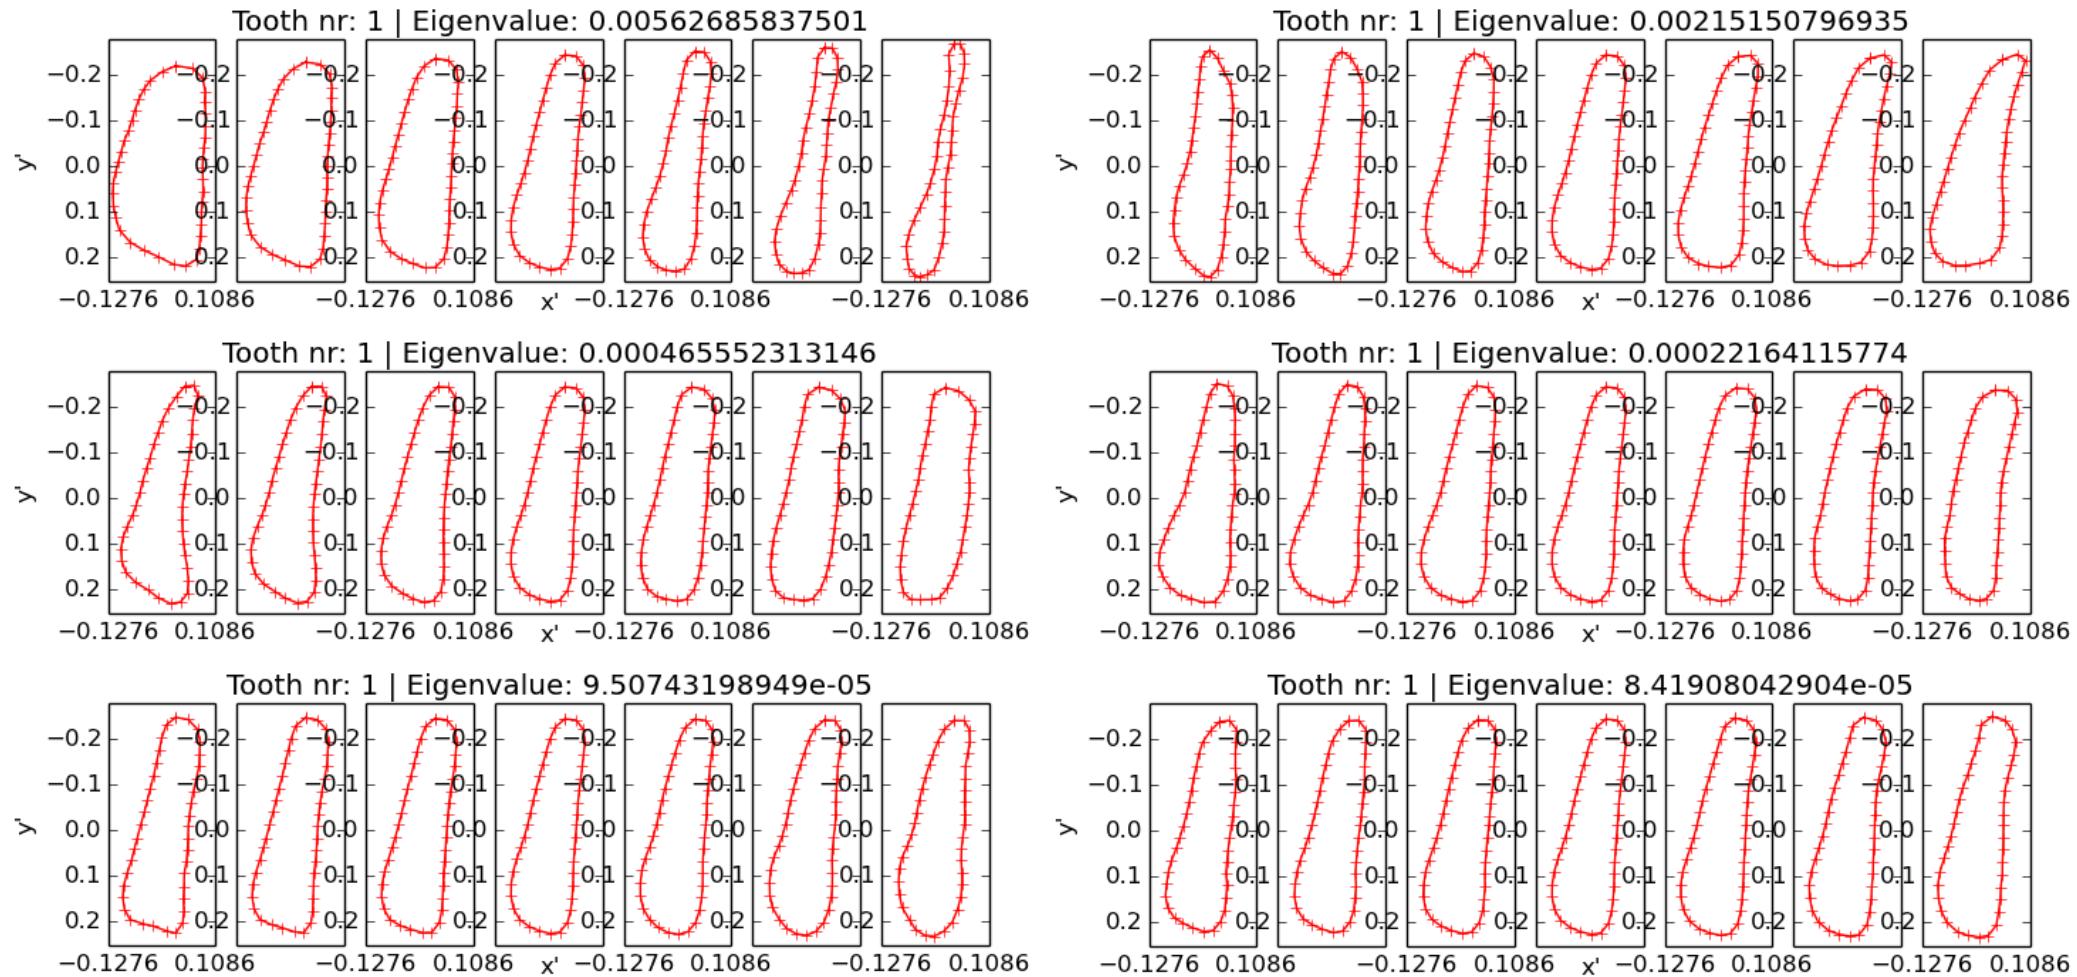
Figuur A.1: De 20 landmarks (rode '+' markeringen) van elk van de 8 snijstanden (rode contouren) weergegeven in de afbeeldingcoördinatenruimte (x , y) voor elk van de 14 trainingsamples op basis van de meegeleverde landmarks bestanden.

Appendix B: Visualisaties van de resultaten van de Procrustes Analyse

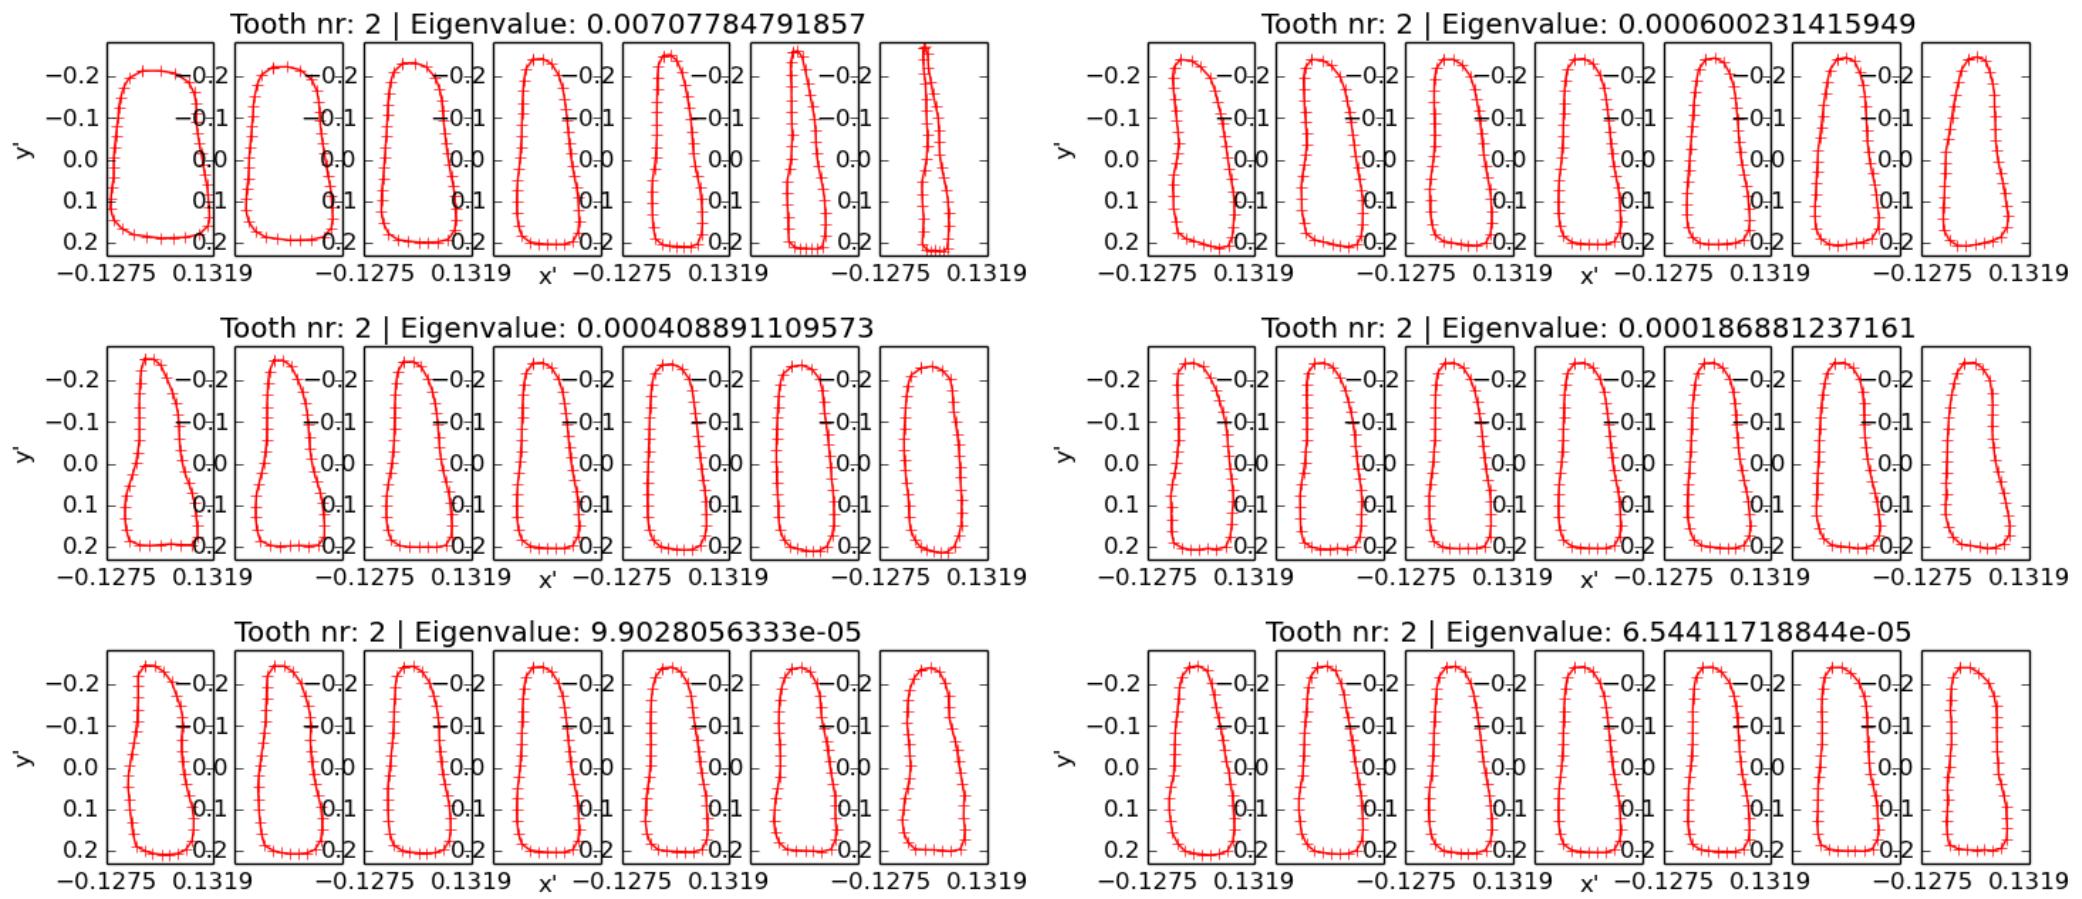


Figuur B.1: De bekomen modellen (rode contouren) en modellandmarks (rode '+' markeringen) voor elk van de 8 snijtanden en de trainingsamplelandmarks (groene '*' markeringen) voor elk van de 14 trainingsamples weergegeven in de model-coördinatenruimte (x' , y') gealigneerd met de landmarks van de tanden van trainingsample 1.

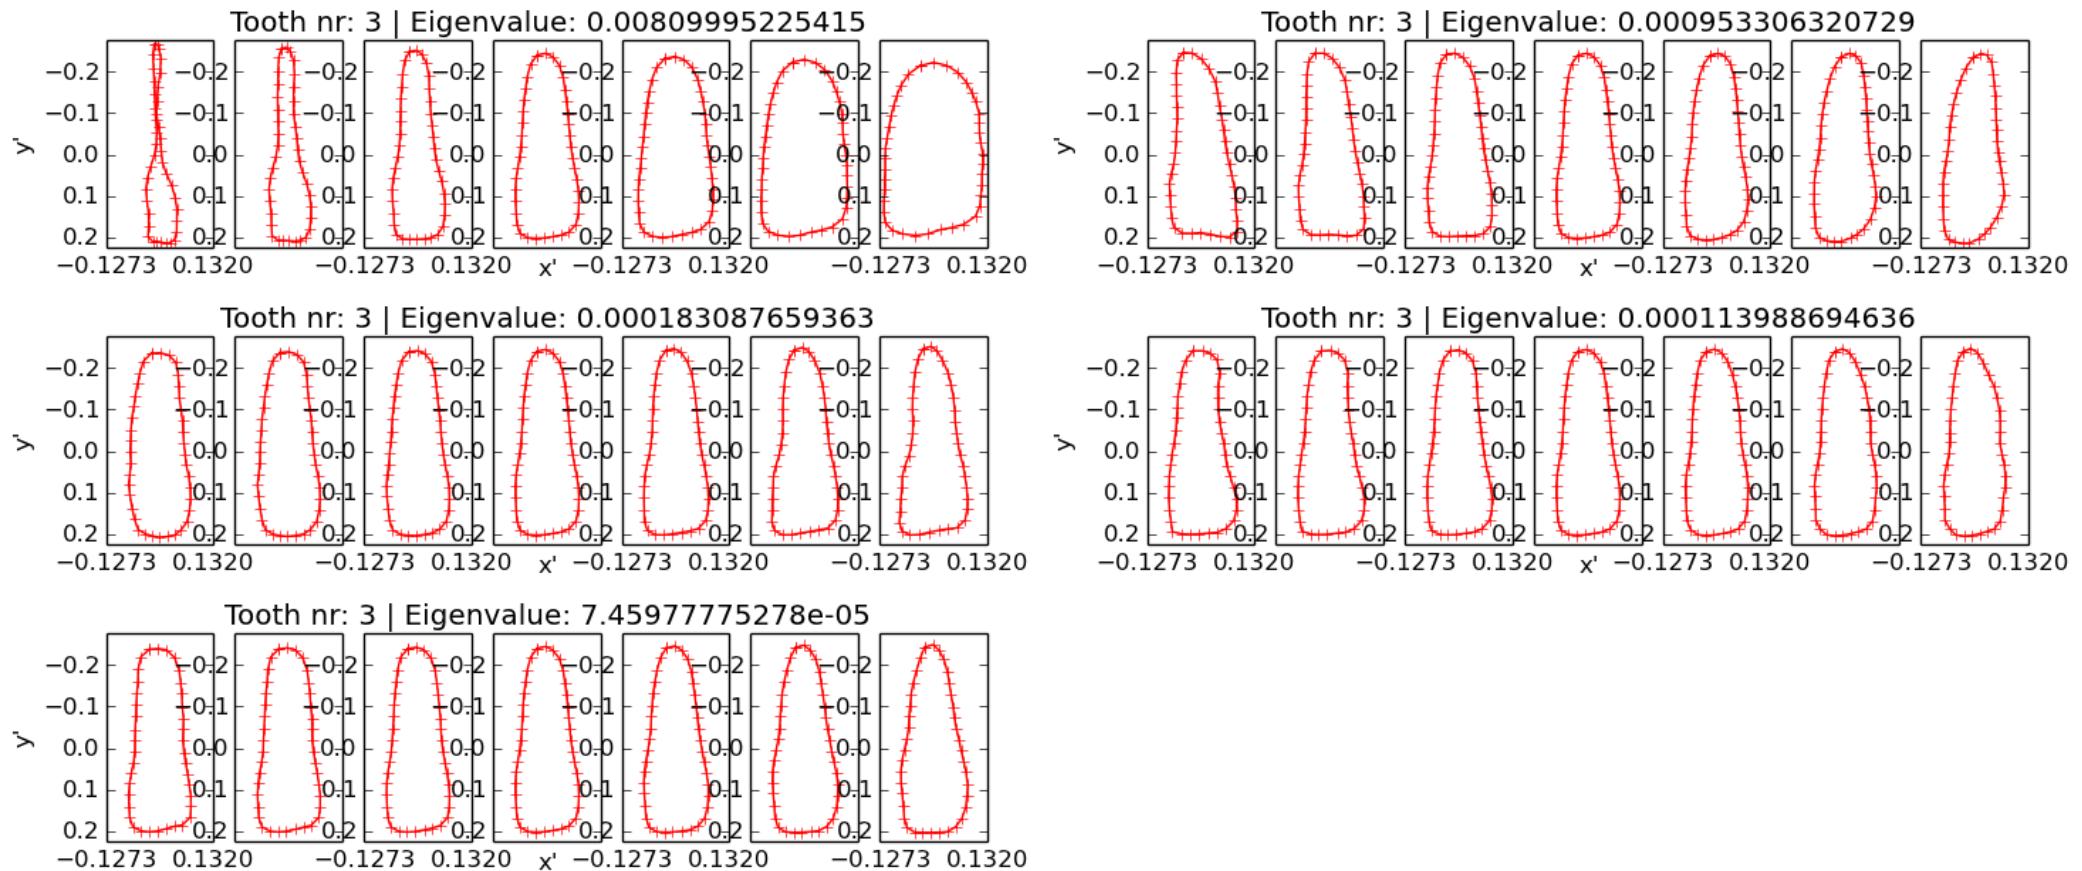
Appendix C: Visualisaties van de resultaten van de Principal Component Analyse



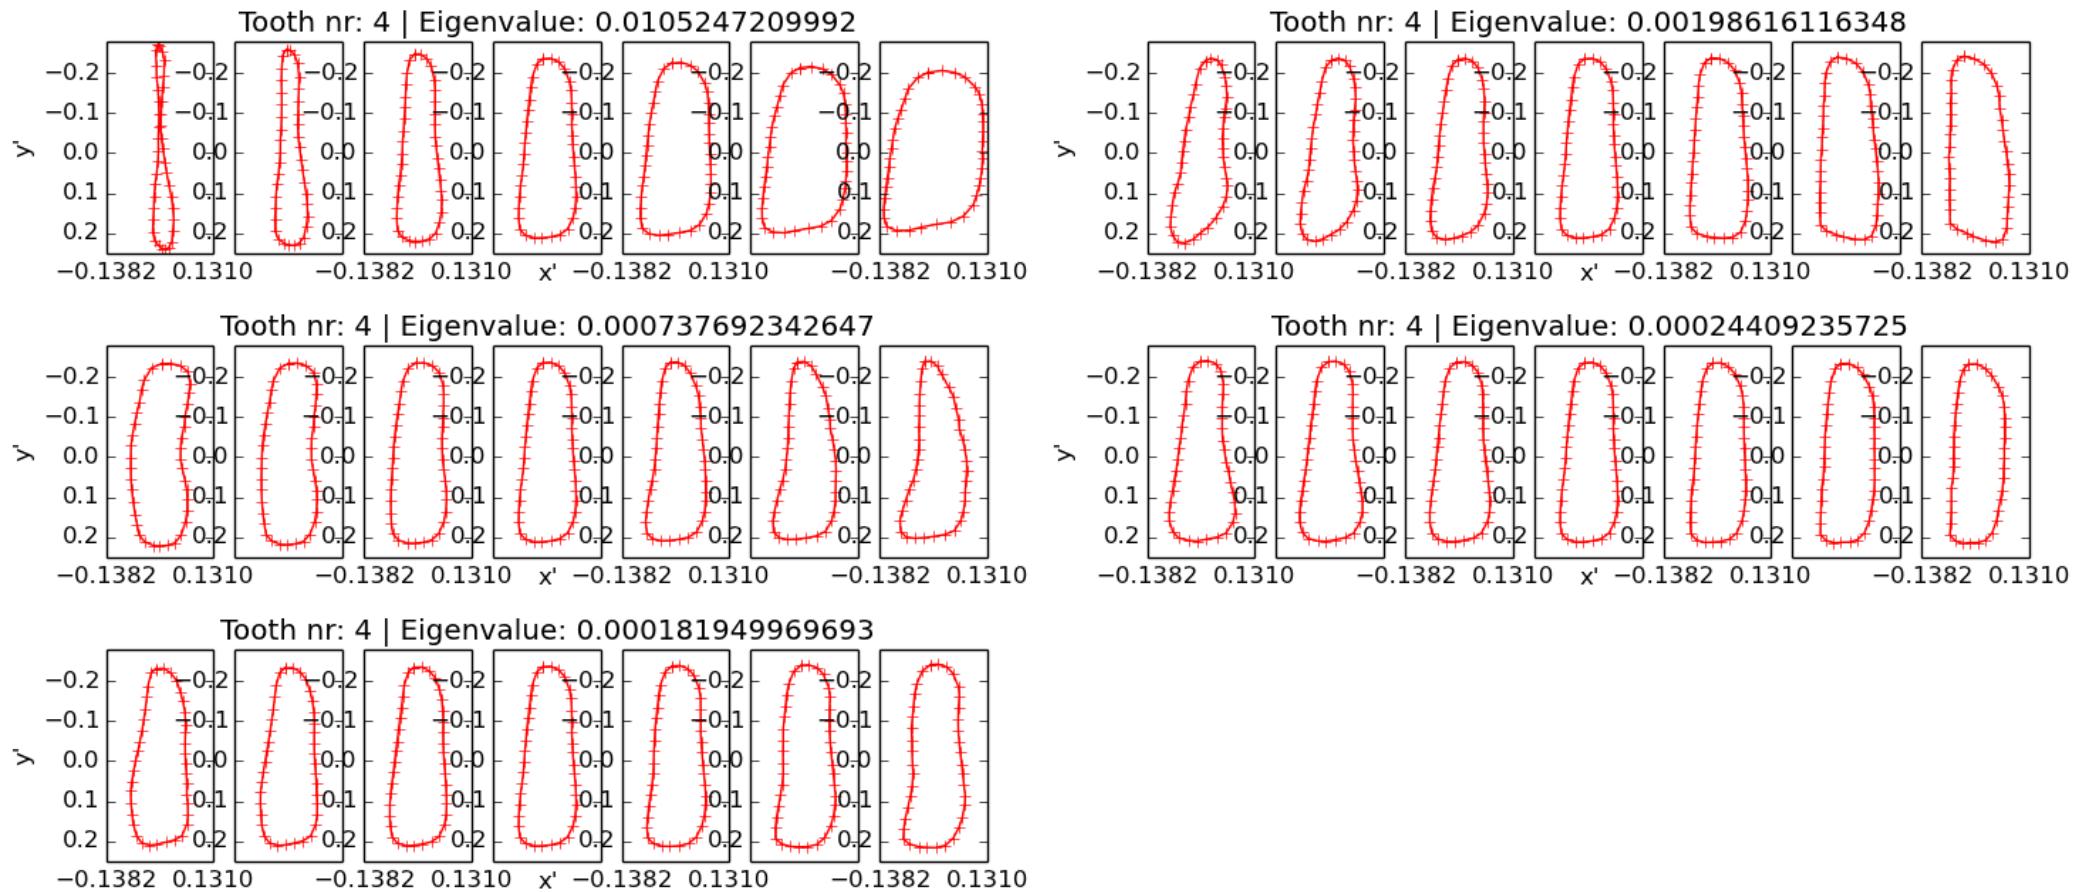
Figuur C.1: Het effect van $-3\sqrt{\lambda}$, $-2\sqrt{\lambda}$, $-\sqrt{\lambda}$, 0, $\sqrt{\lambda}$, $2\sqrt{\lambda}$, $3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de eerste tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactors in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.



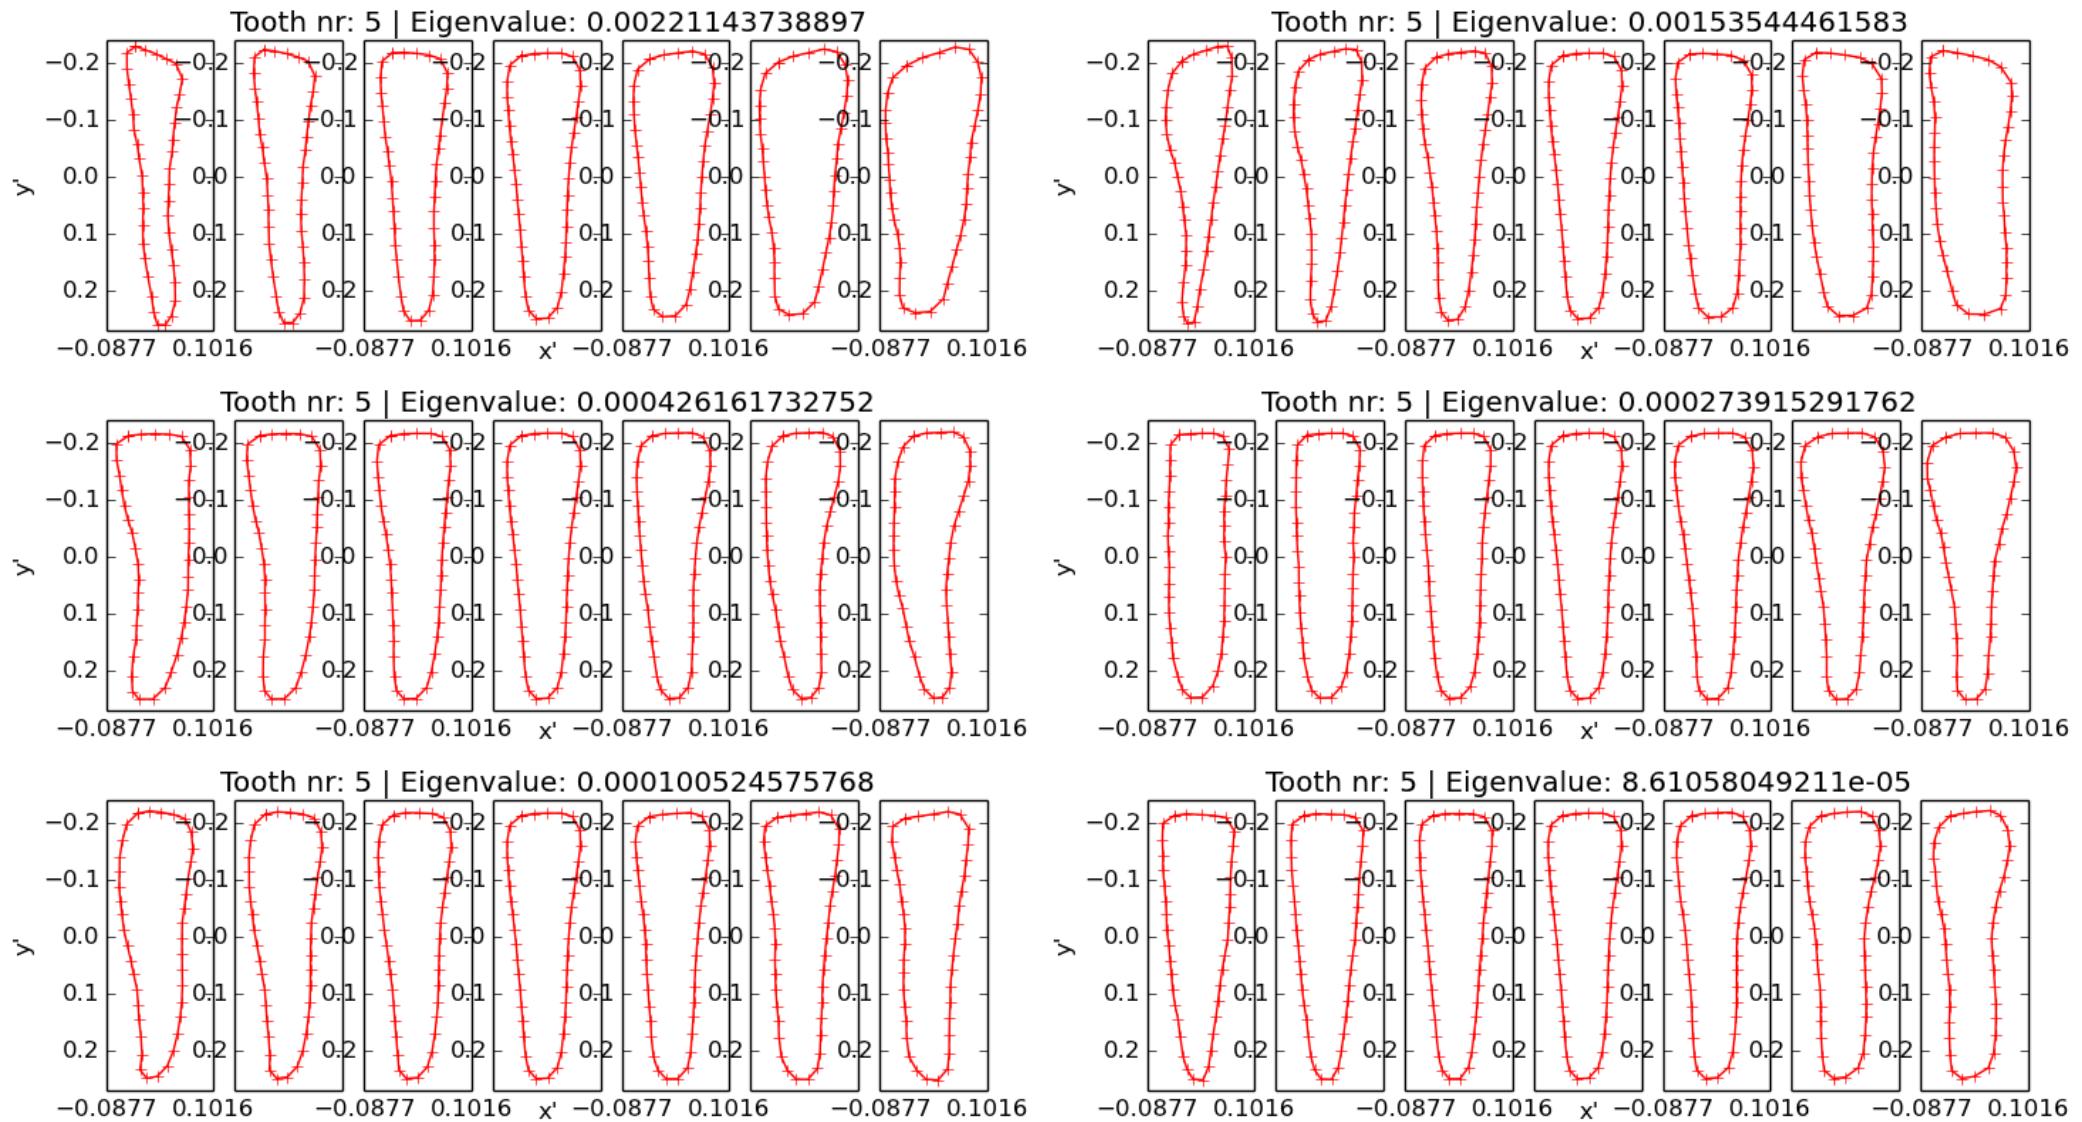
Figuur C.2: Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de tweede tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactoren in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.

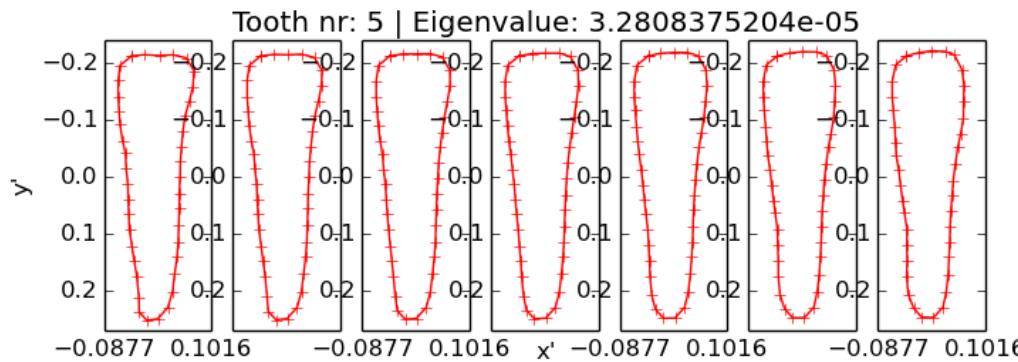


Figuur C.3: Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de derde tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactoren in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.

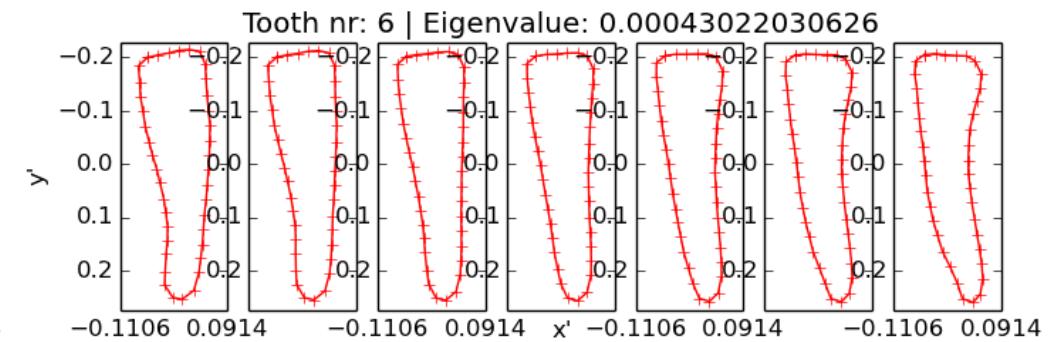
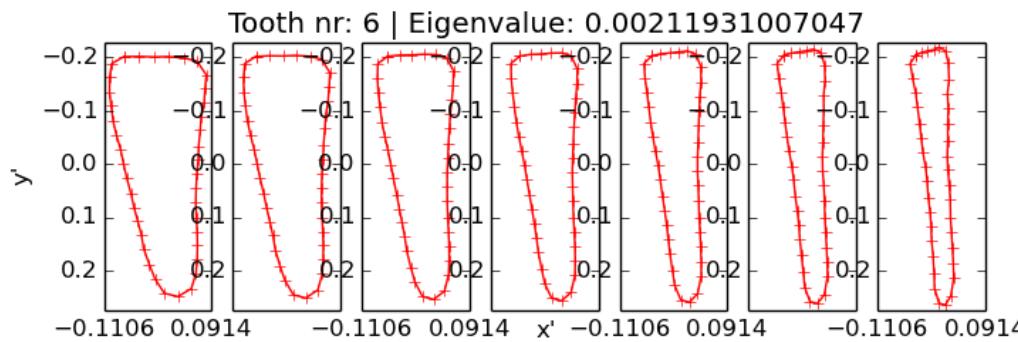


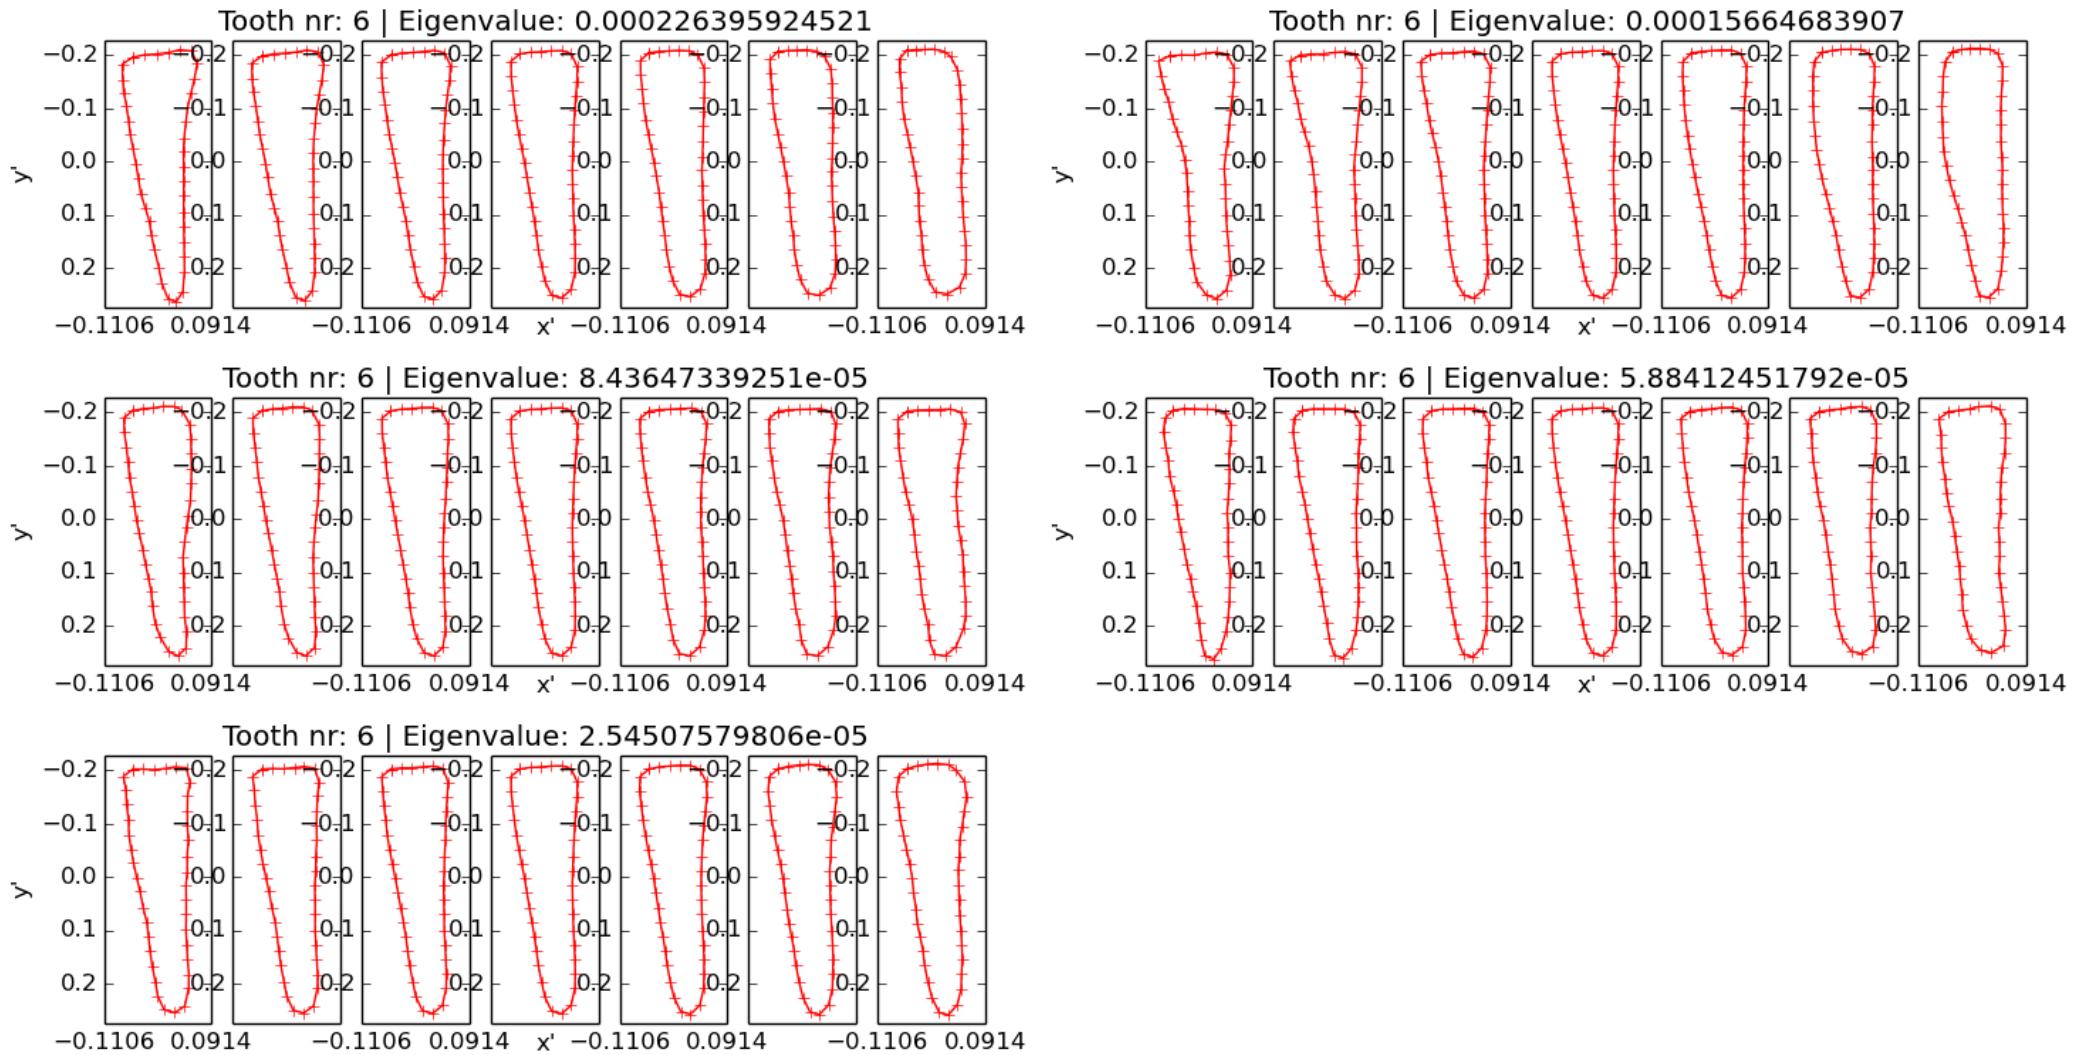
Figuur C.4: Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de vierde tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactoren in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.



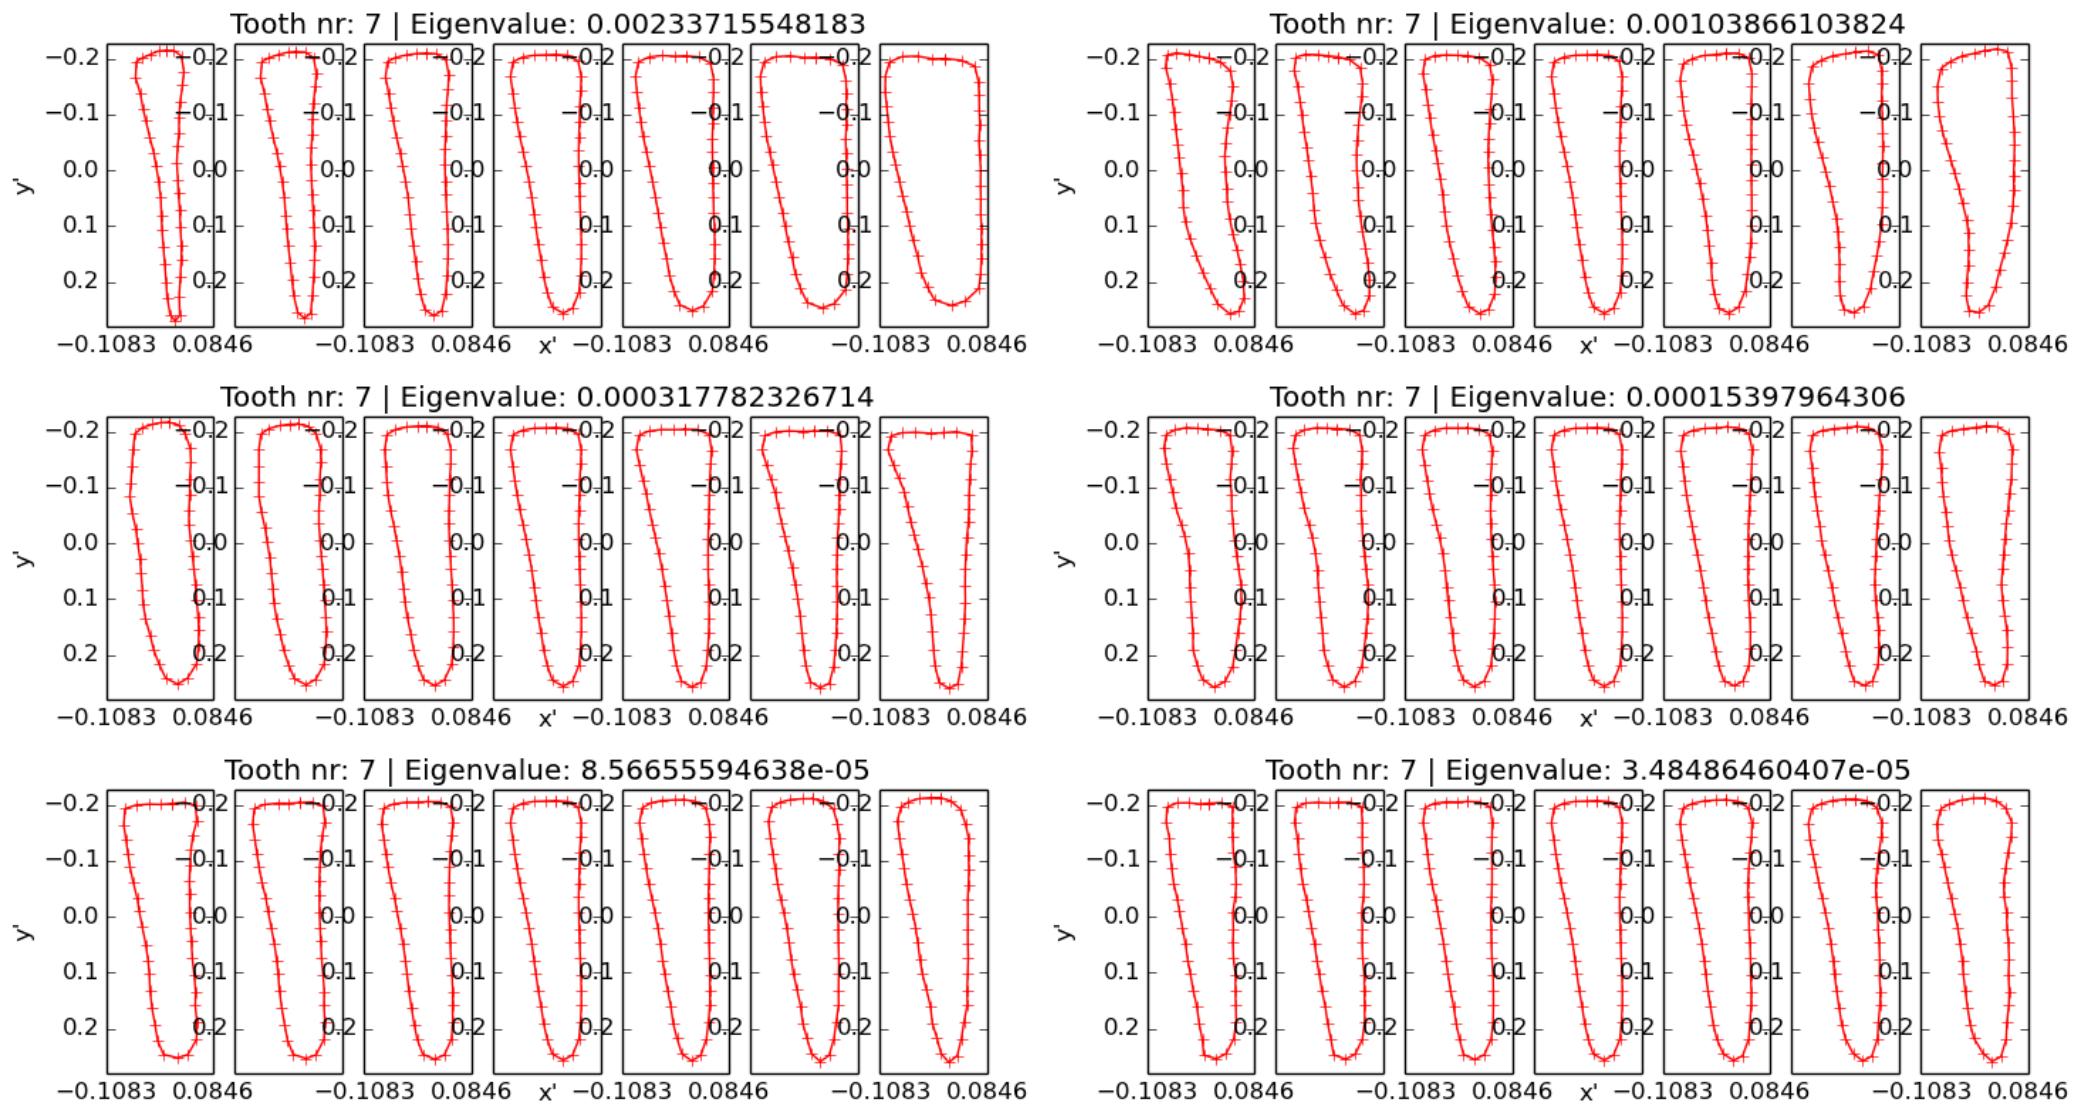


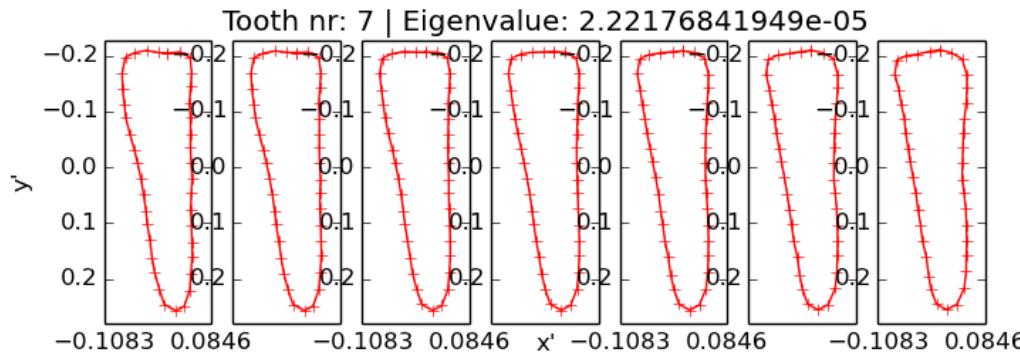
Figuur C.5: Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de vijfde tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactoren in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.



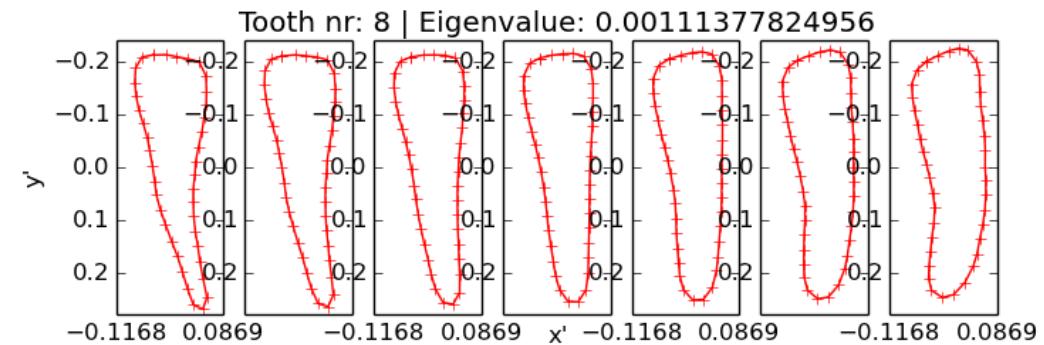
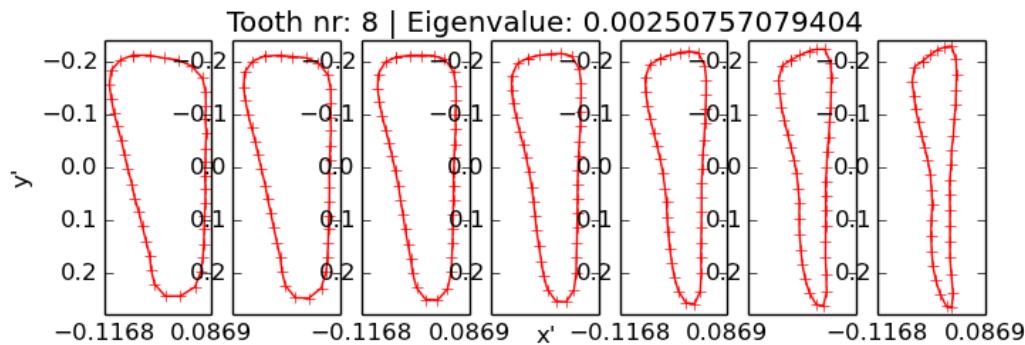


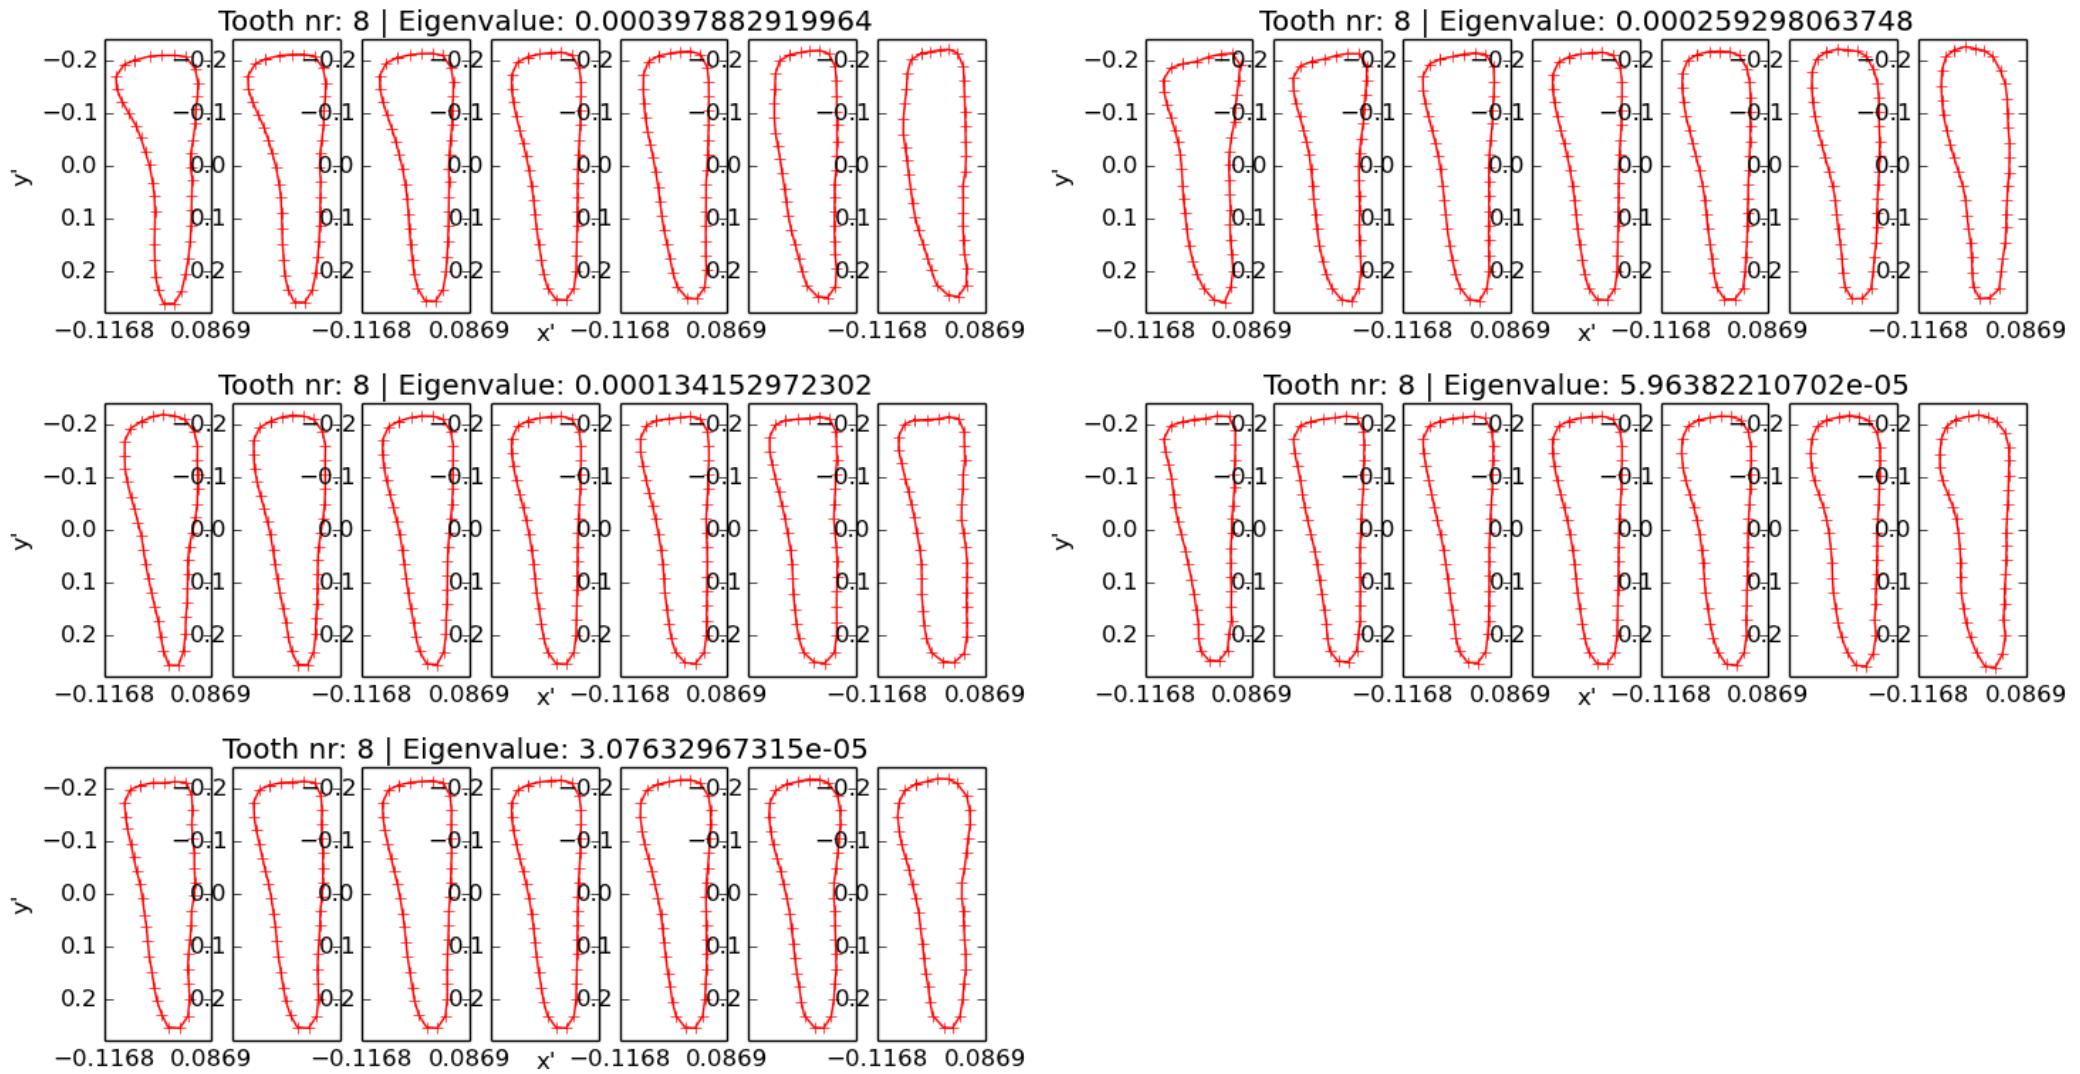
Figuur C.6: Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de zesde tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactoren in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.





Figuur C.7: Het effect van $-3\sqrt{\lambda}$, $-2\sqrt{\lambda}$, $-\sqrt{\lambda}$, 0, $\sqrt{\lambda}$, $2\sqrt{\lambda}$, $3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de zevende tand in de model-coördinatenruimte (x' , y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactors in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.

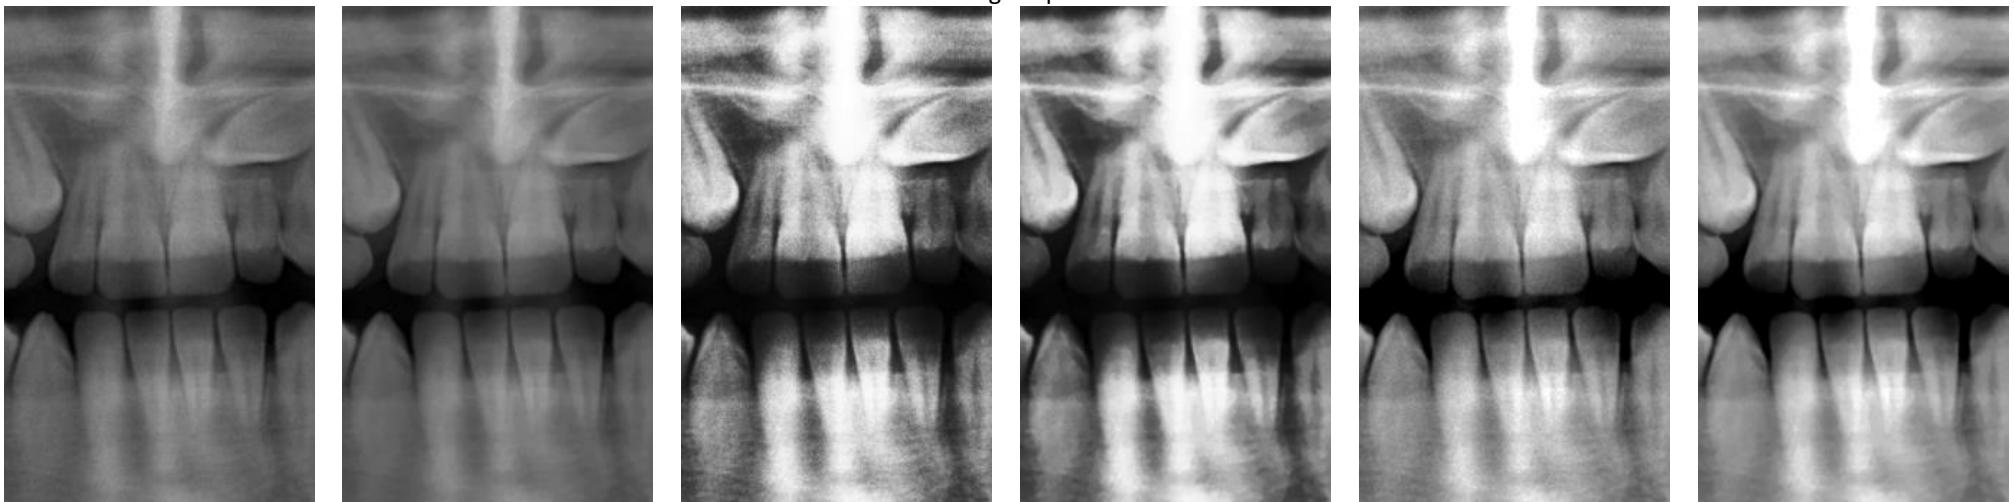




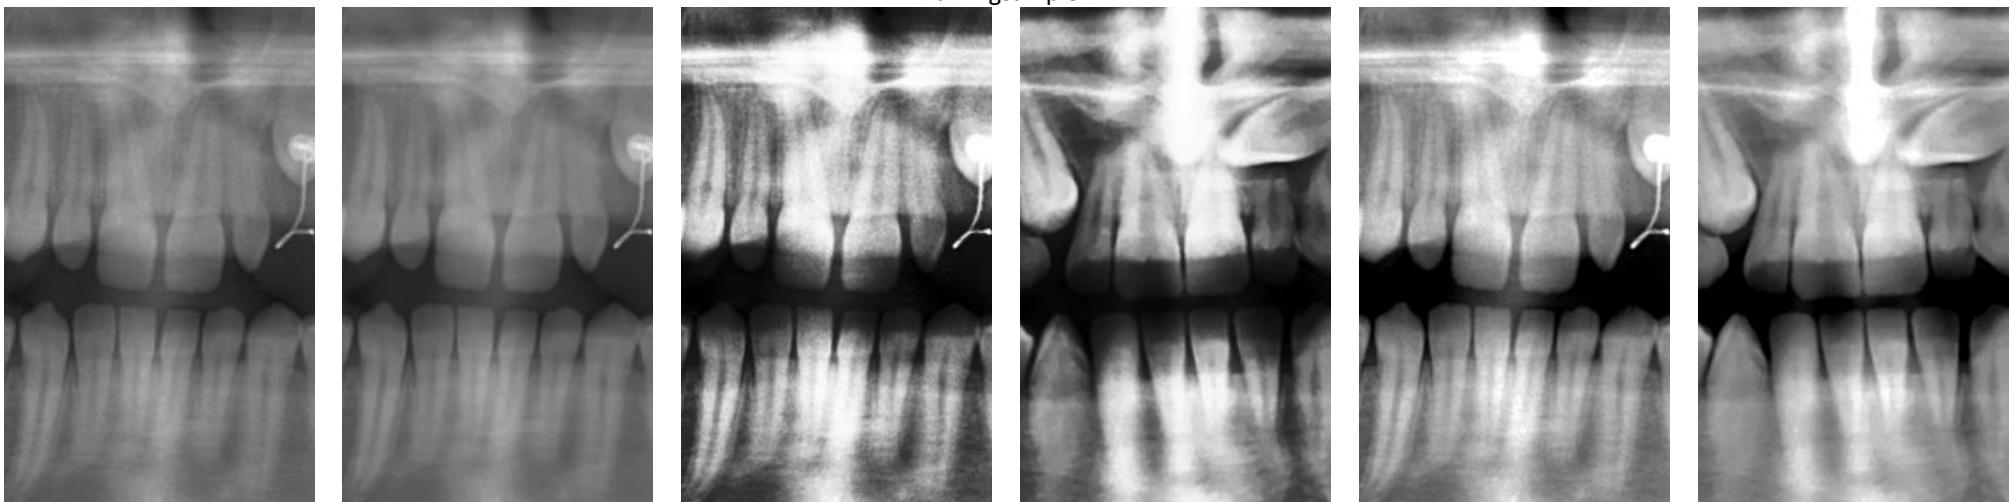
Figuur C.8: Het effect van $-3\sqrt{\lambda}, -2\sqrt{\lambda}, -\sqrt{\lambda}, 0, \sqrt{\lambda}, 2\sqrt{\lambda}, 3\sqrt{\lambda}$ (± 3 standaard deviaties) (van links naar rechts) afwijkingen ten opzichte van het gemiddelde model voor de achtste tand in de model-coördinatenruimte (x', y') startende vanaf de vormparameter verantwoordelijk voor de grootste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model en gaande naar de vormparameter verantwoordelijk voor de kleinste variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model (van boven naar onder). Hierbij zijn deze vormfactors in beschouwing genomen die minstens 98% van de variantie van de landmarkposities van de 14 trainingsamples t.o.v. het gemiddelde model verklaren.

Appendix D: Visualisaties van de resultaten van het preprocessen

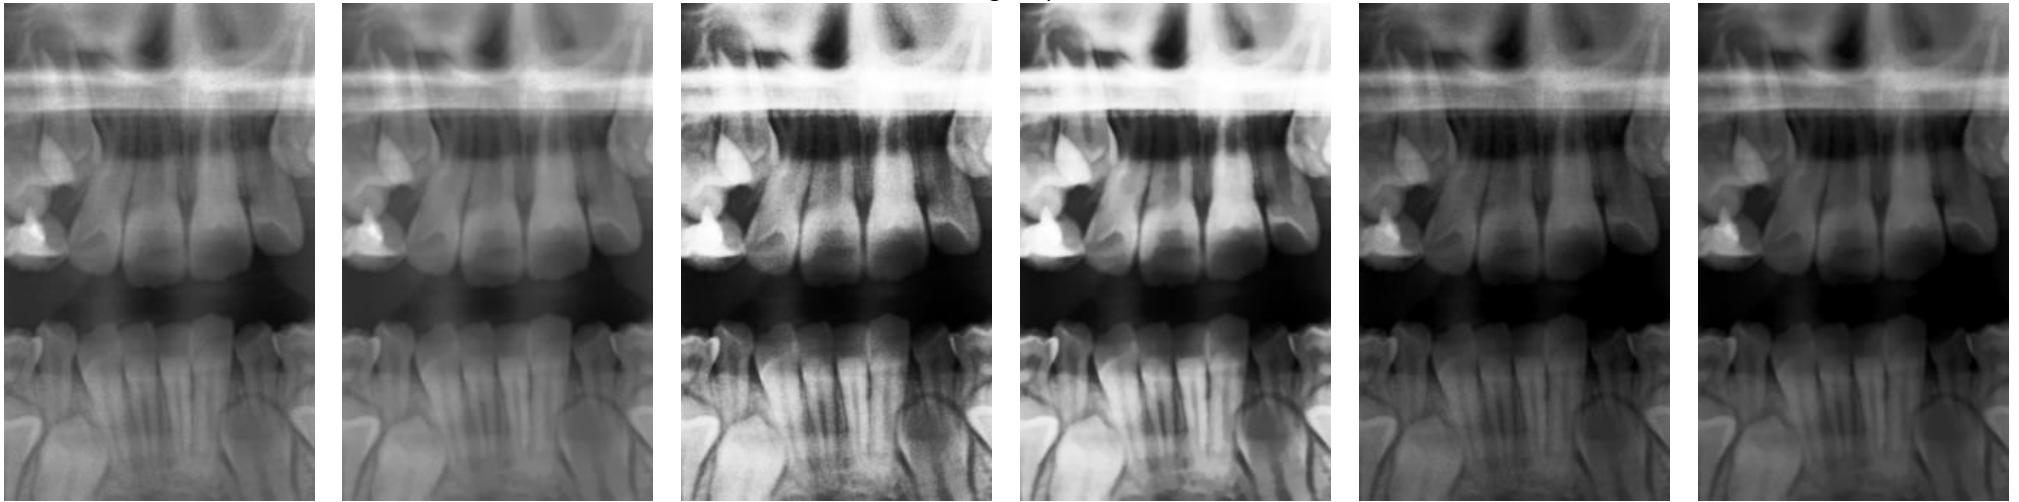
Trainingsample 1



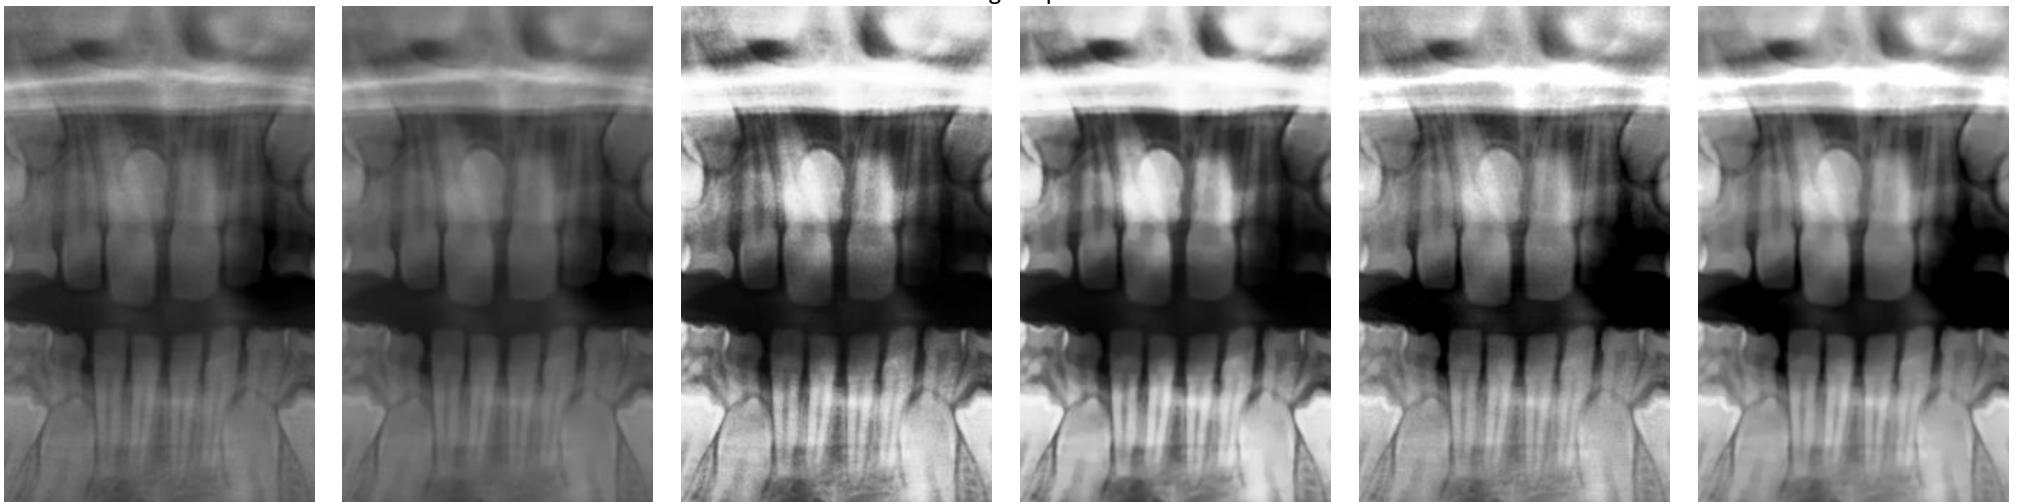
Trainingsample 2



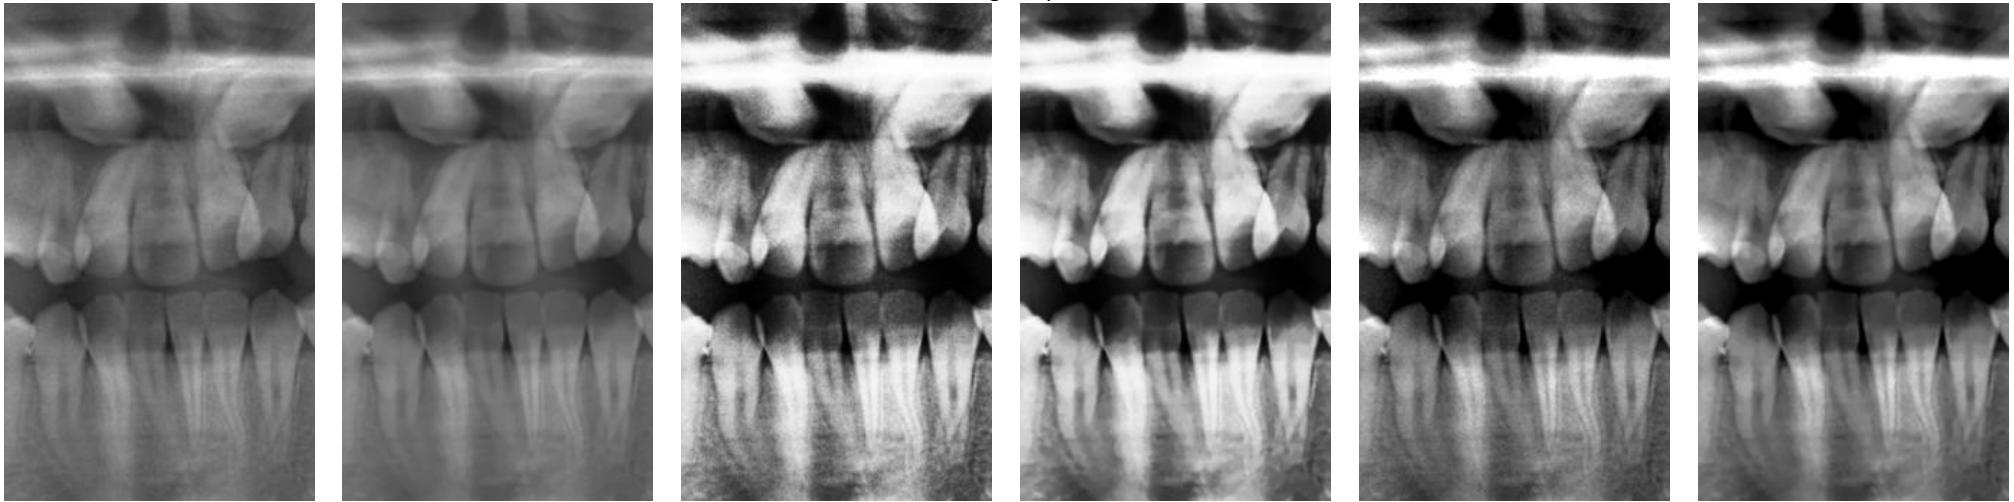
Trainingsample 3



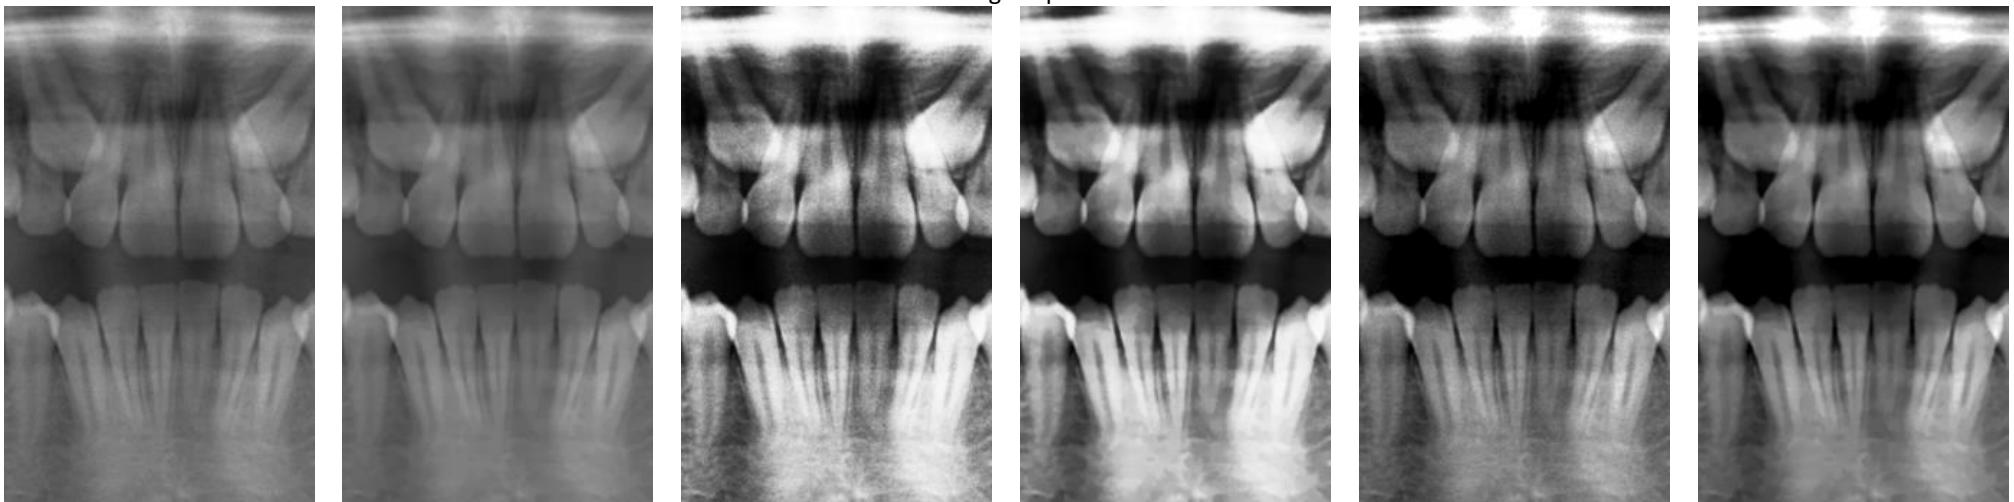
Trainingsample 4



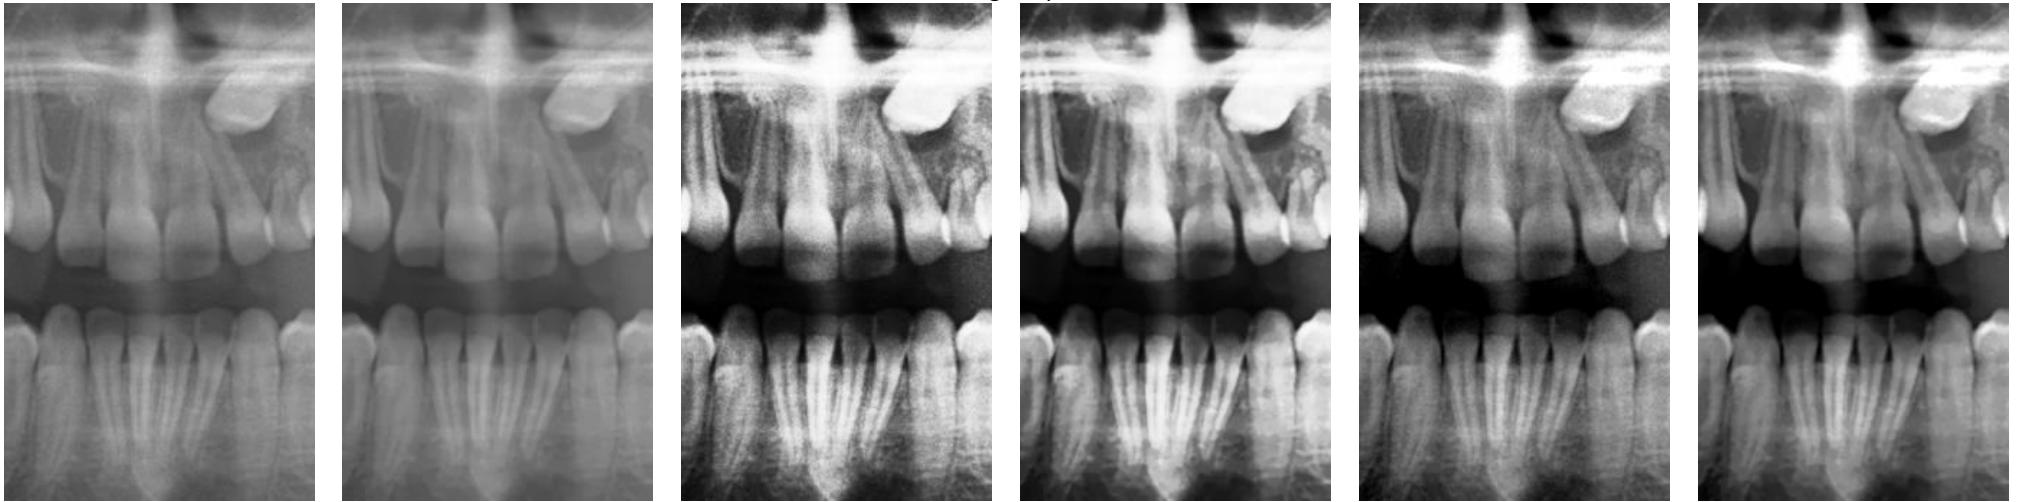
Trainingsample 5



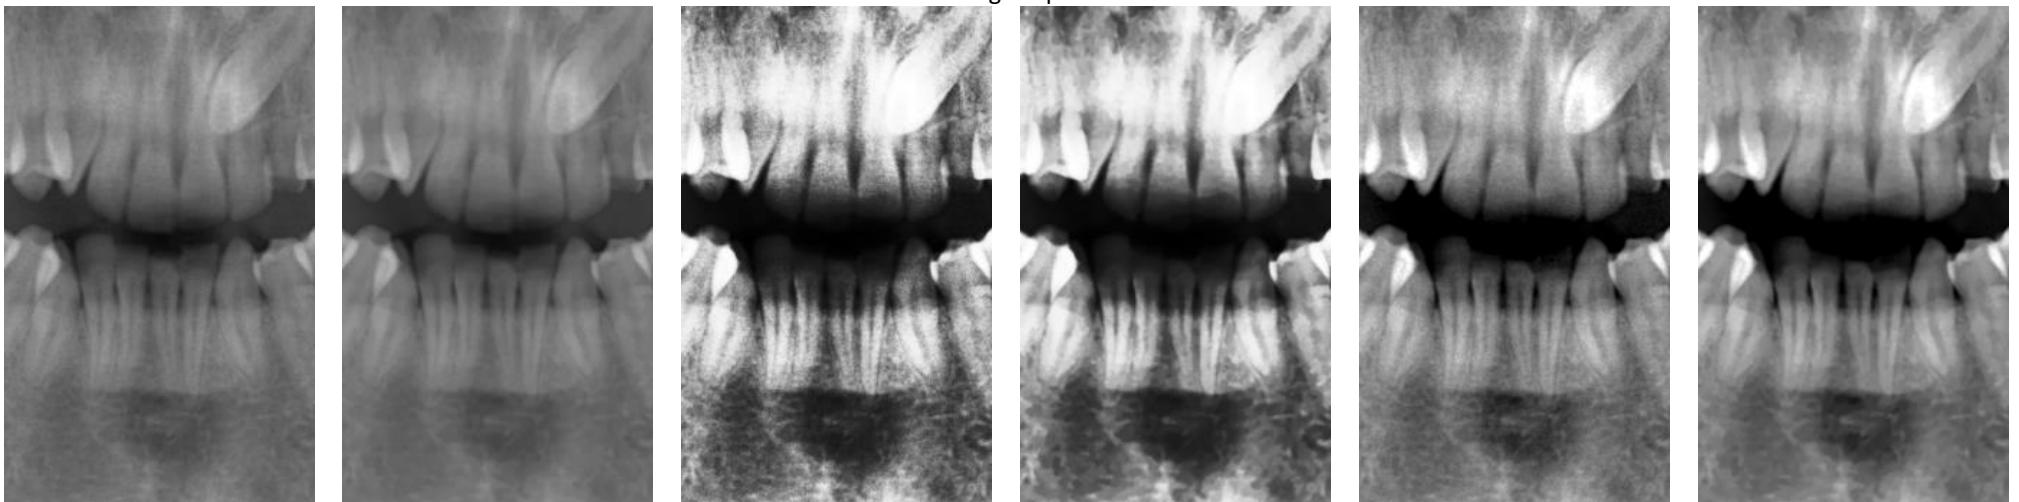
Trainingsample 6



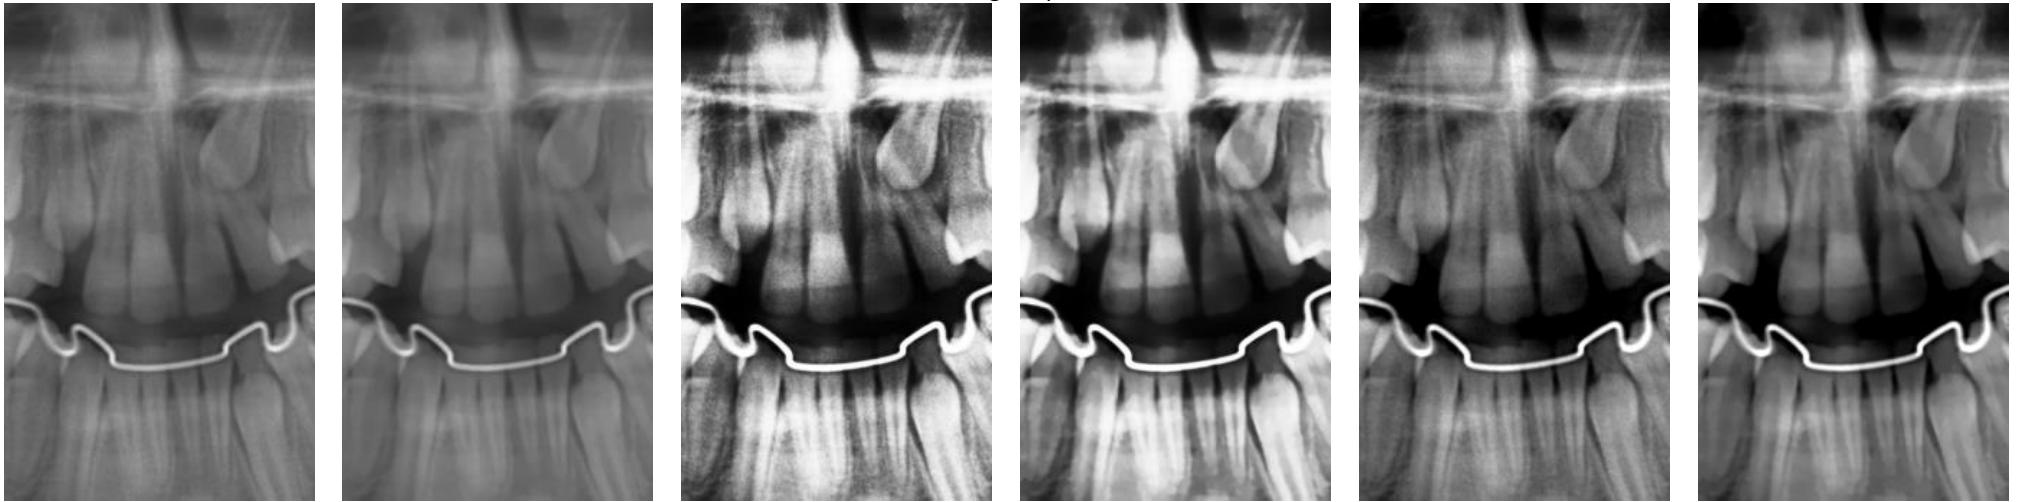
Trainingsample 7



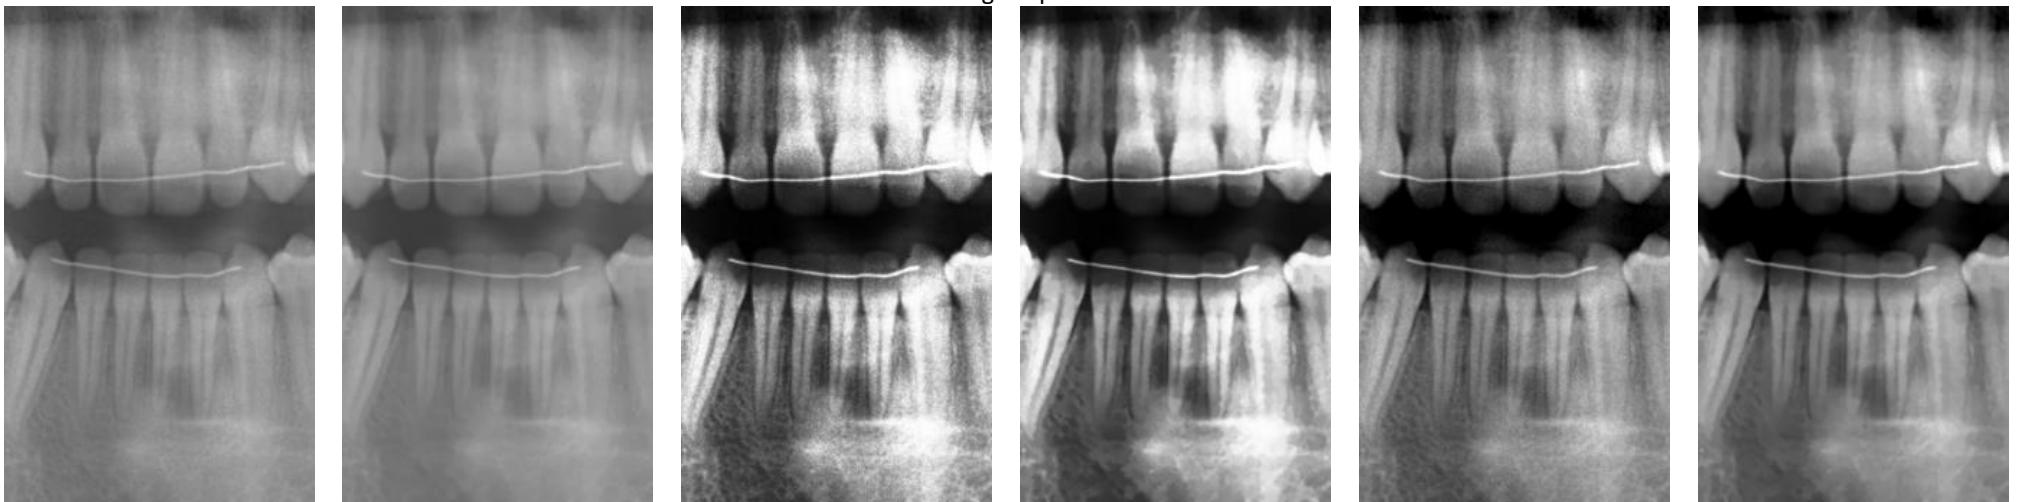
Trainingsample 8



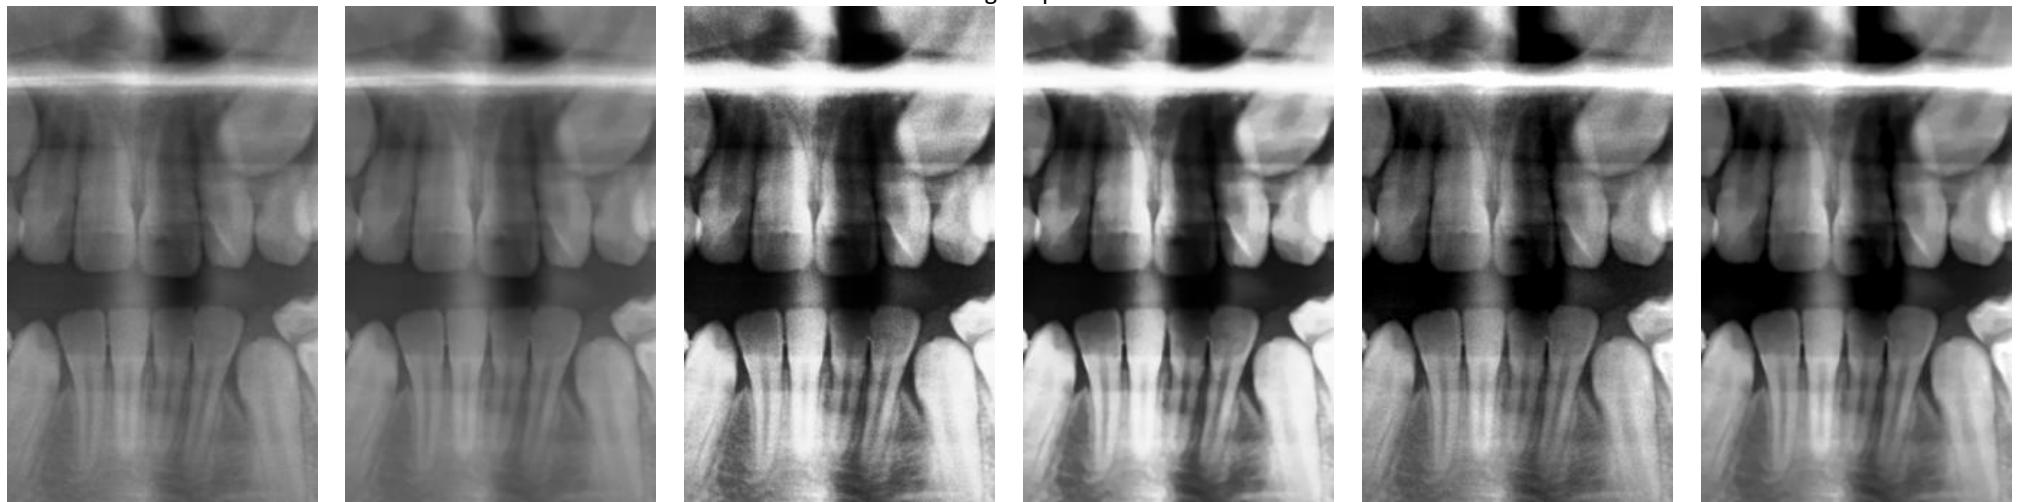
Trainingsample 9



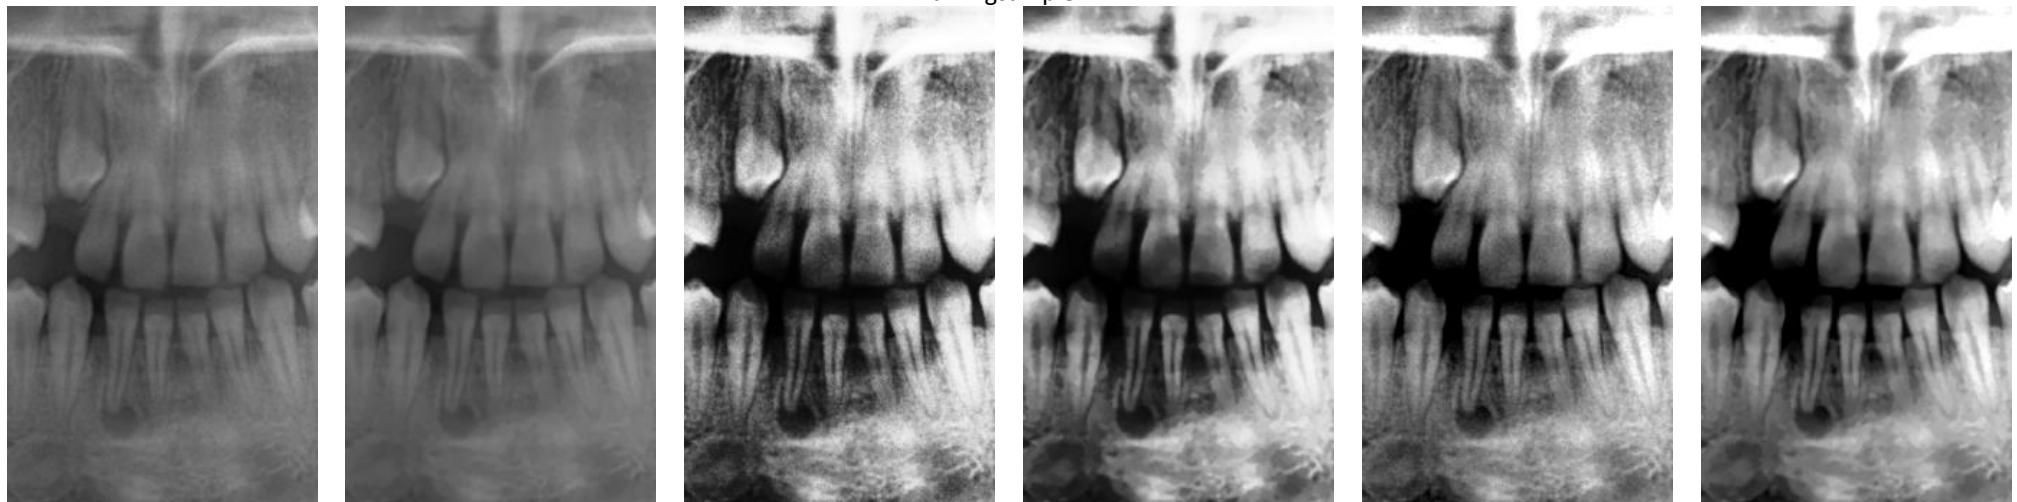
Trainingsample 10



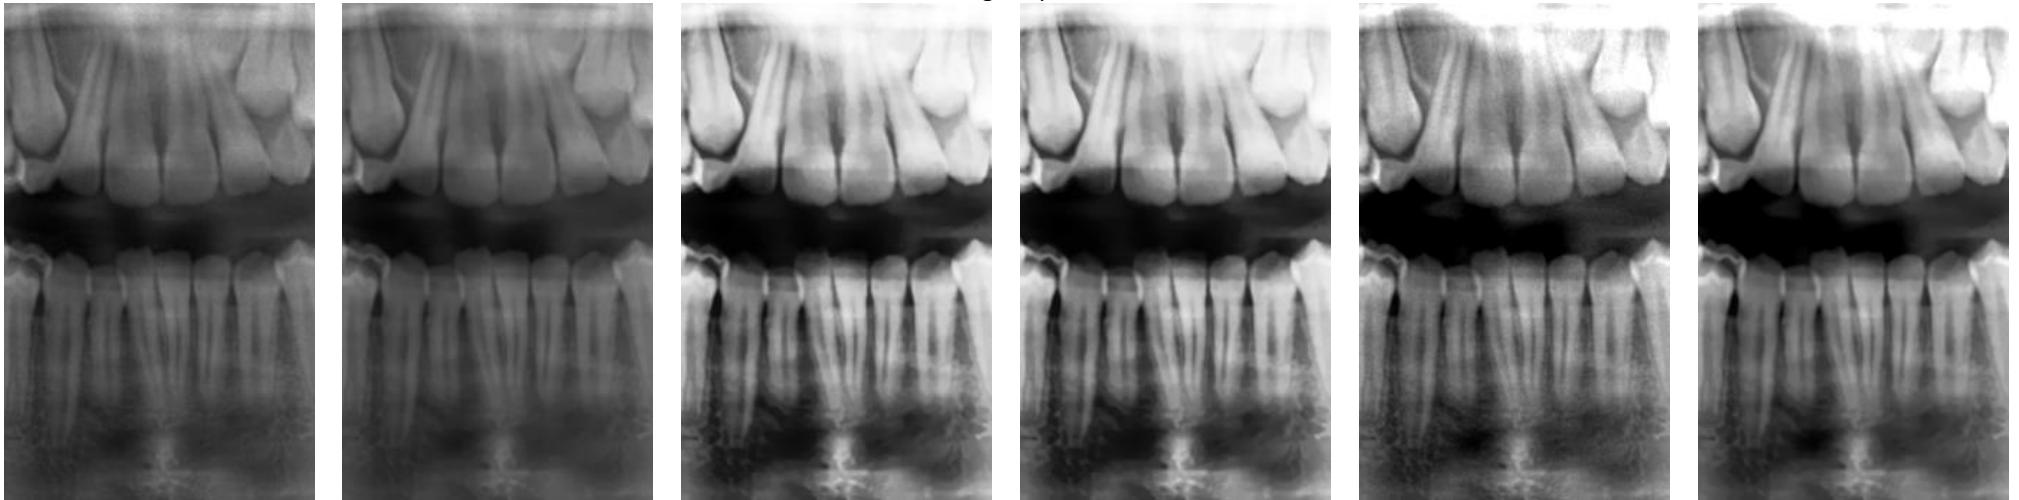
Trainingsample 11



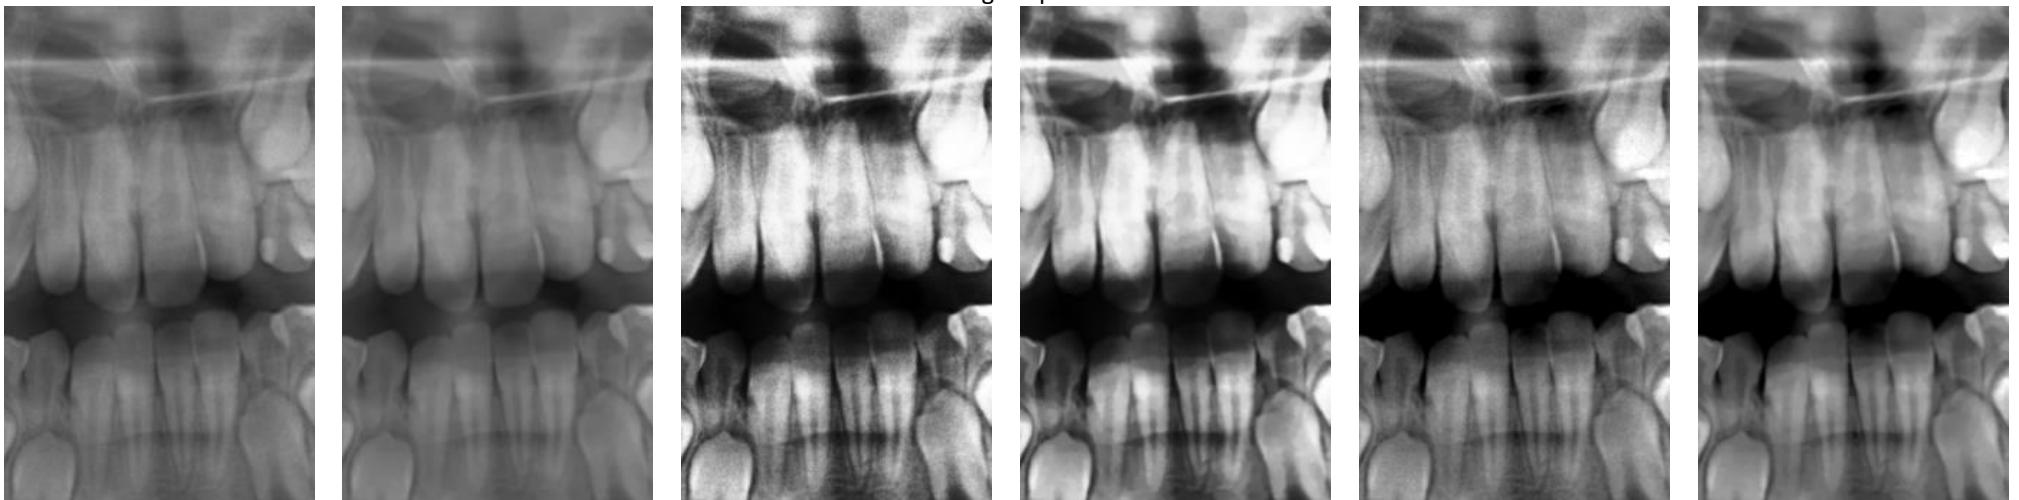
Trainingsample 12



Trainingsample 13



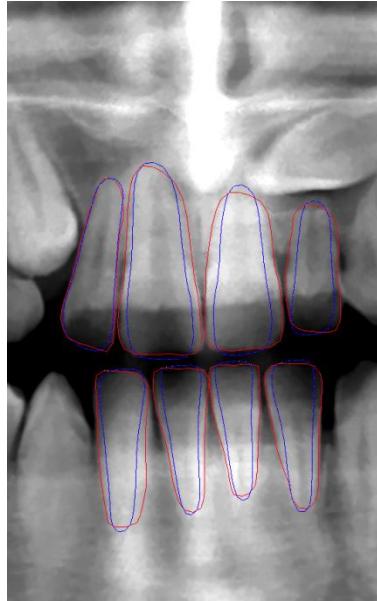
Trainingsample 14



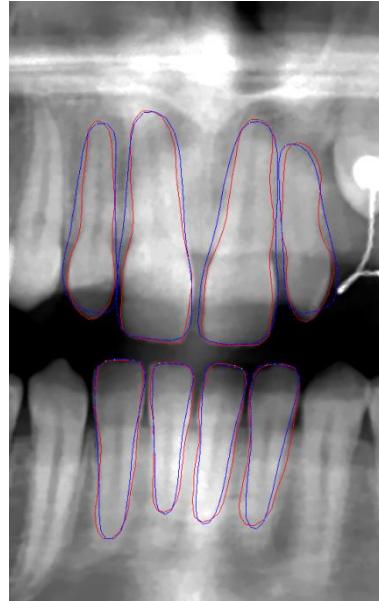
Figuur D.1: De originele radiografieën voor de 14 trainingsamples na croppen, de originele radiografieën voor de 14 trainingsamples na croppen en denoisen, de radiografieën voor de 14 trainingsamples na croppen en histogram equalization, de radiografieën voor de 14 trainingsamples na croppen, denoisen en histogram equalization, de radiografieën voor de 14 trainingsamples na croppen en (linear) contrast stretching en de radiografieën voor de 14 trainingsamples na croppen, denoisen en (linear) contrast stretching.

Appendix E: Visualisaties van de constructie van de fitting functies & resultaten fitting procedure (met manuele initialisatie)

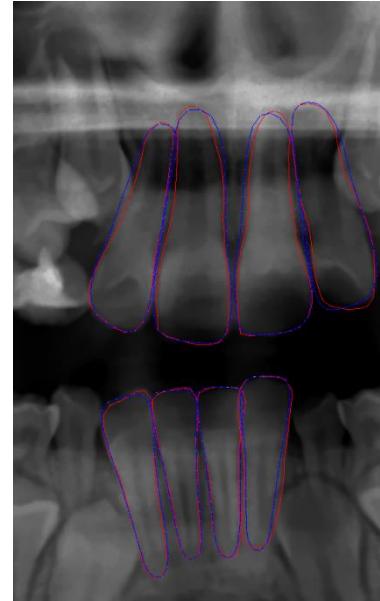
Trainingsample 1



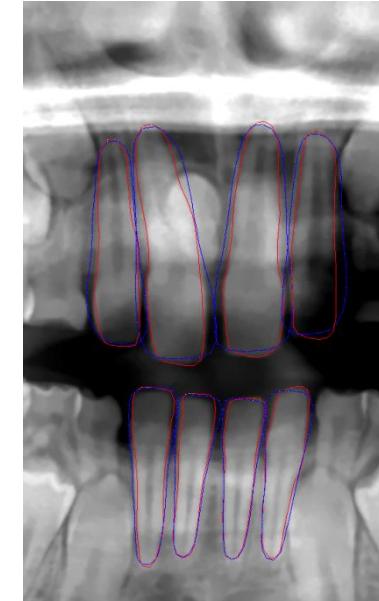
Trainingsample 2



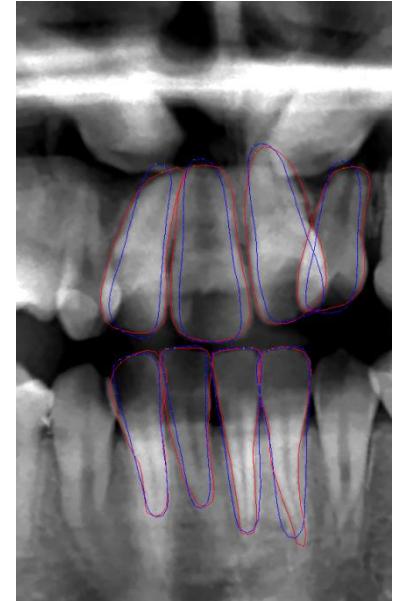
Trainingsample 3



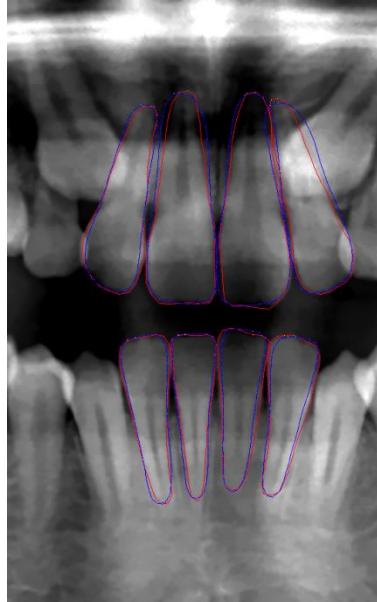
Trainingsample 4



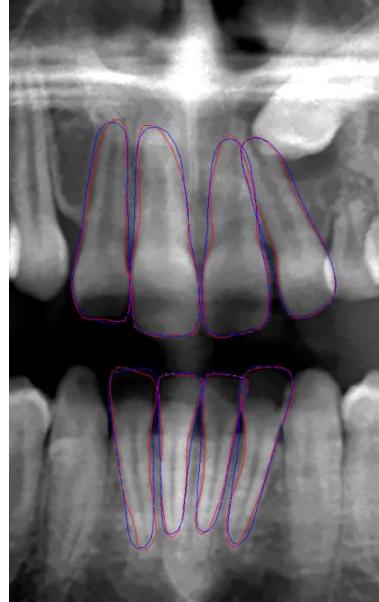
Trainingsample 5



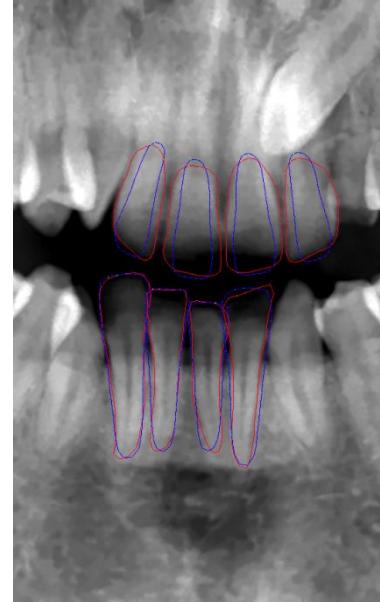
Trainingsample 6



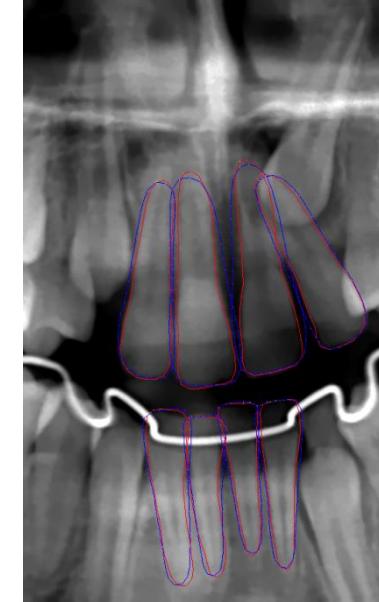
Trainingsample 7



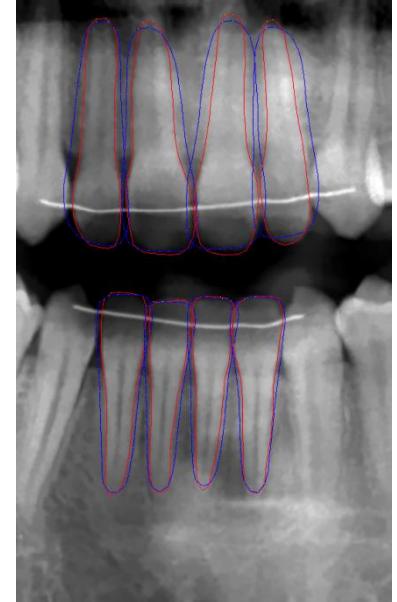
Trainingsample 8

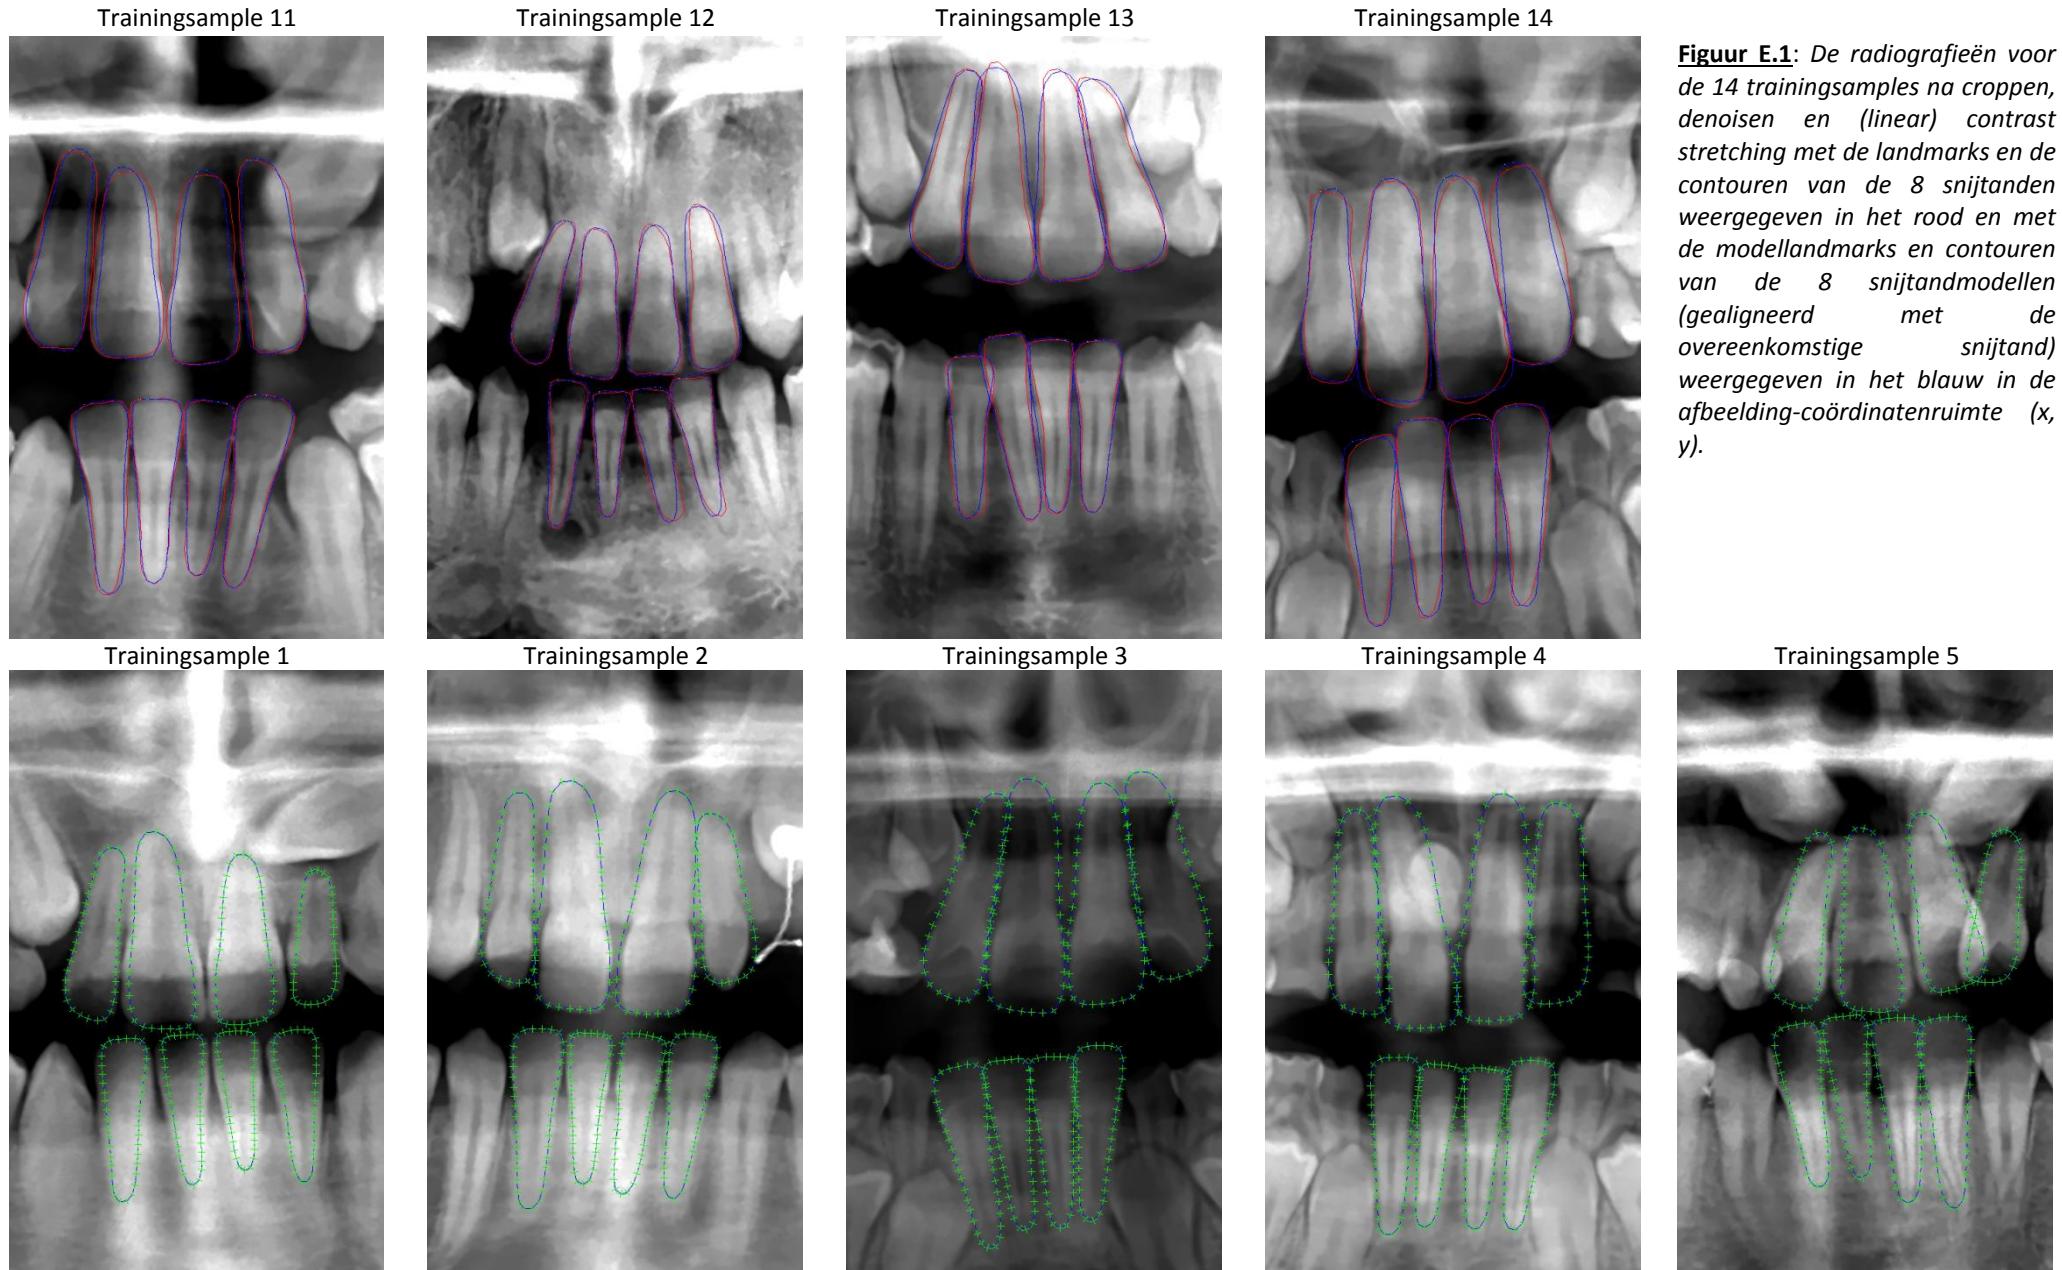


Trainingsample 9

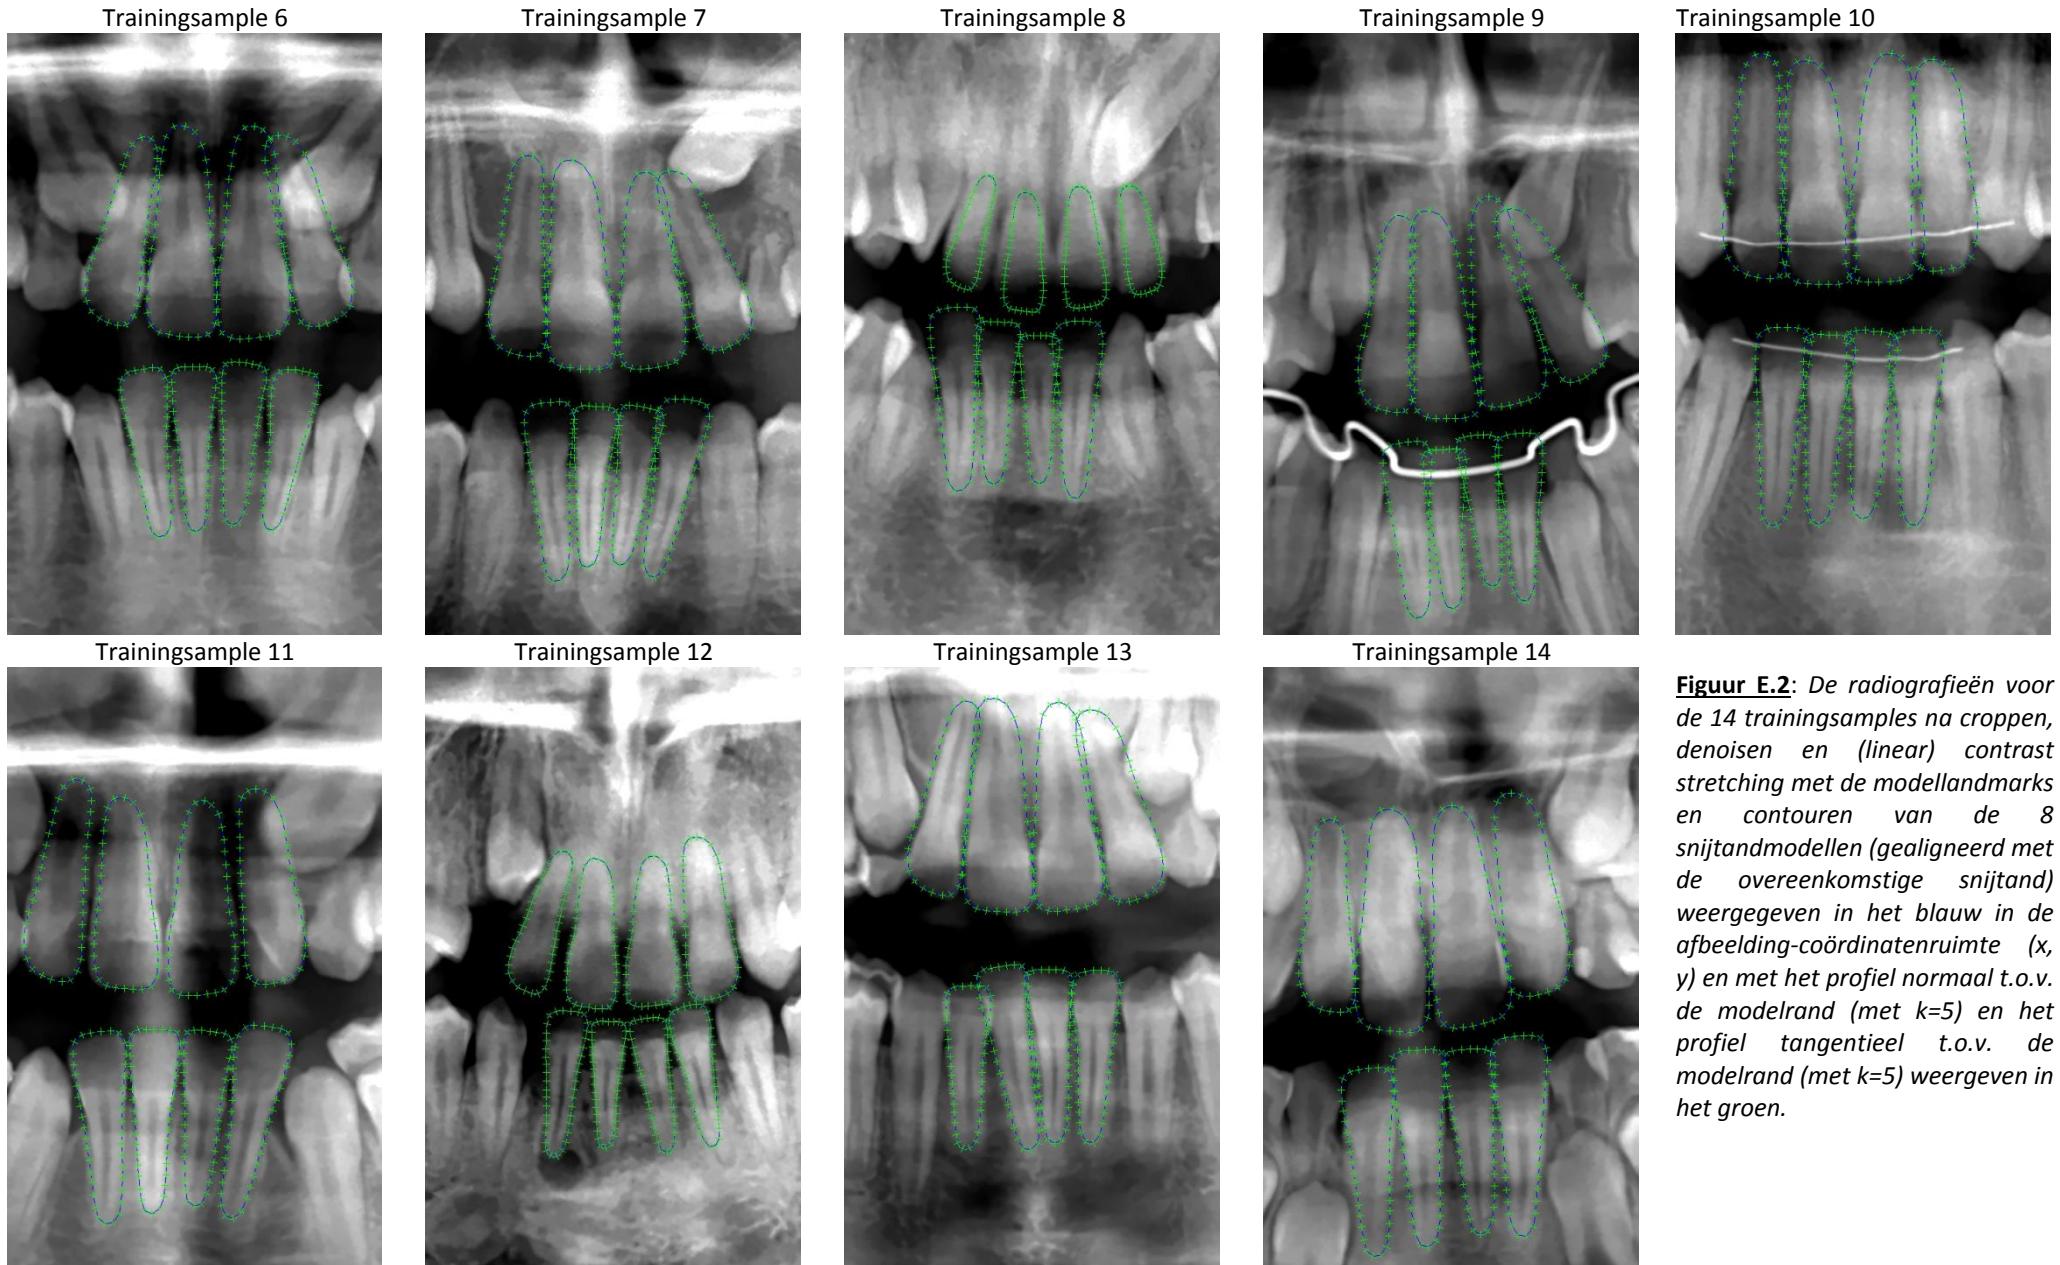


Trainingsample 10





Figuur E.1: De radiografieën voor de 14 trainingsamples na croppen, denoisen en (linear) contrast stretching met de landmarks en de contouren van de 8 snijtanden weergegeven in het rood en met de modellandmarks en contouren van de 8 snijtandmodellen (gealigneerd met de overeenkomstige snijtand) weergegeven in het blauw in de afbeelding-coördinatenruimte (x, y).



Trainingsample 6 Trainingsample 7 Trainingsample 8 Trainingsample 9 Trainingsample 10

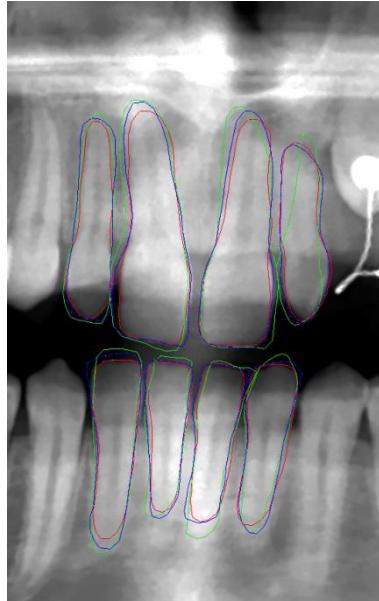
Trainingsample 11 Trainingsample 12 Trainingsample 13 Trainingsample 14

Figuur E.2: De radiografieën voor de 14 trainingsamples na croppen, denoisen en (linear) contrast stretching met de modellandmarks en contouren van de 8 snijtandmodellen (gealigneerd met de overeenkomstige snijtand) weergegeven in het blauw in de afbeelding-coördinatenruimte (x , y) en met het profiel normaal t.o.v. de modelrand (met $k=5$) en het profiel tangentieel t.o.v. de modelrand (met $k=5$) weergeven in het groen.

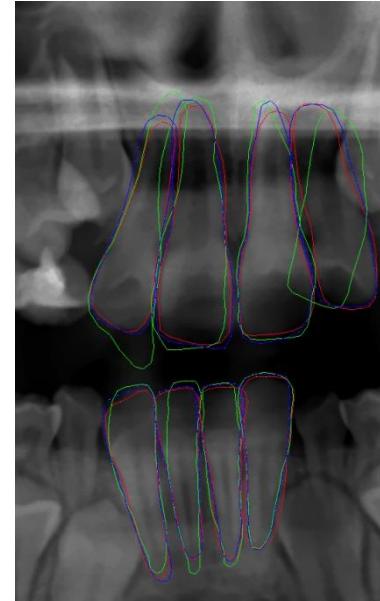
Trainingsample 1



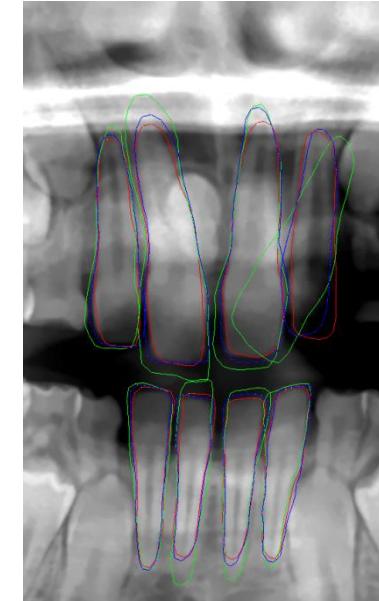
Trainingsample 2



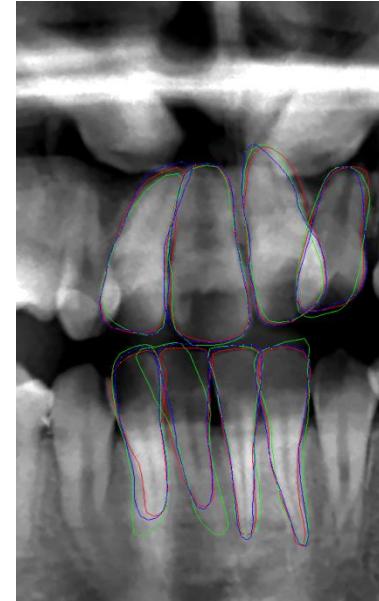
Trainingsample 3



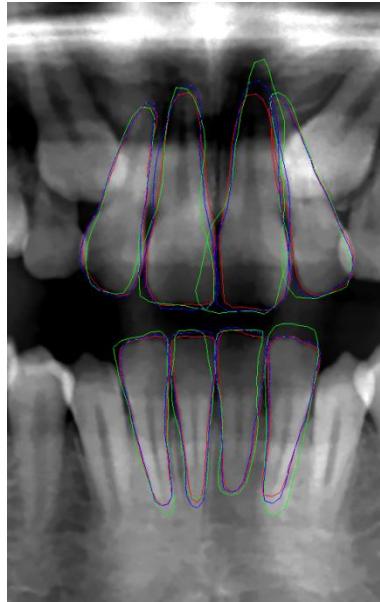
Trainingsample 4



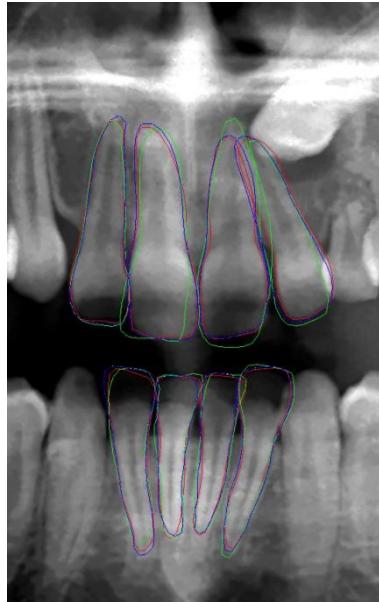
Trainingsample 5



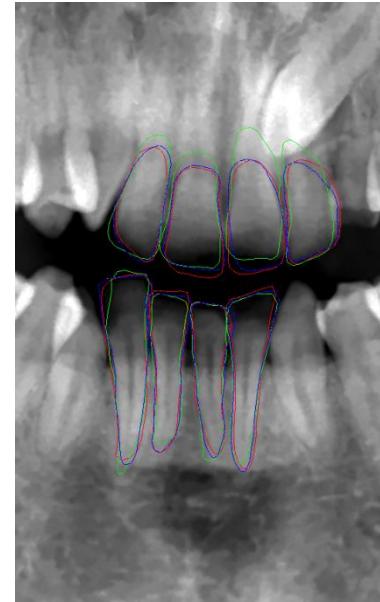
Trainingsample 6



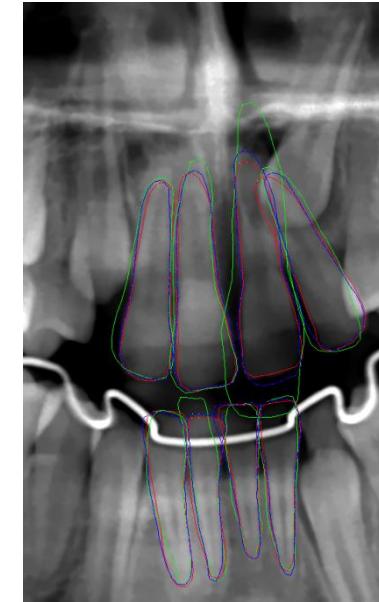
Trainingsample 7



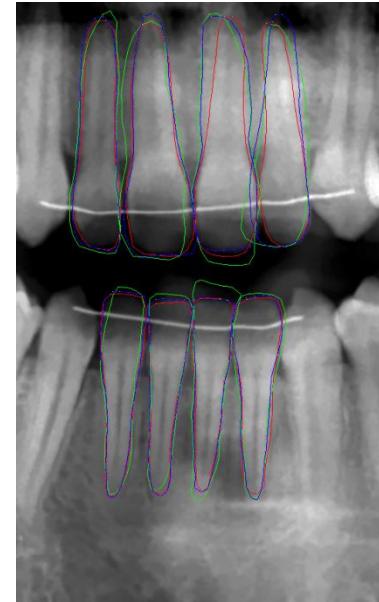
Trainingsample 8



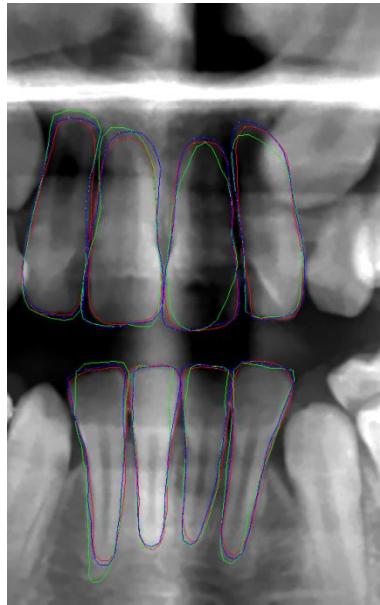
Trainingsample 9



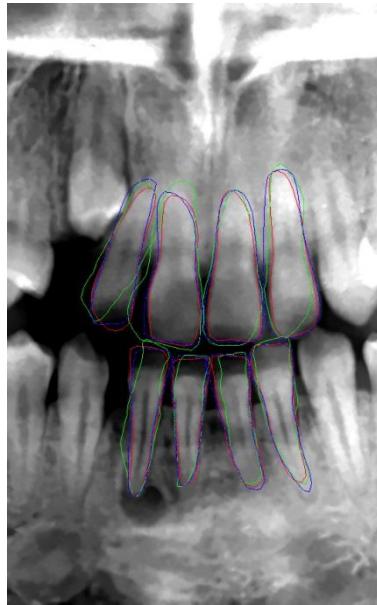
Trainingsample 10



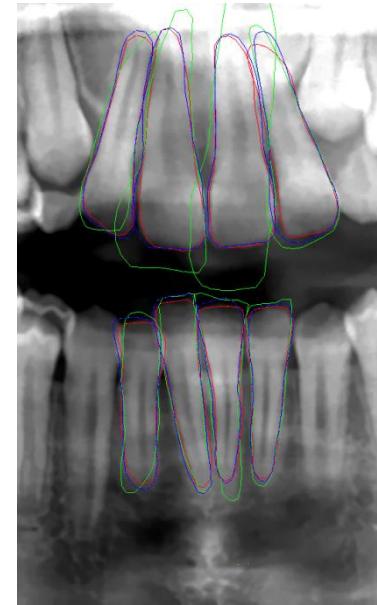
Trainingsample 11



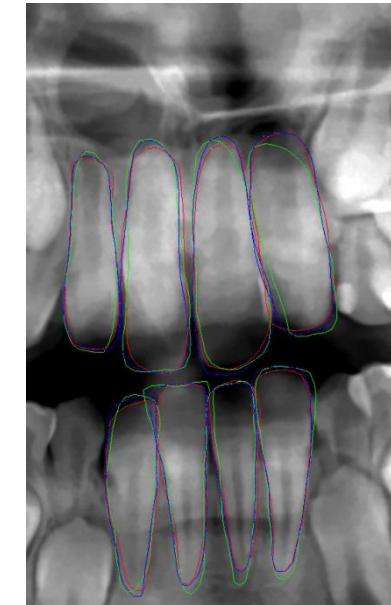
Trainingsample 12



Trainingsample 13

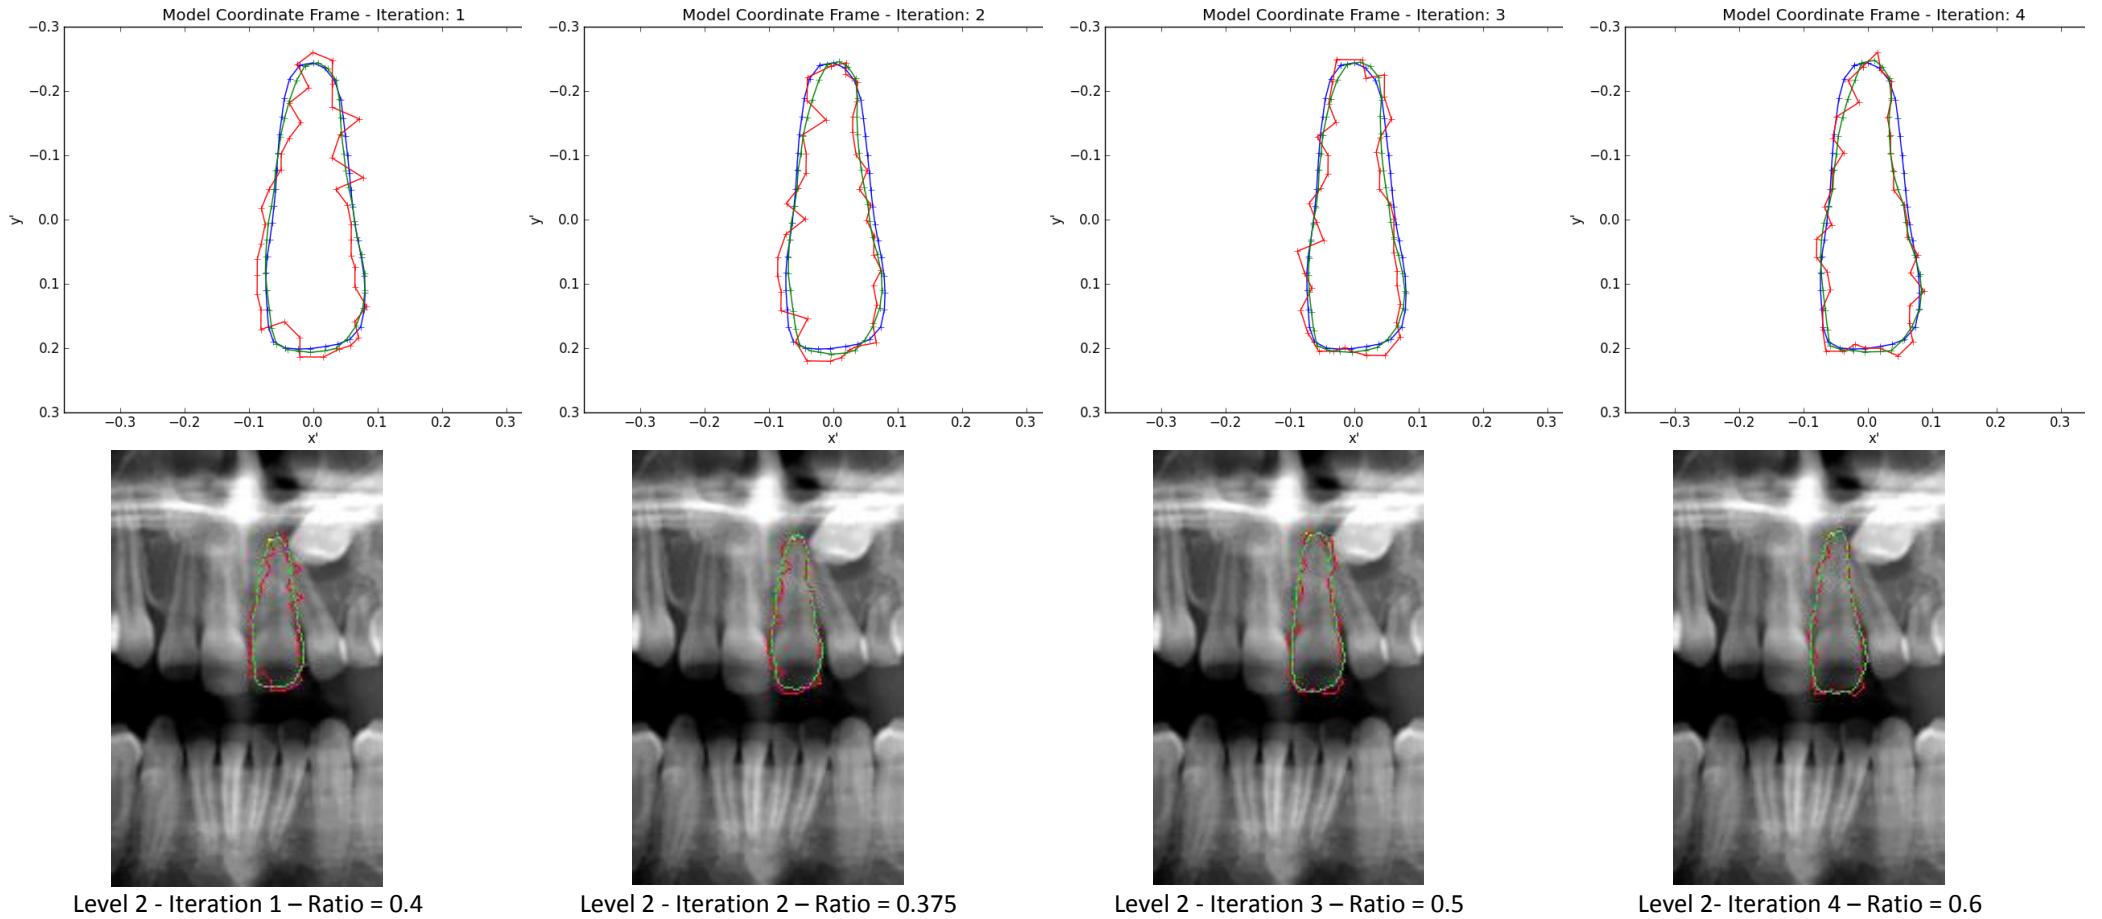


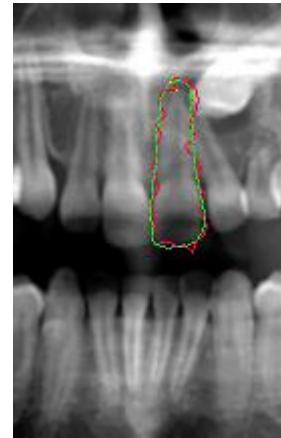
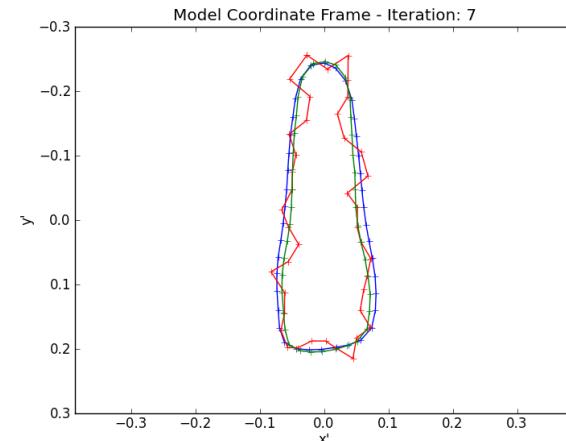
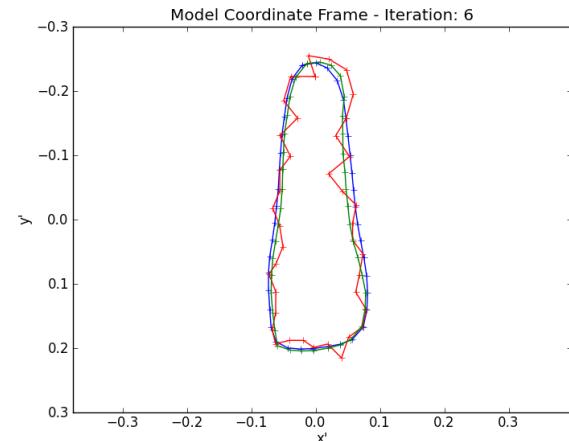
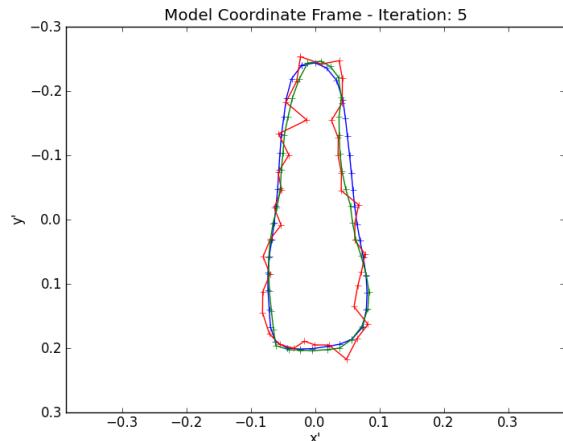
Trainingsample 14



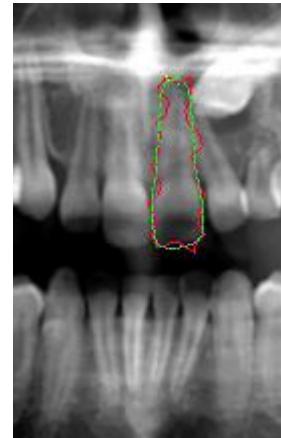
Figuur E.3: De Referentielandmarks en contouren als initiële startoplossing weergegeven in het rood samen met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen, weergegeven in het blauw, en fitting functies die zowel het profiel normaal en tangentieel t.o.v. de modelranden in rekening nemen; weergegeven in het groen.

$$\#levels = 3, k = 4, m = 8$$

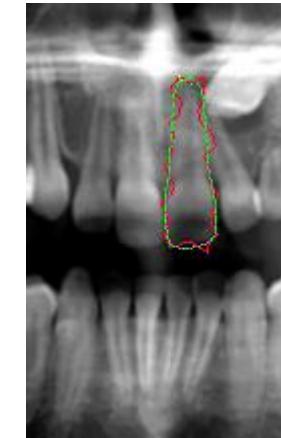




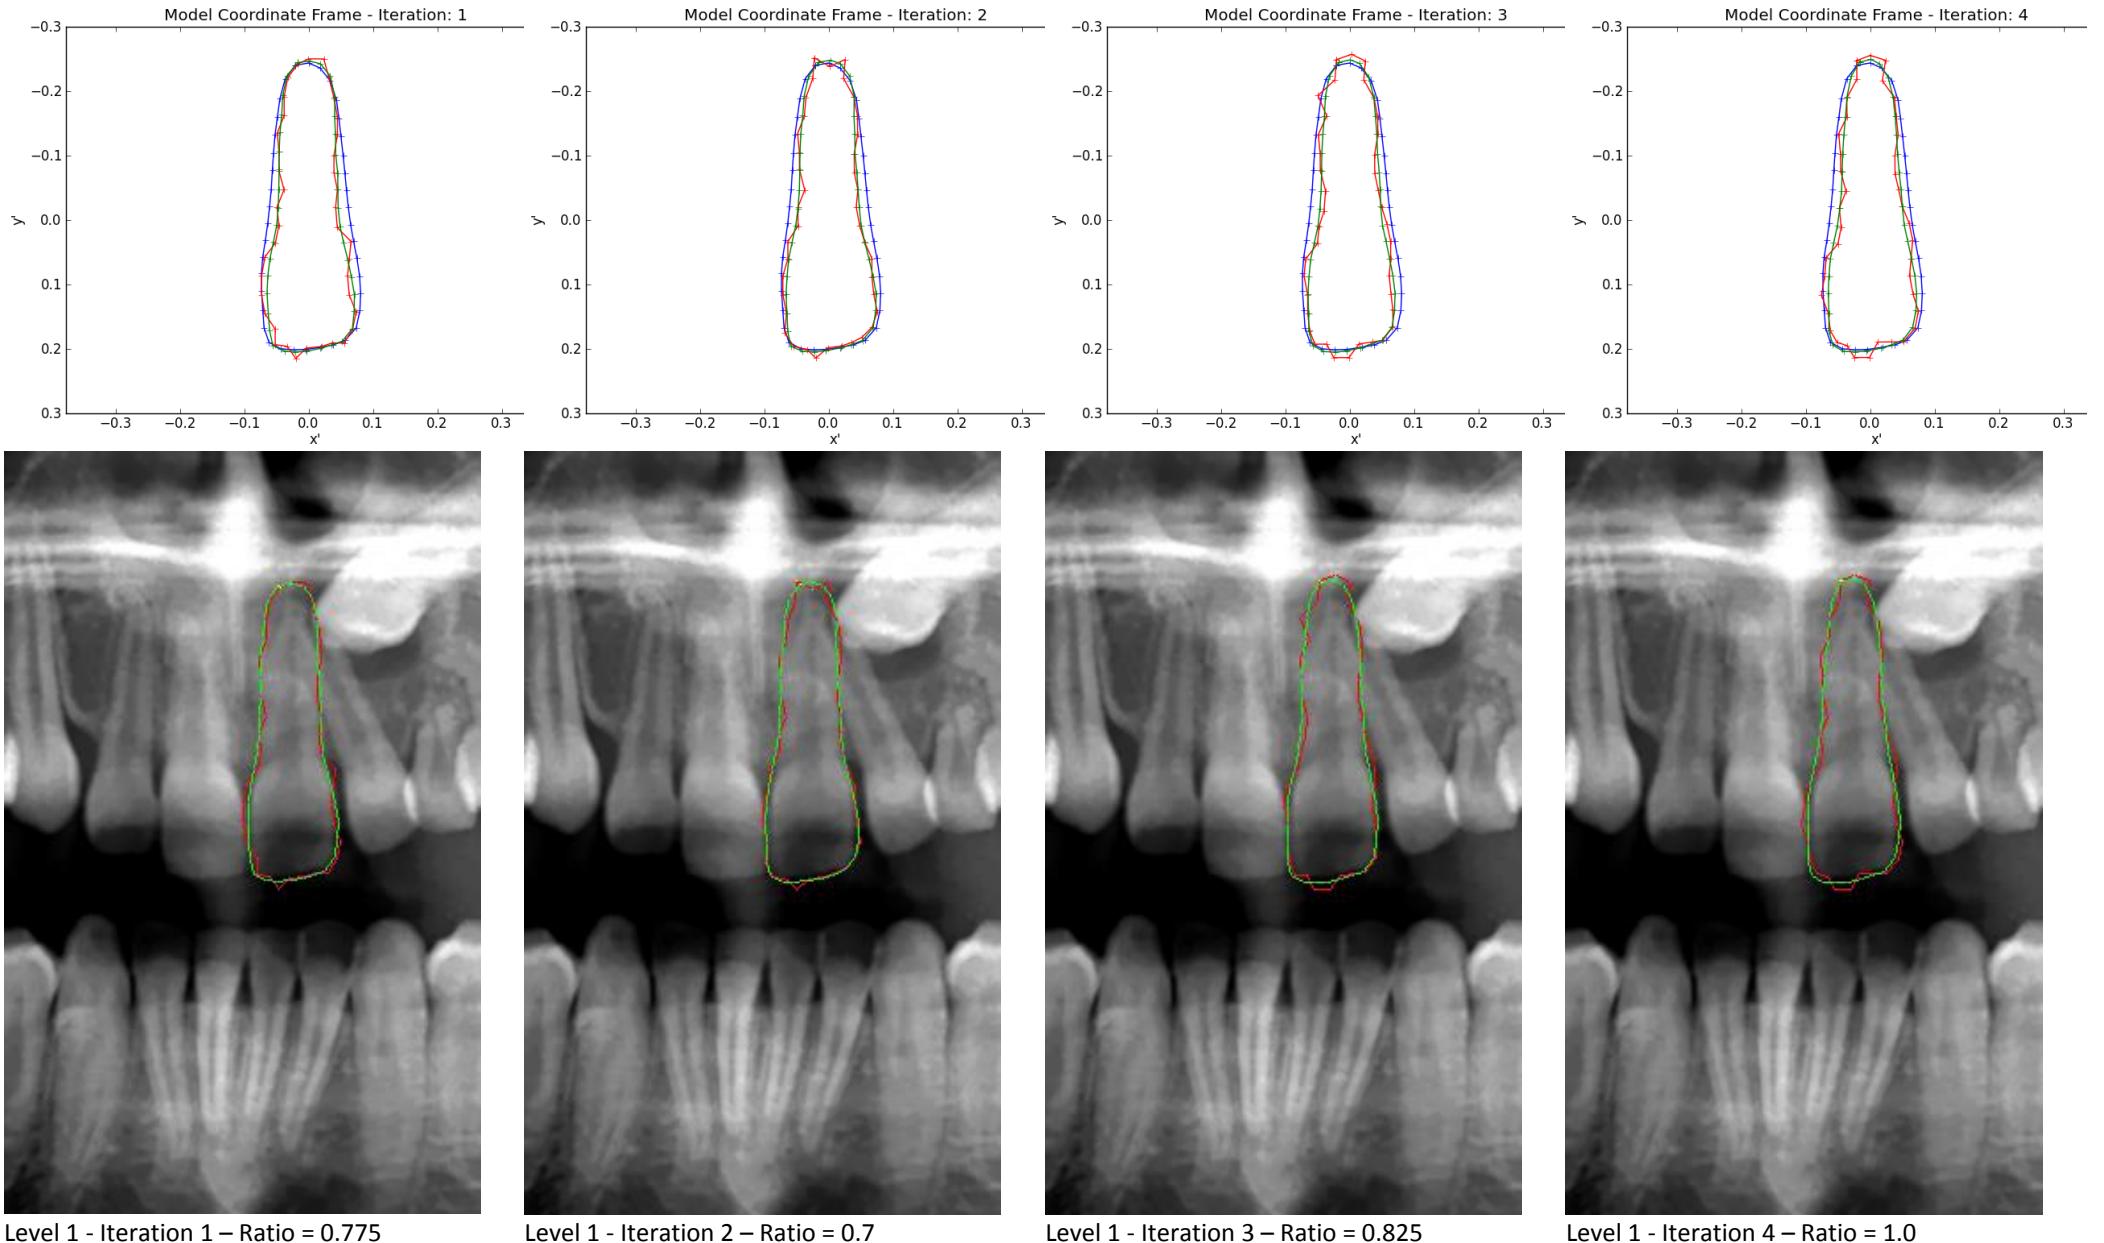
Level 2- Iteration 5 – Ratio = 0.6

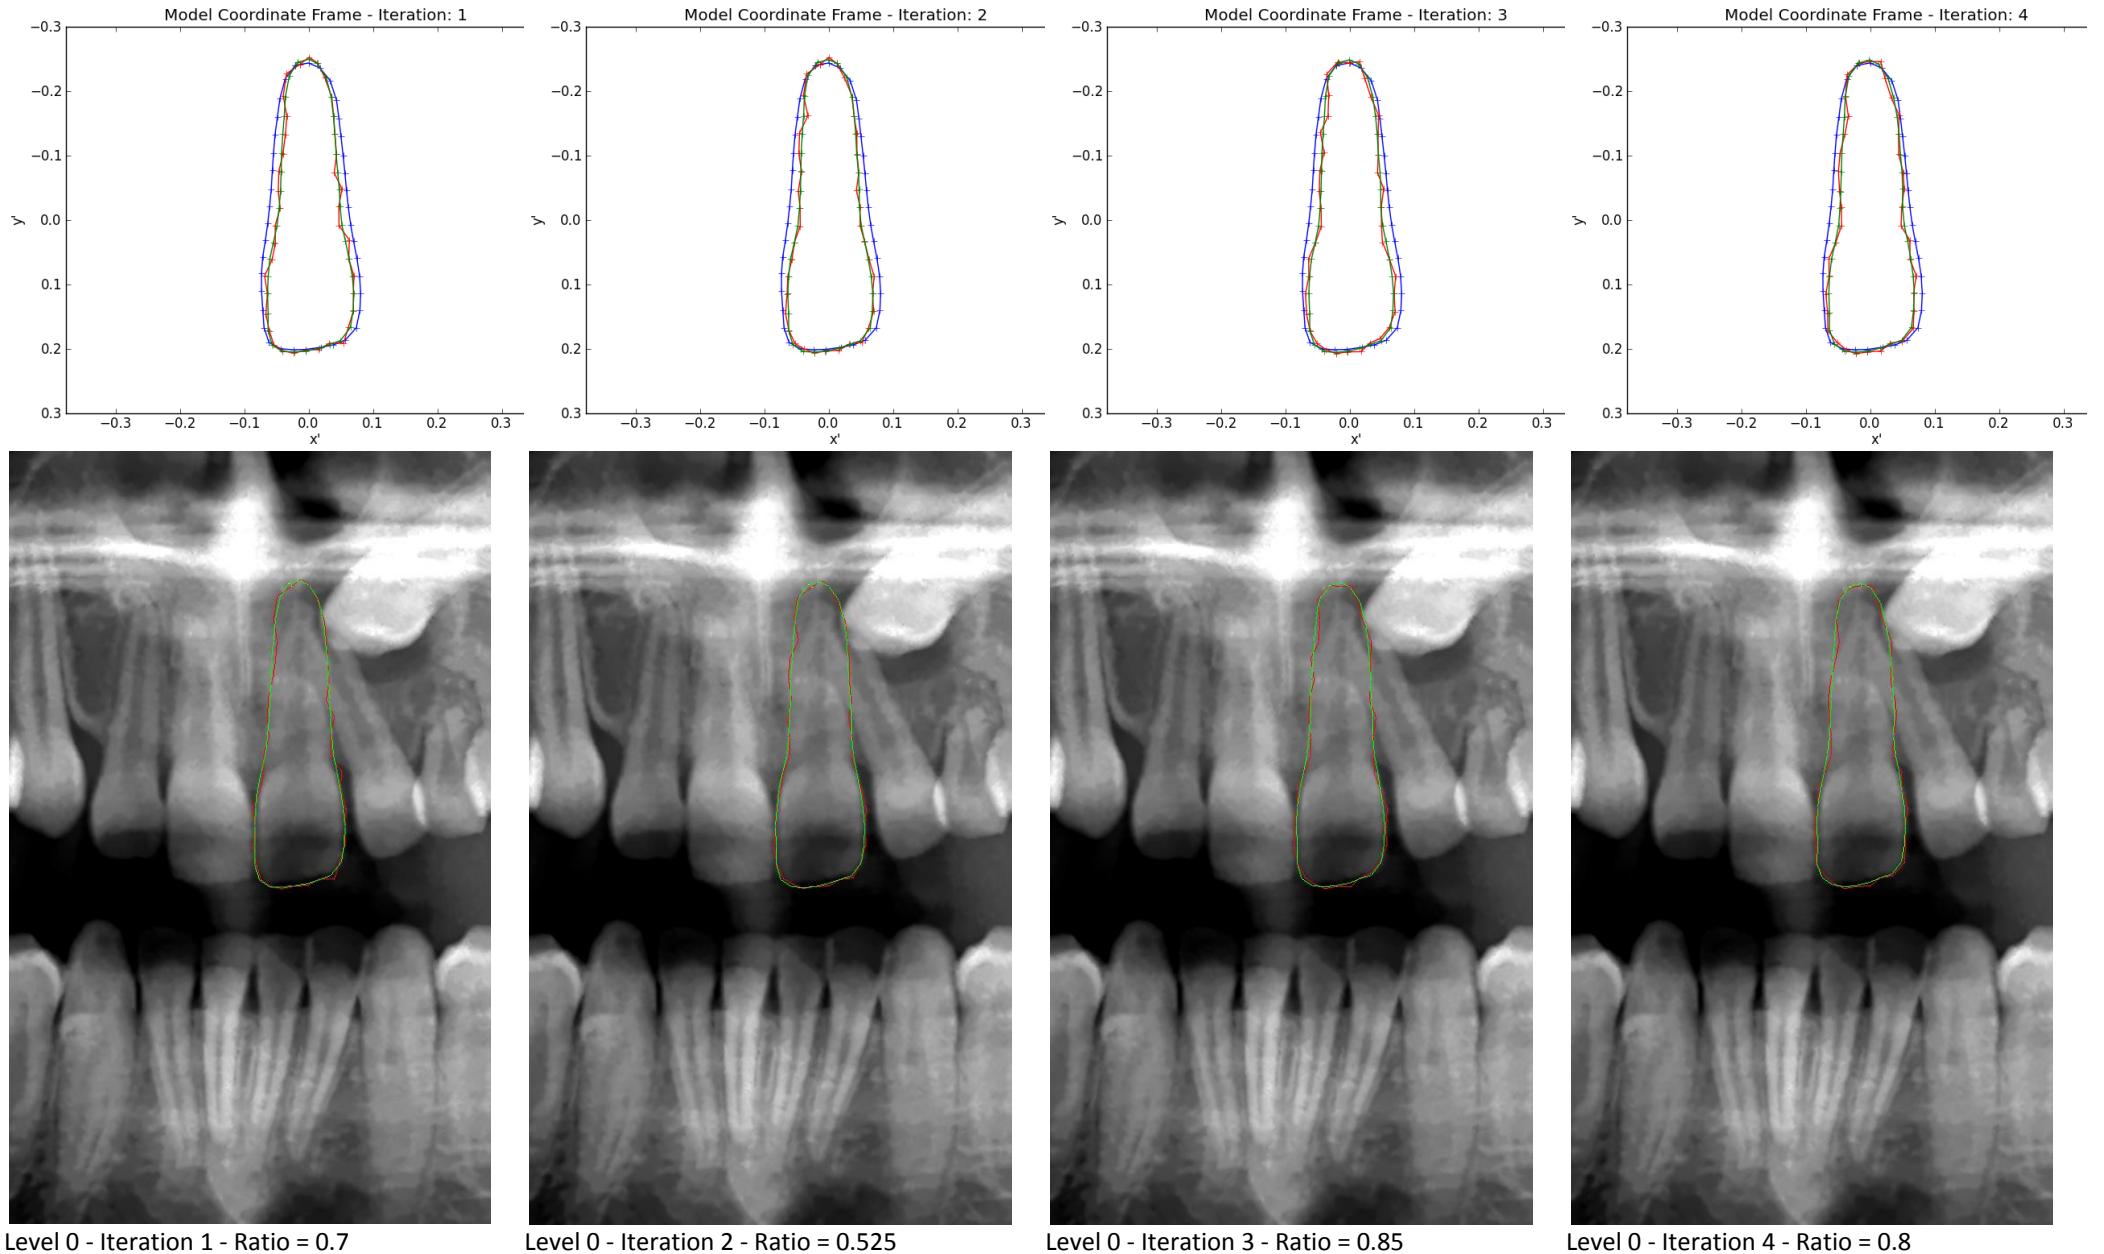


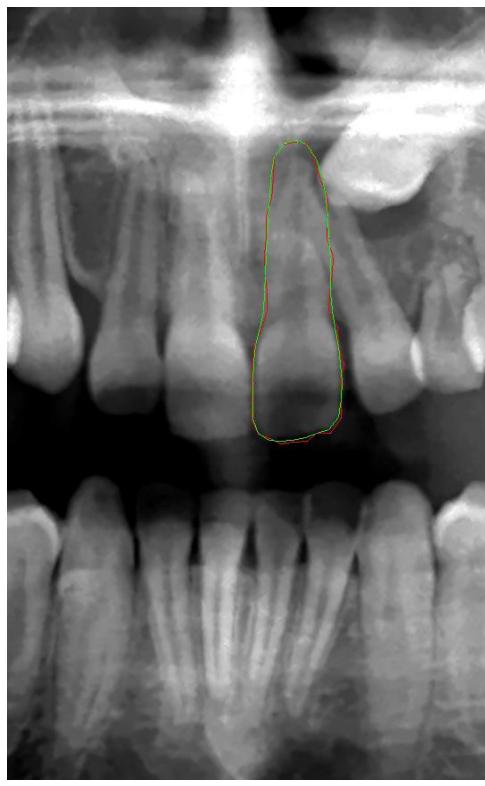
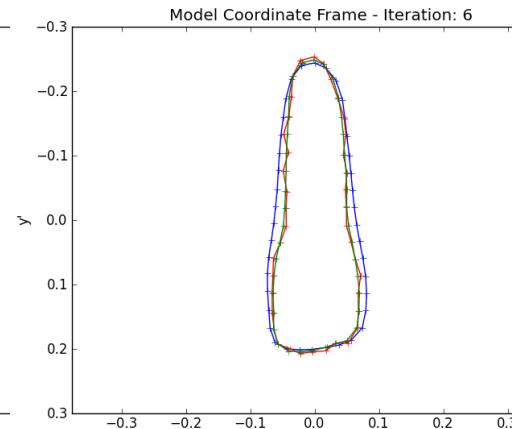
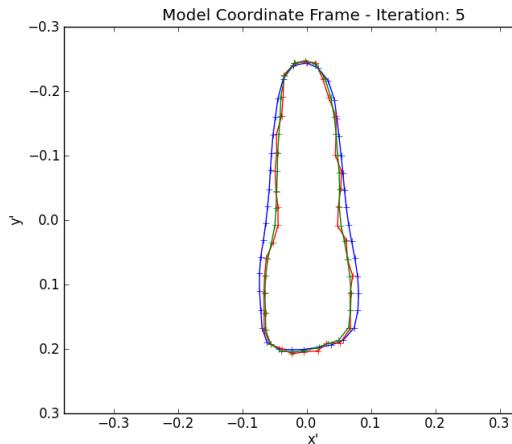
Level 2 - Iteration 6 – Ratio = 0.7



Level 2 - Iteration 7 – Ratio = 0.9







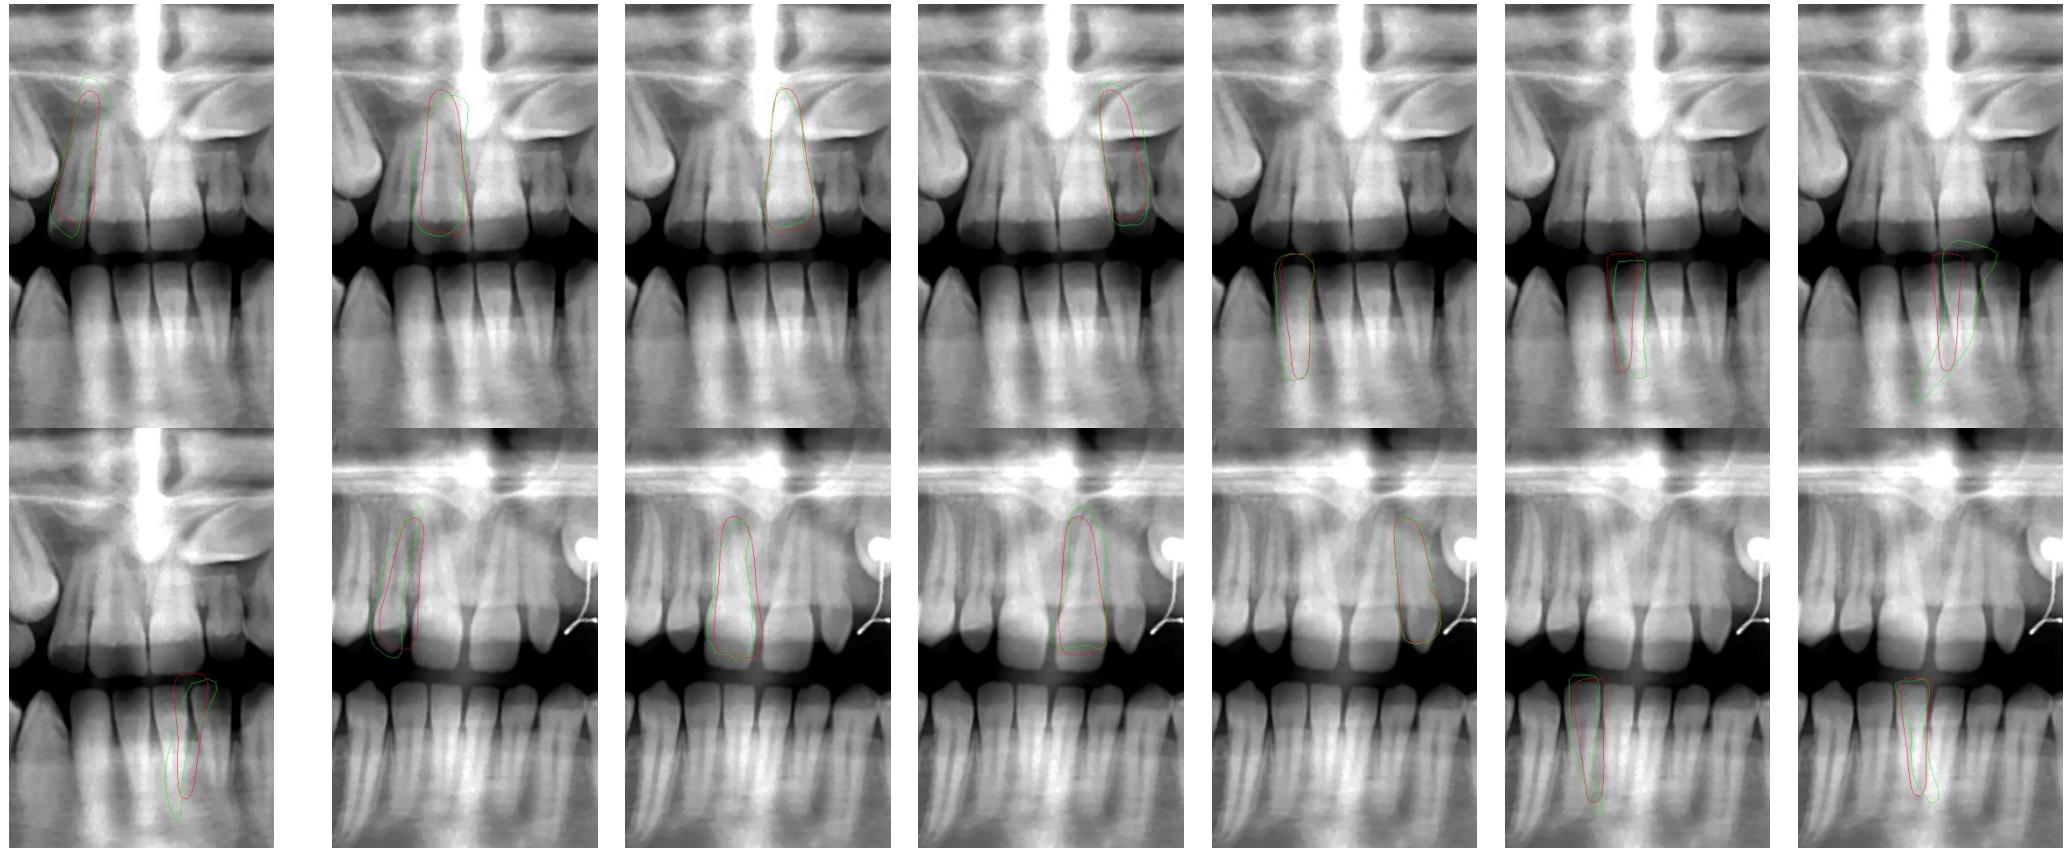
Figuur E.4: Alle iteraties op level 2, 1 en 0 van de multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen voor de 3^e tand van de 7^e radiografie weergegeven in de model-coördinatenruimte (x' , y'). De contouren van de modeltand zijn weergegeven in het blauw, de contouren van de nieuwe gevonden landmarkpunten zijn weergegeven in het rood en de contouren van de punten na validatie (vormfactoren) in het groen.

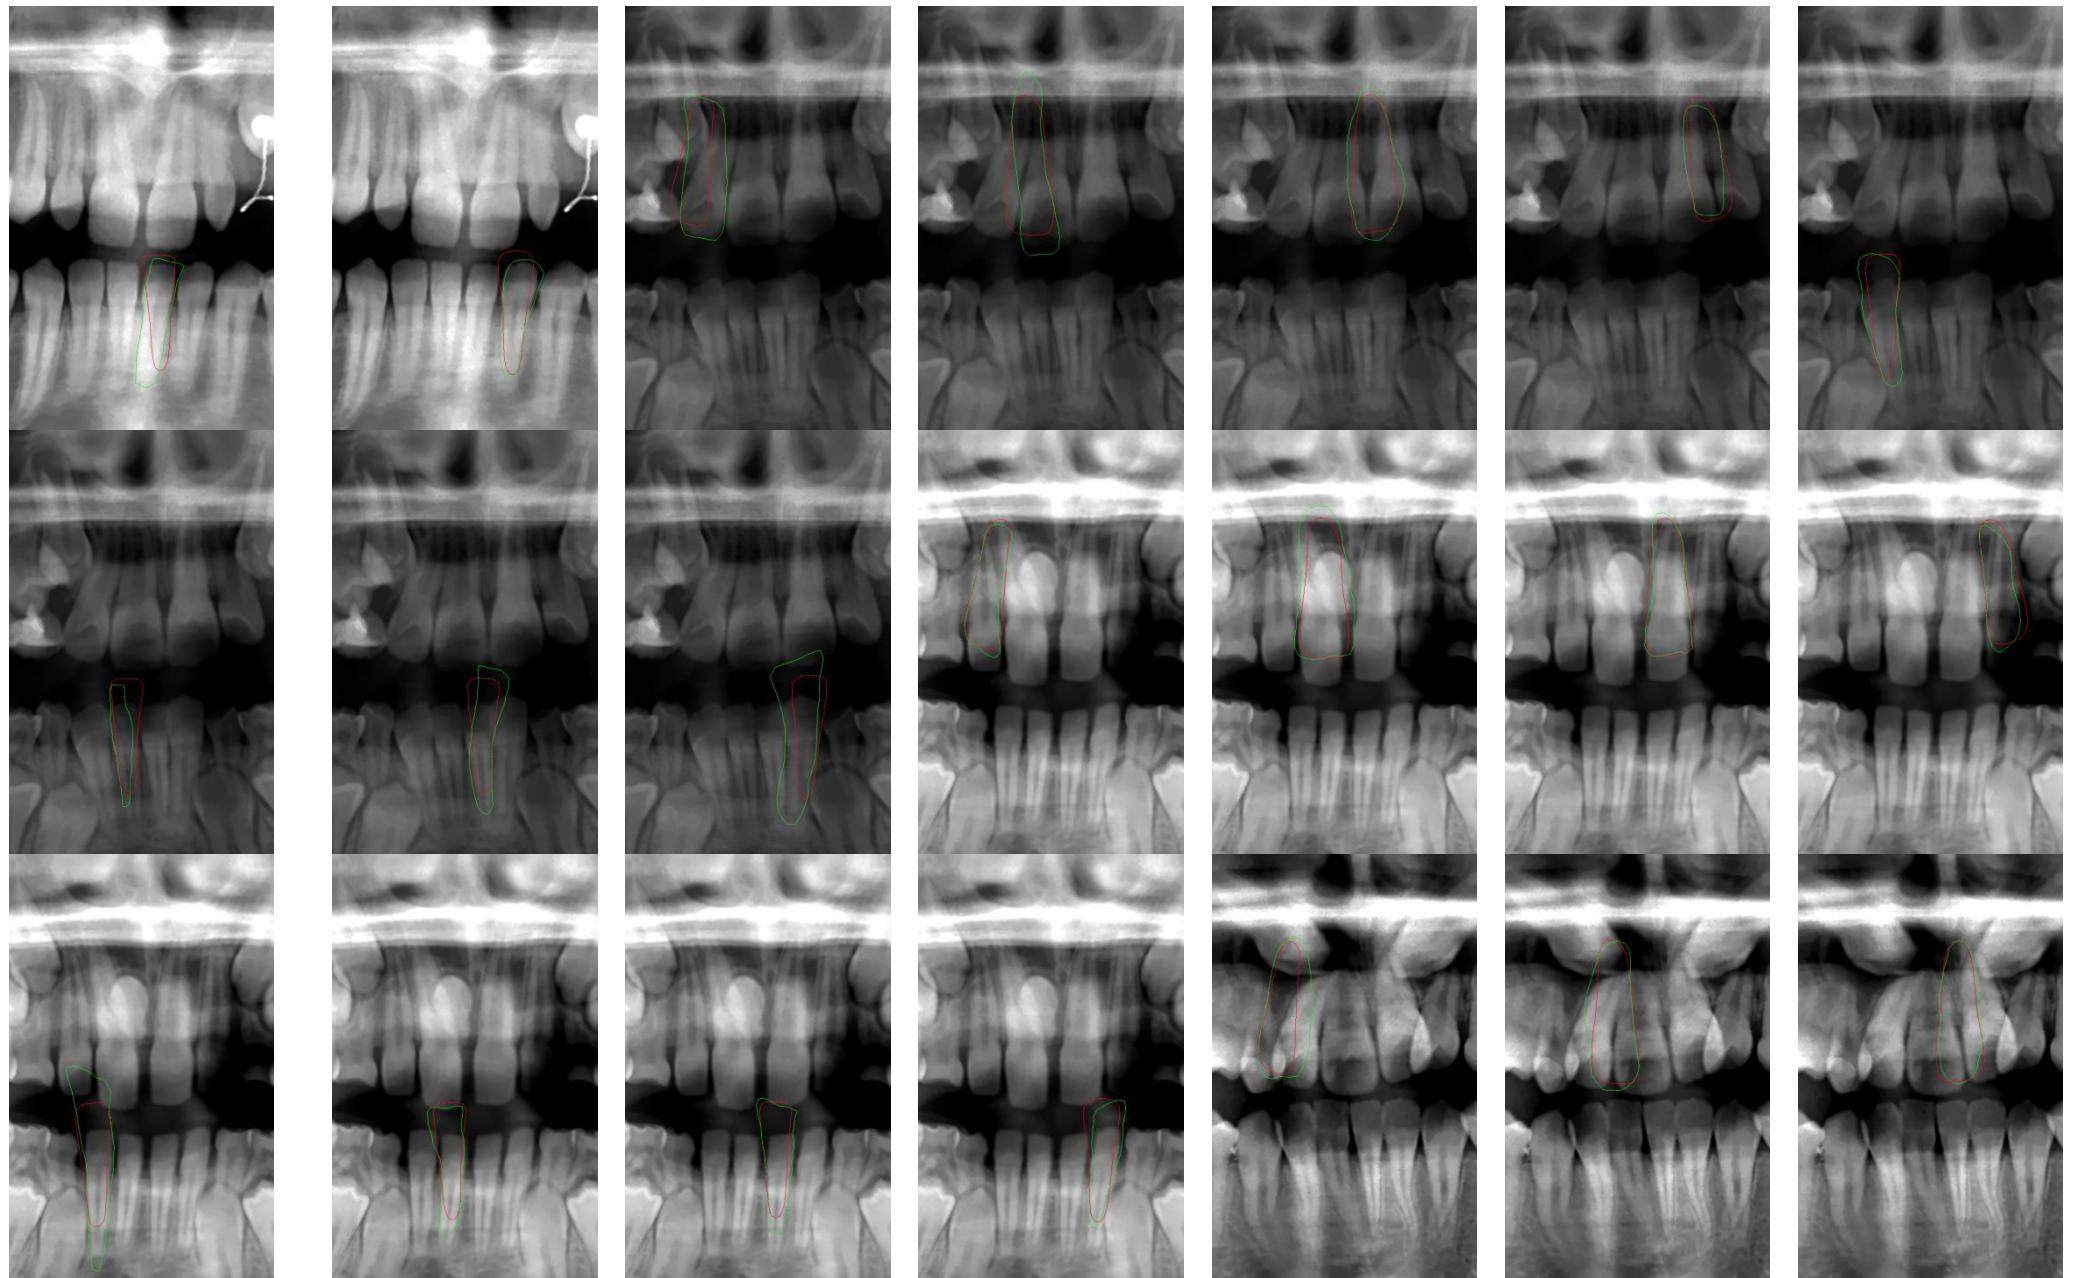
Alle iteraties op level 2, 1 en 0 van de multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen voor de 3^e tand van de 7^e radiografie weergegeven in de afbeelding-coördinatenruimte (x , y). De contouren van de nieuwe gevonden landmarkpunten zijn weergegeven in het rood en de contouren van de punten na validatie in het groen. Merk op dat de afbeeldingen voor level 0 niet op de juiste schaal zijn weergegeven.

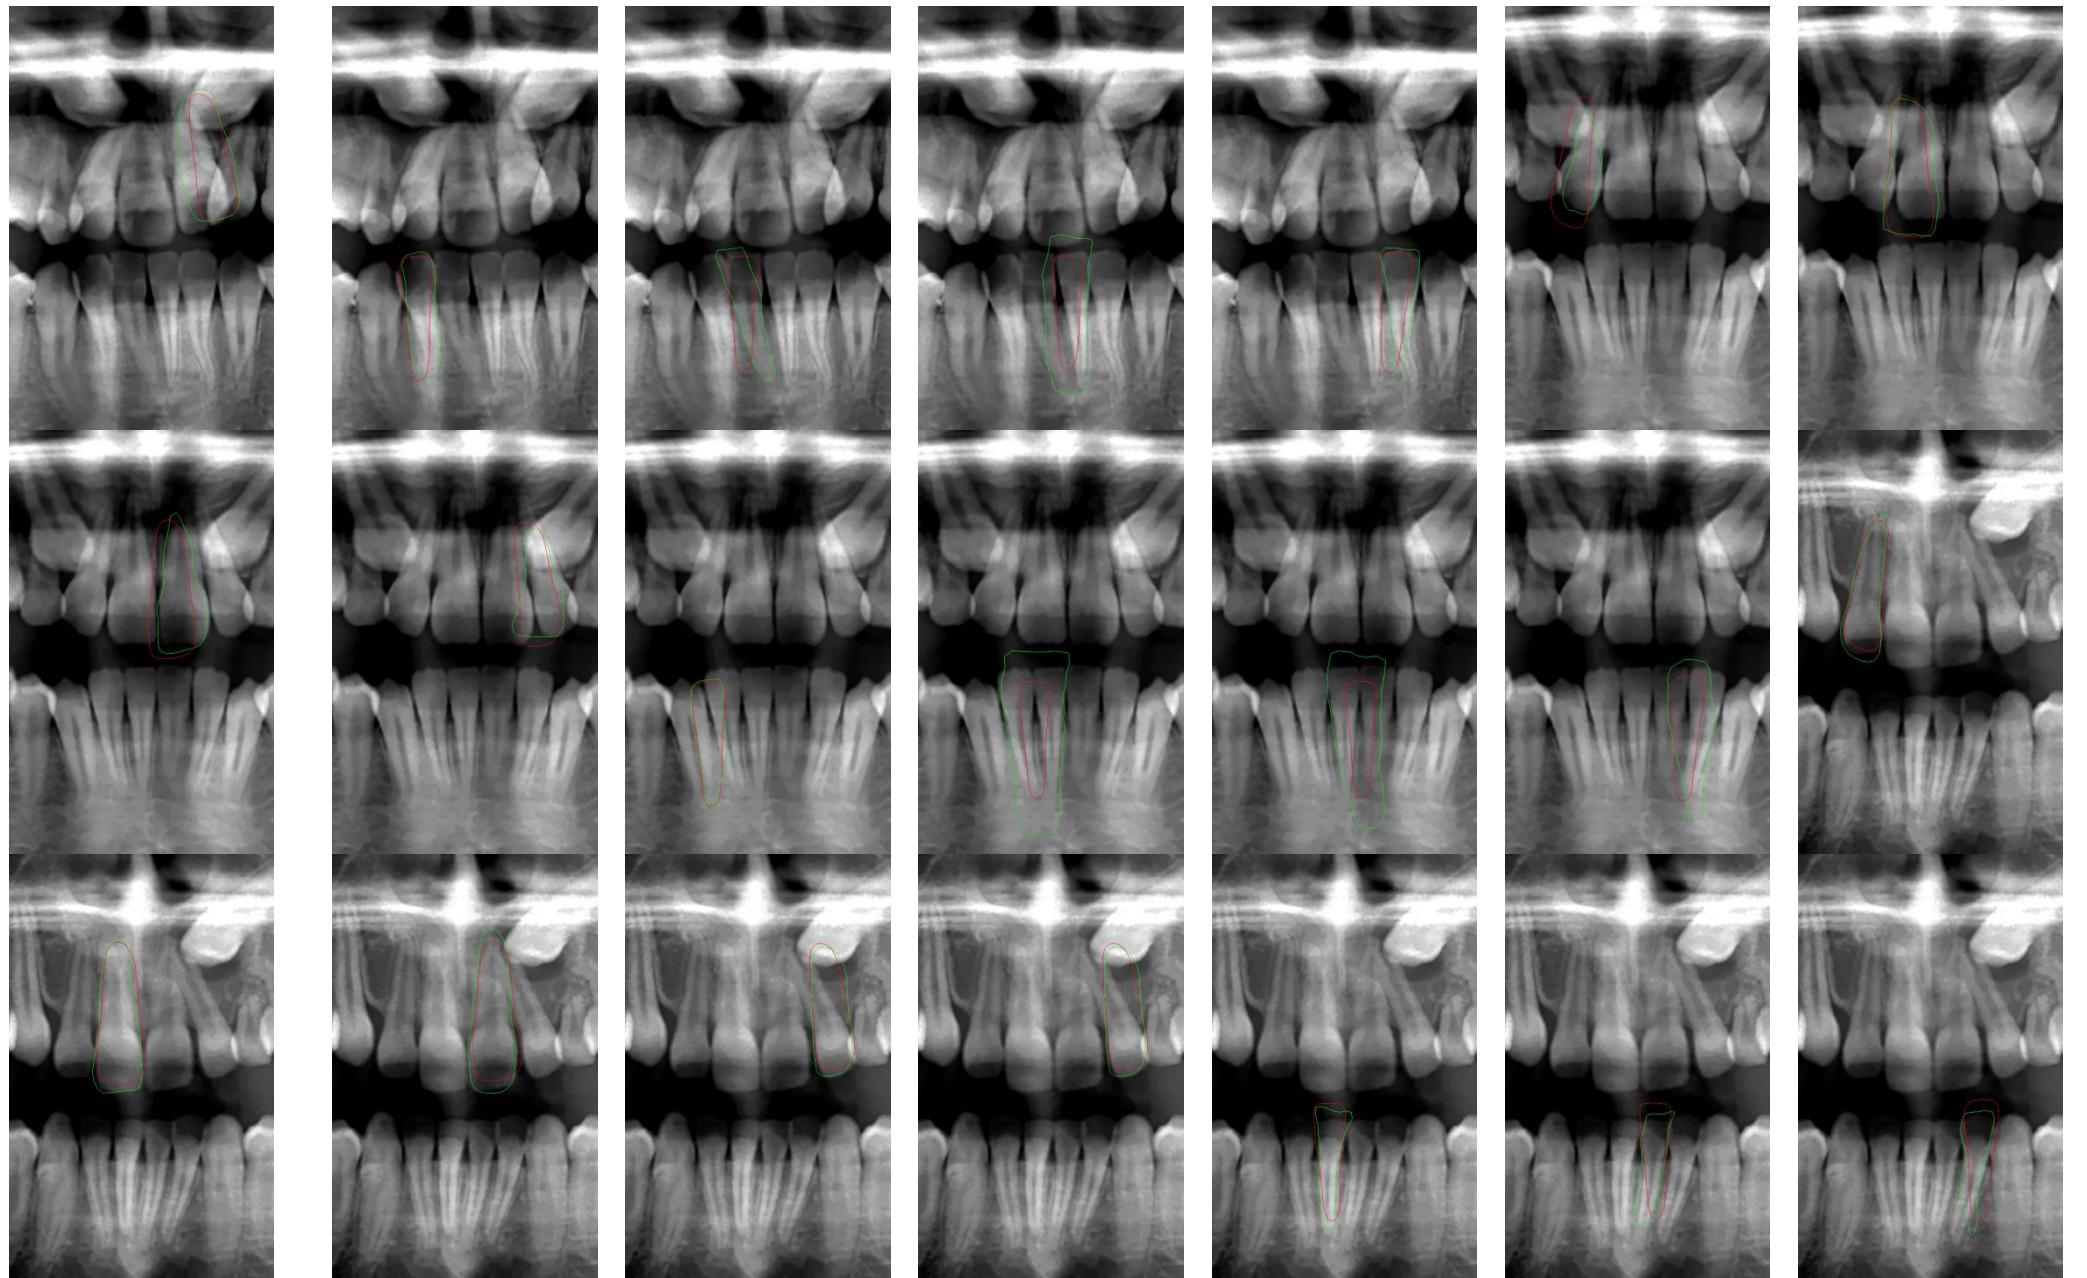
Convergentie wordt bereikt wanneer de ratio (zie sectie 4.2) groter of gelijk is aan 0,9.

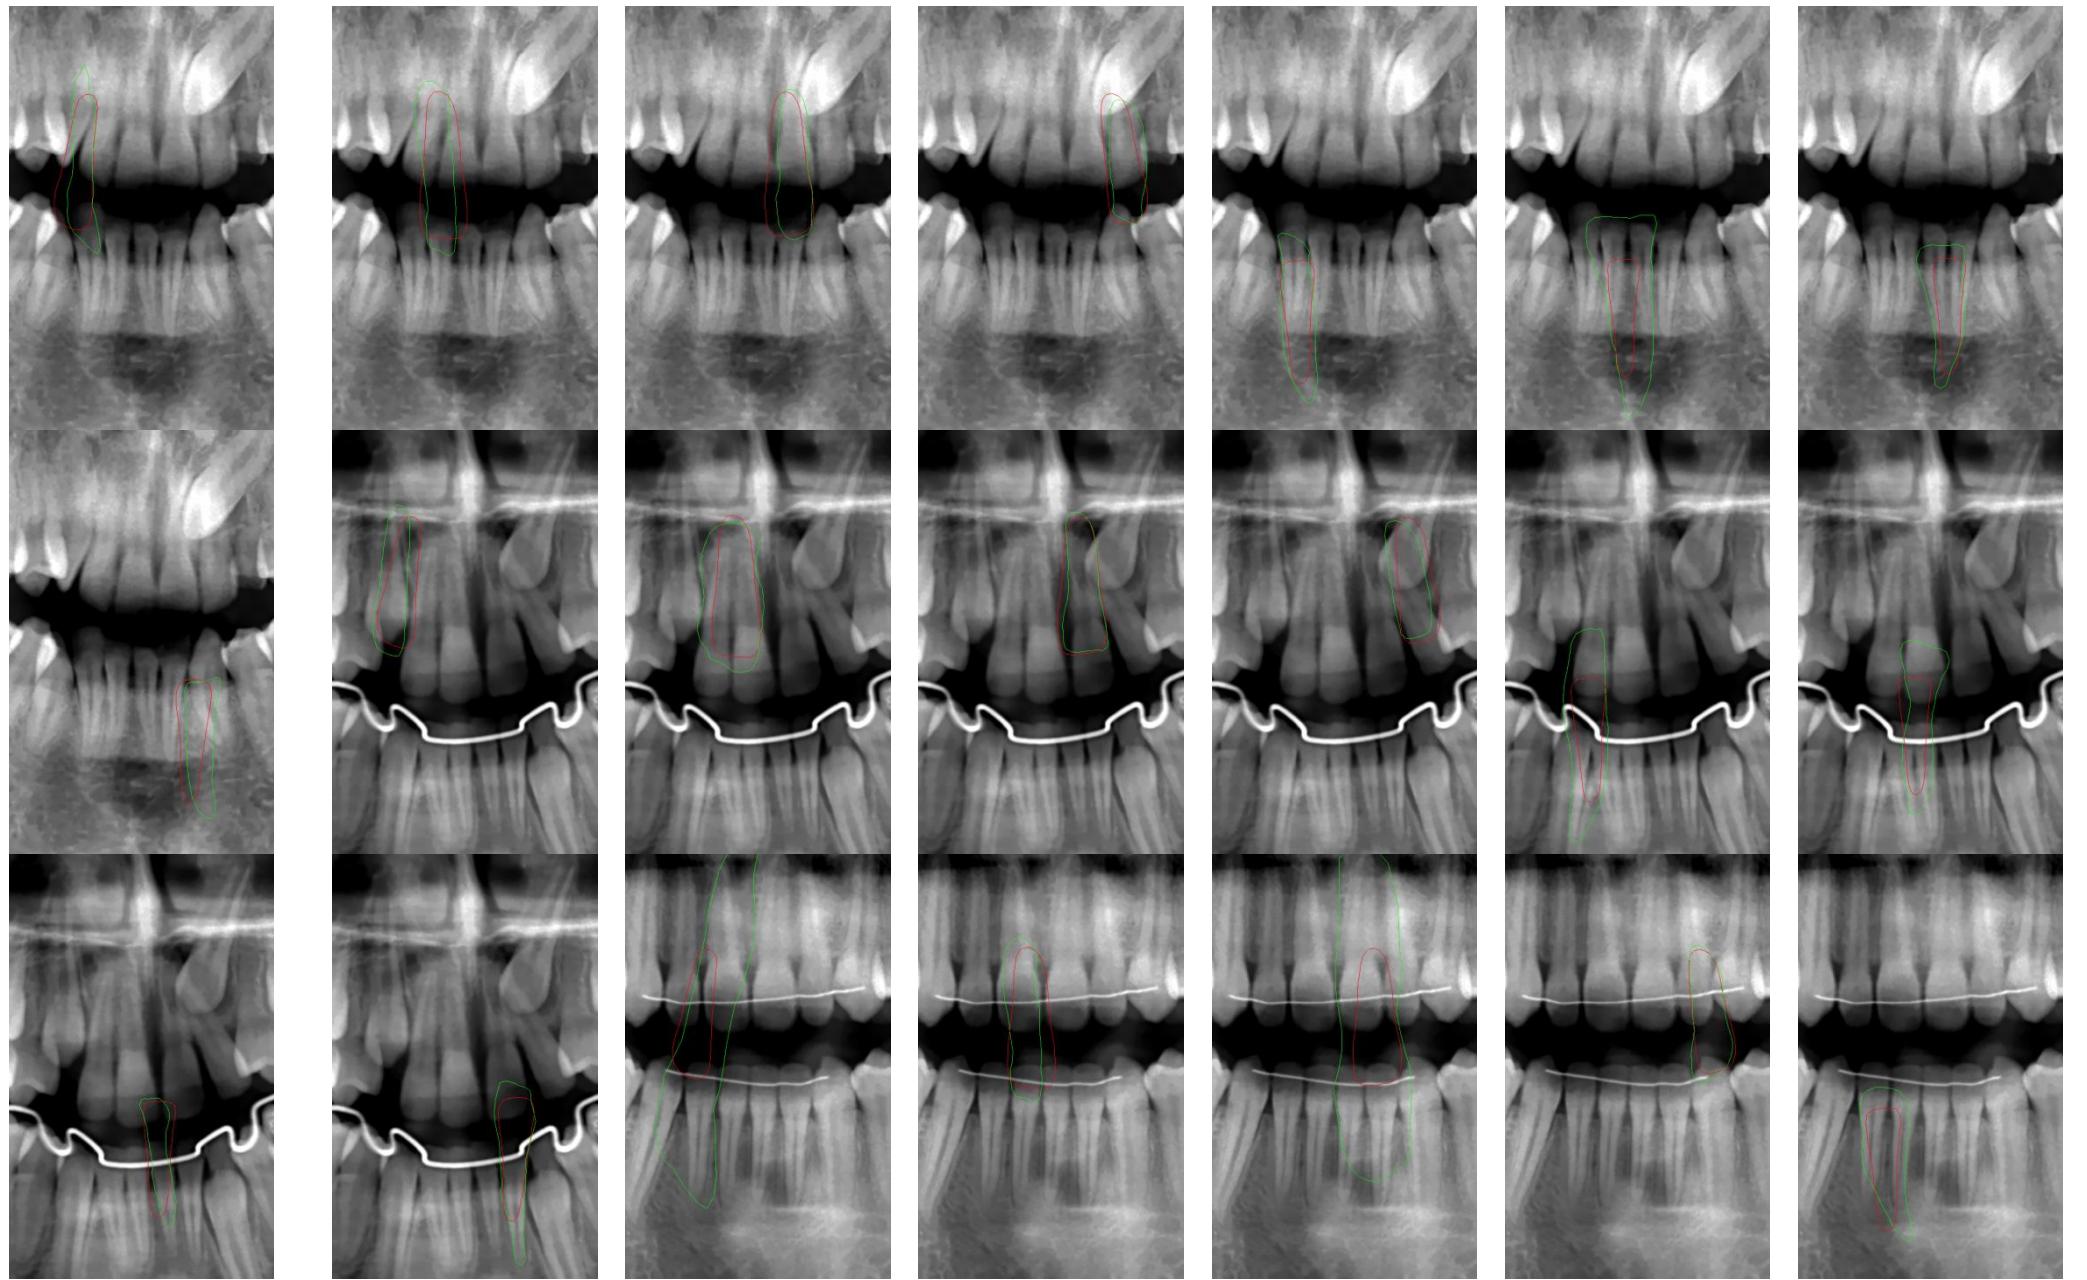
$$\#levels = 3, k = 4, m = 8$$

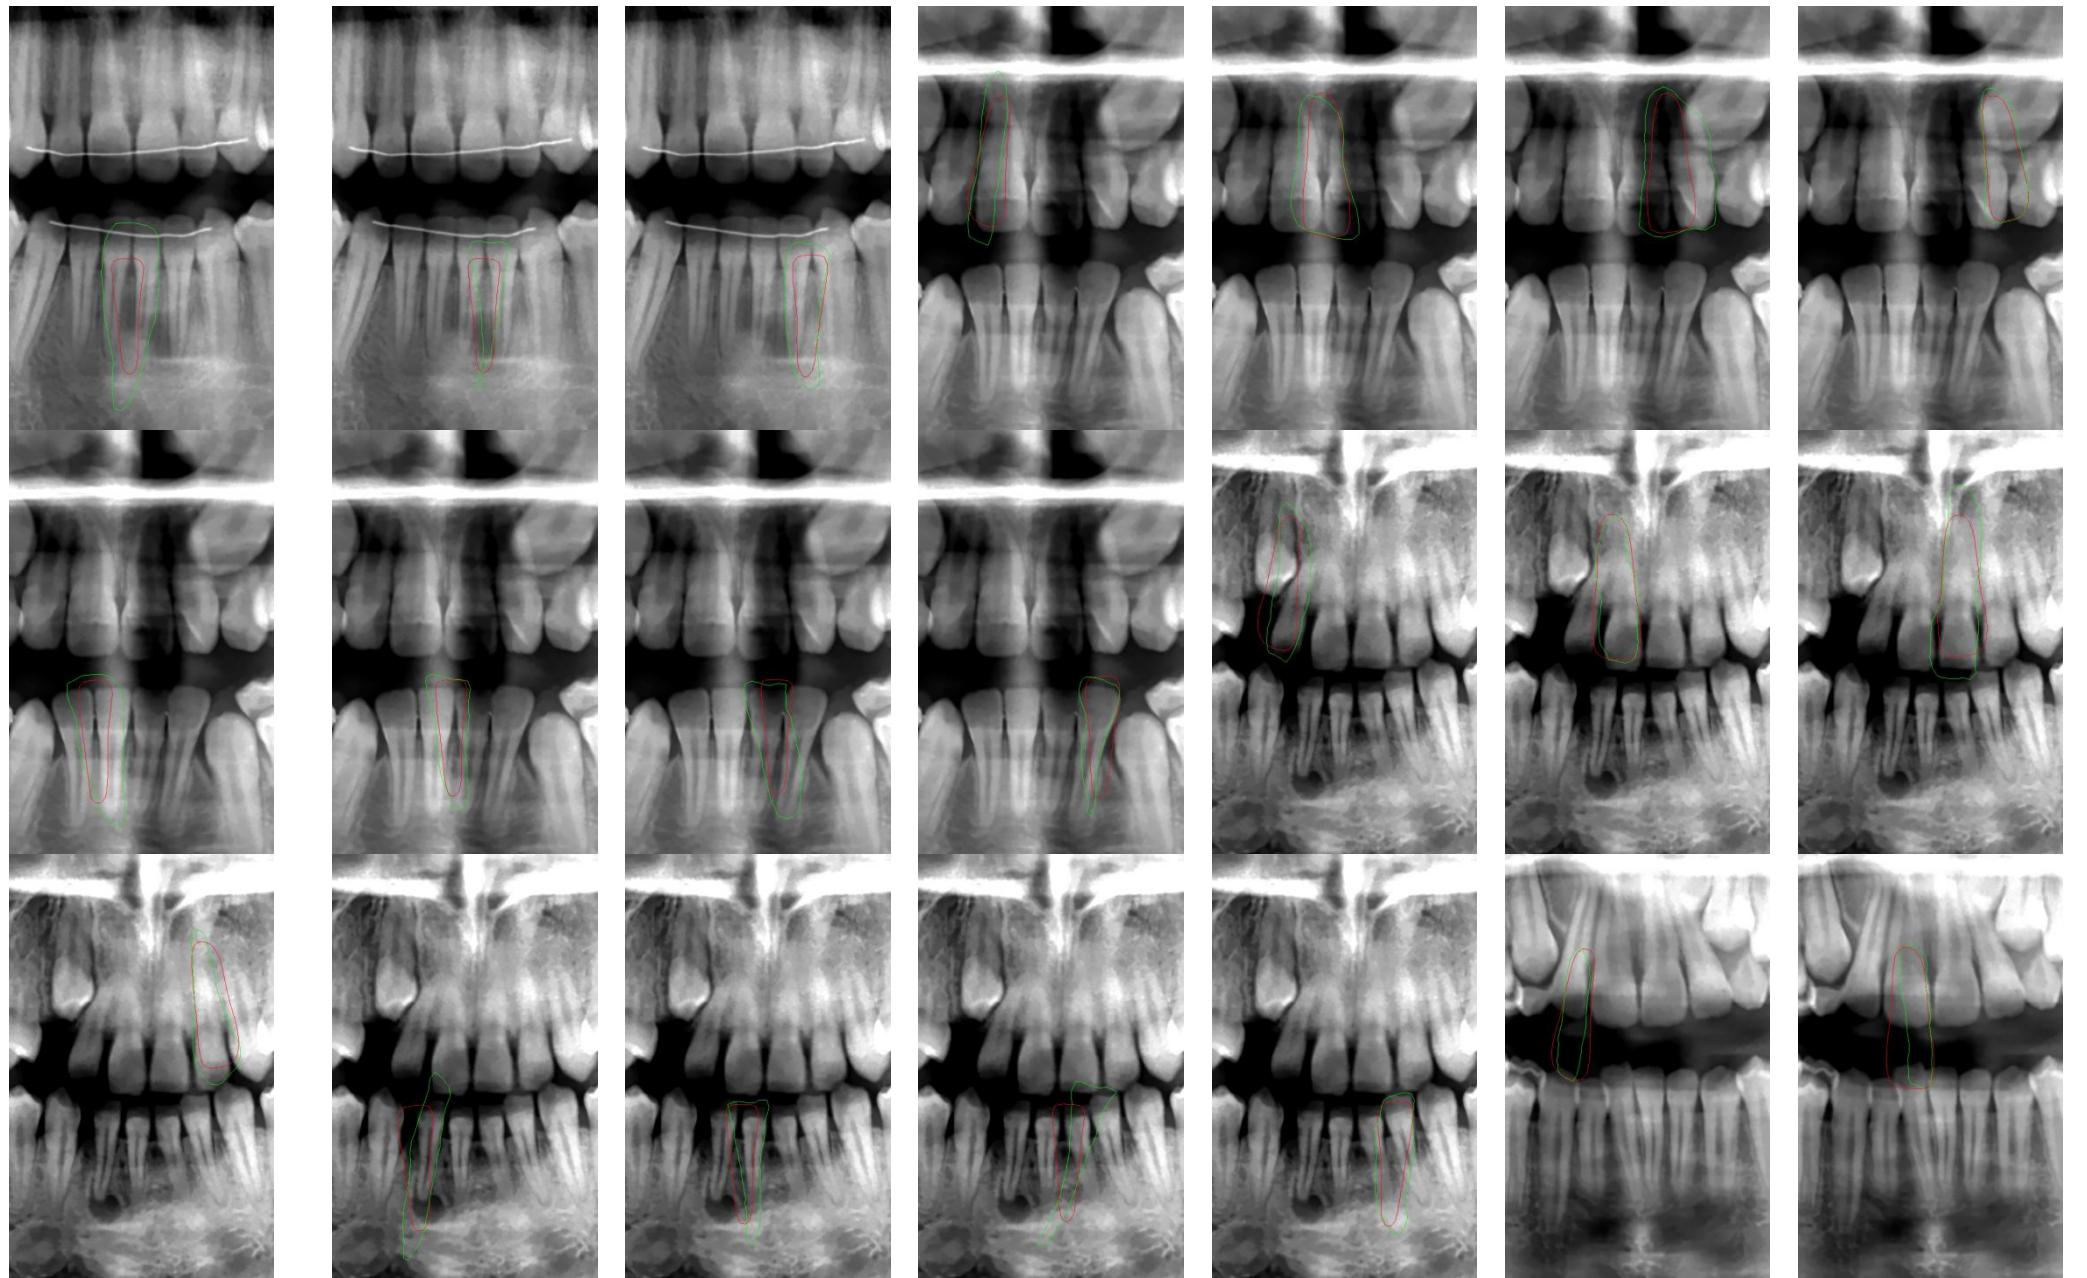
Appendix F: Visualisaties van de resultaten van de fitting procedure (met automatische initialisatie)

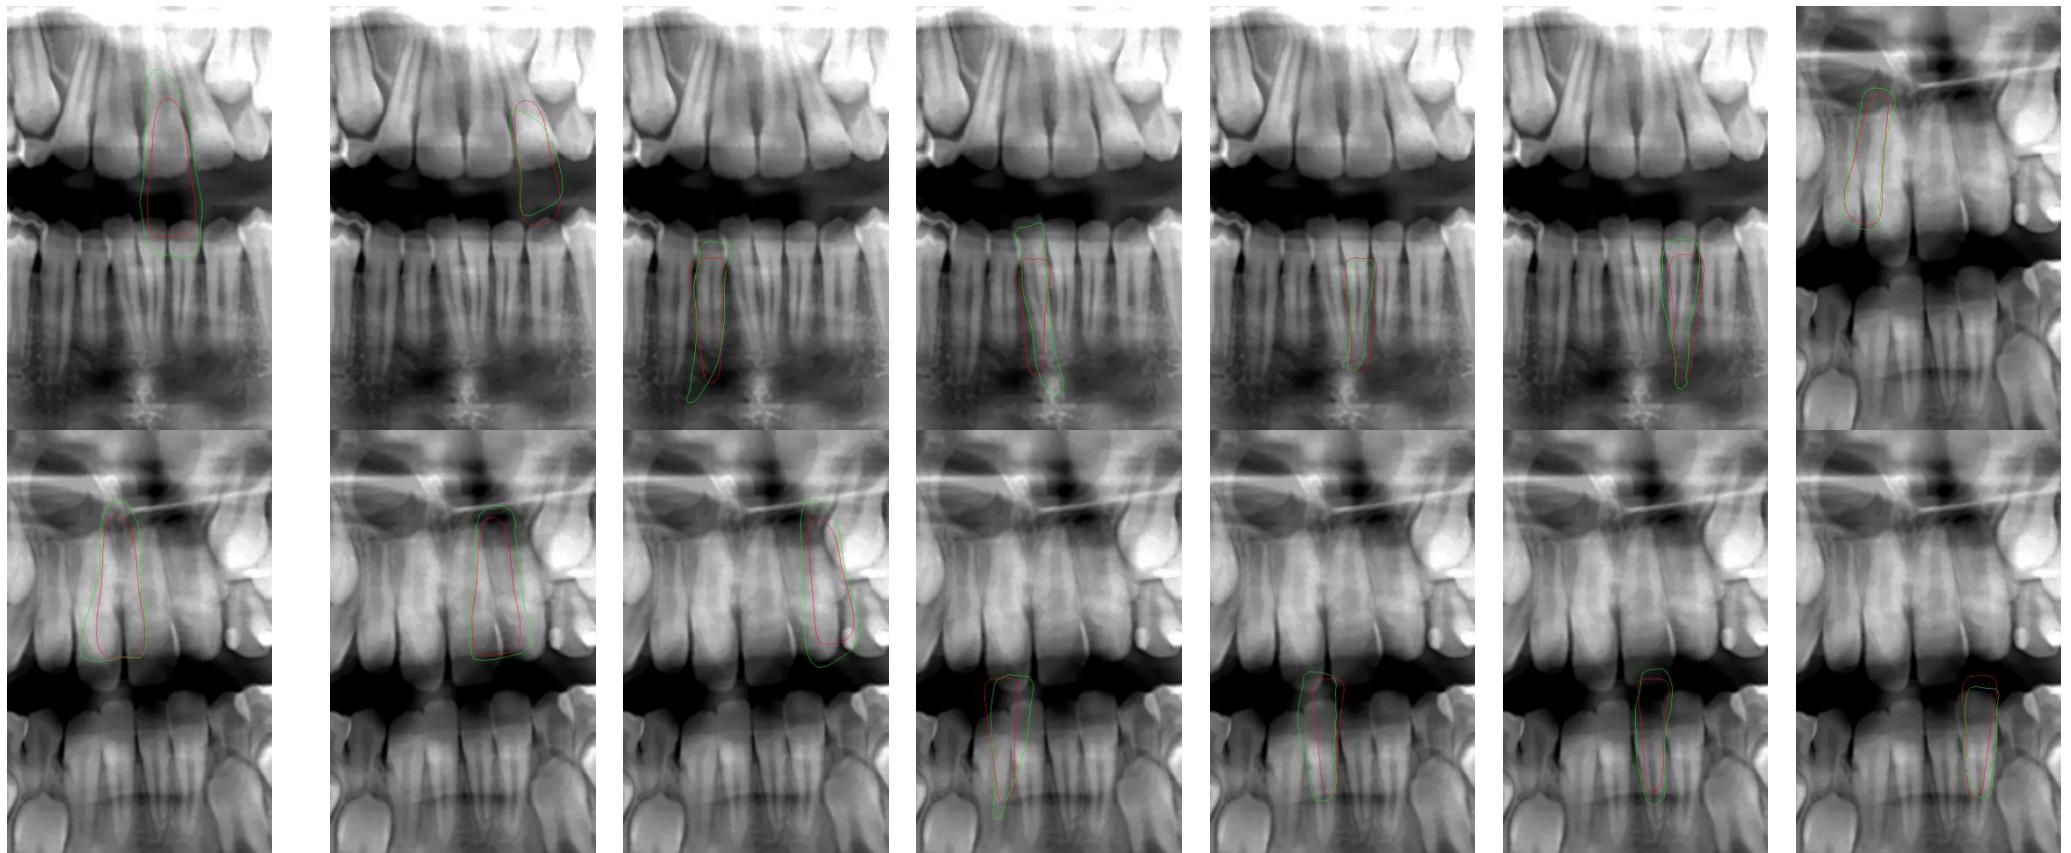






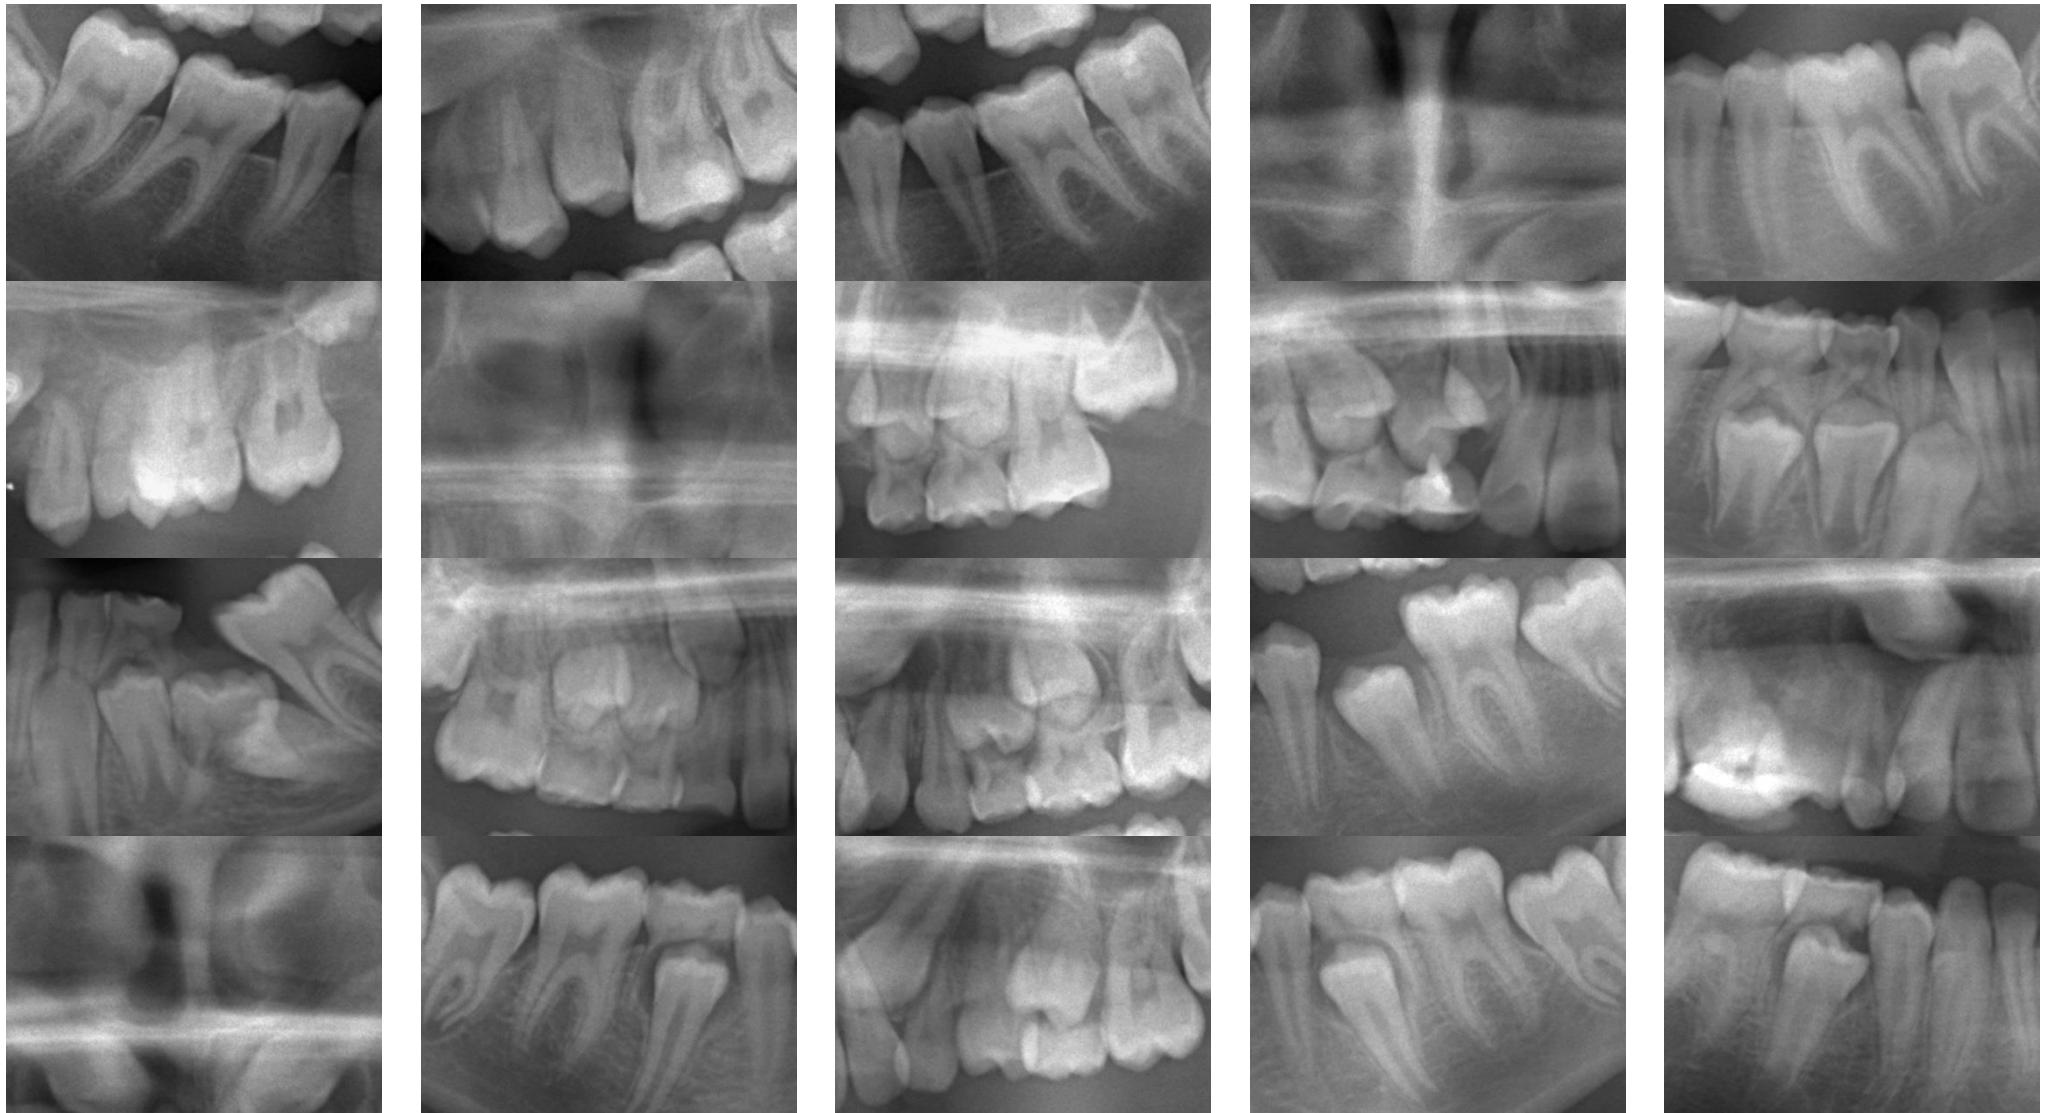






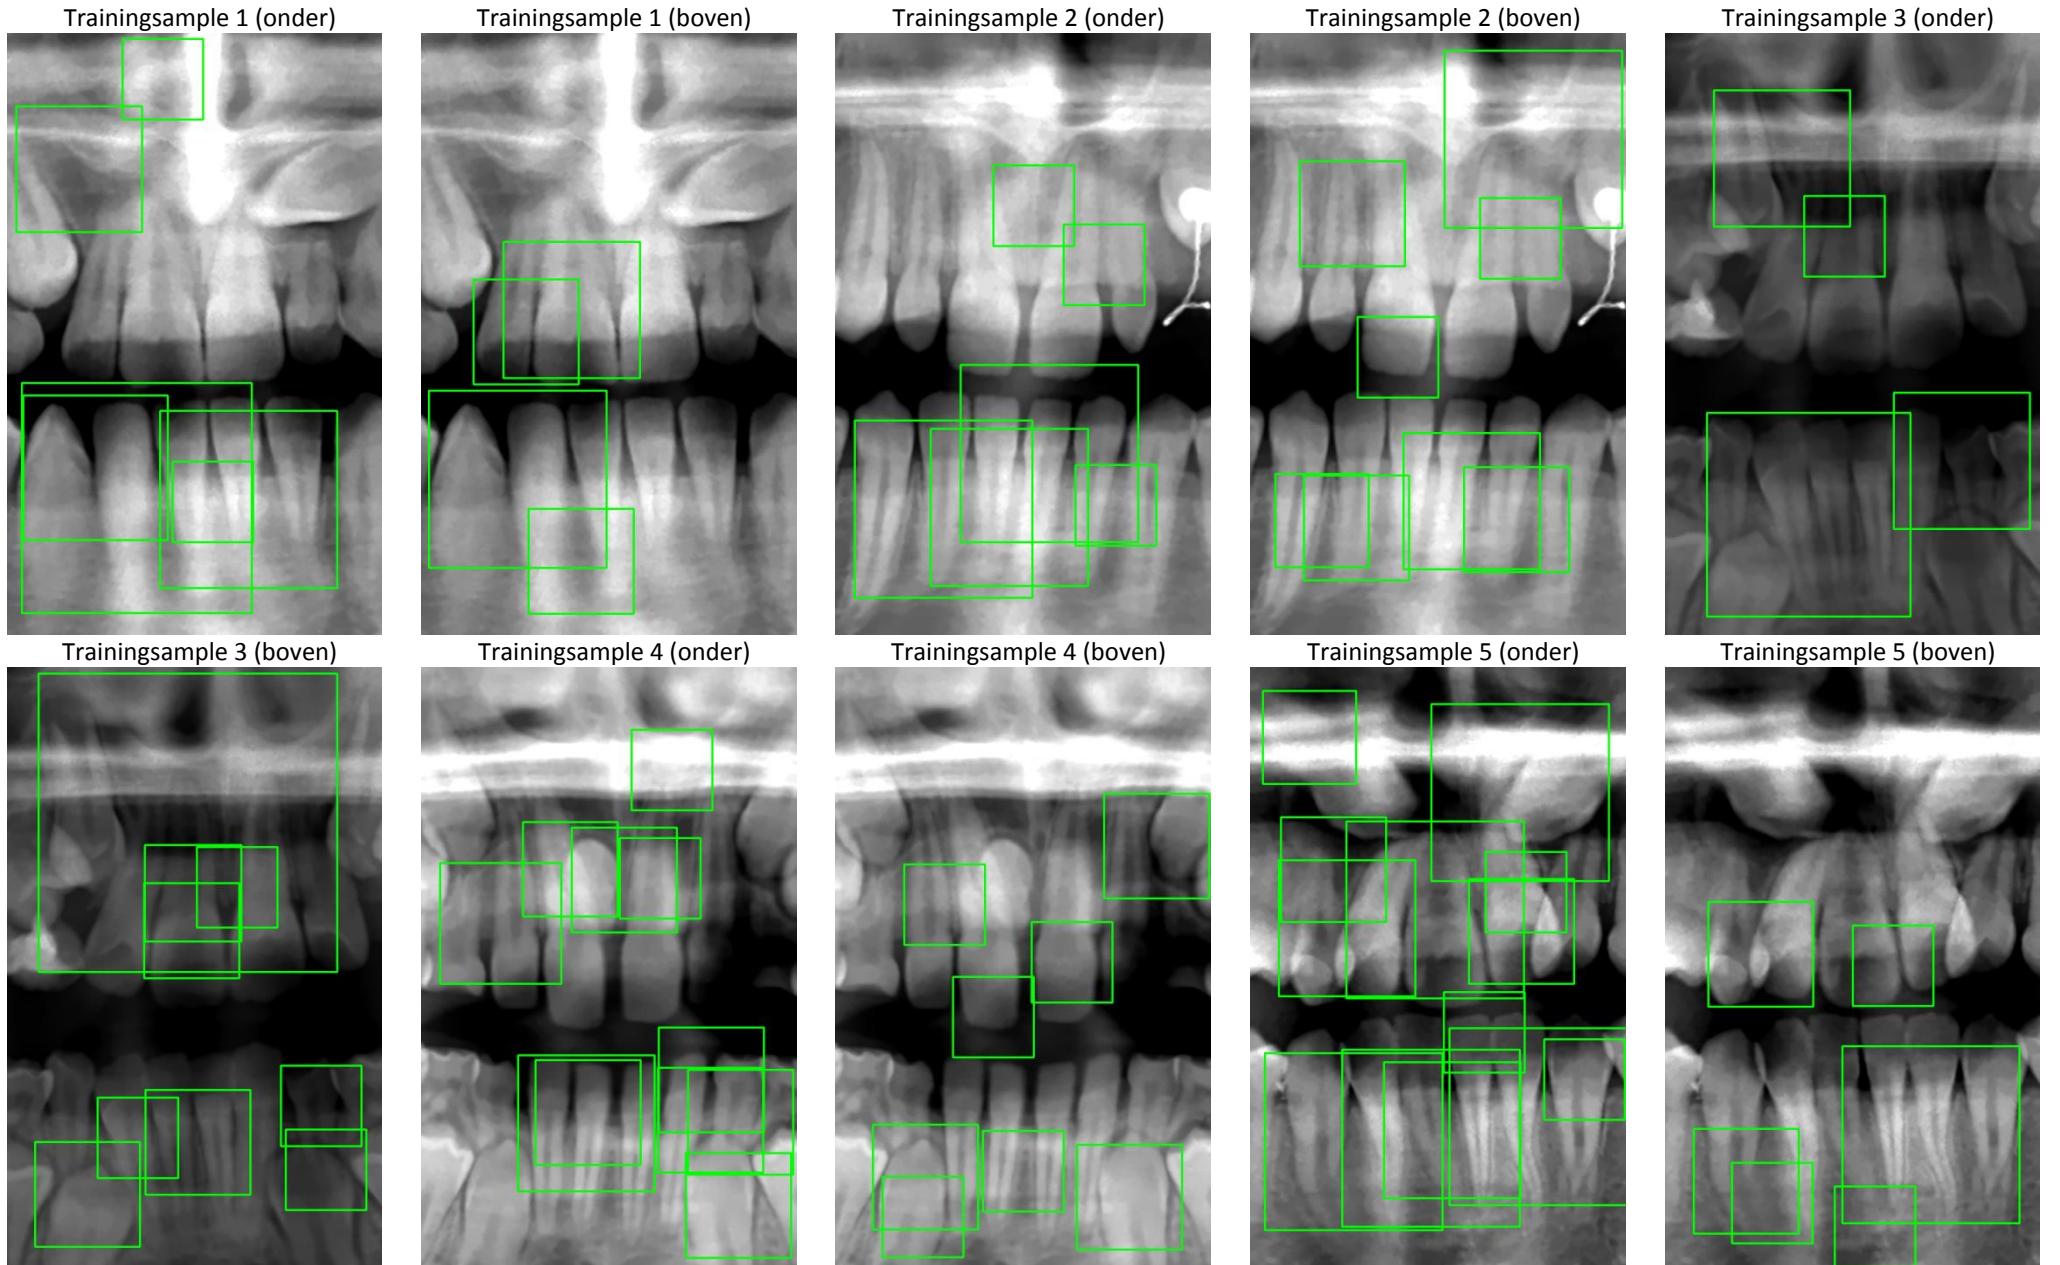
Figuur F.1: De modellandmarks en contouren van de gemiddelde gealigneerde modelltand als initiële startoplossing weergegeven in het rood samen met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen, weergegeven in het groen.

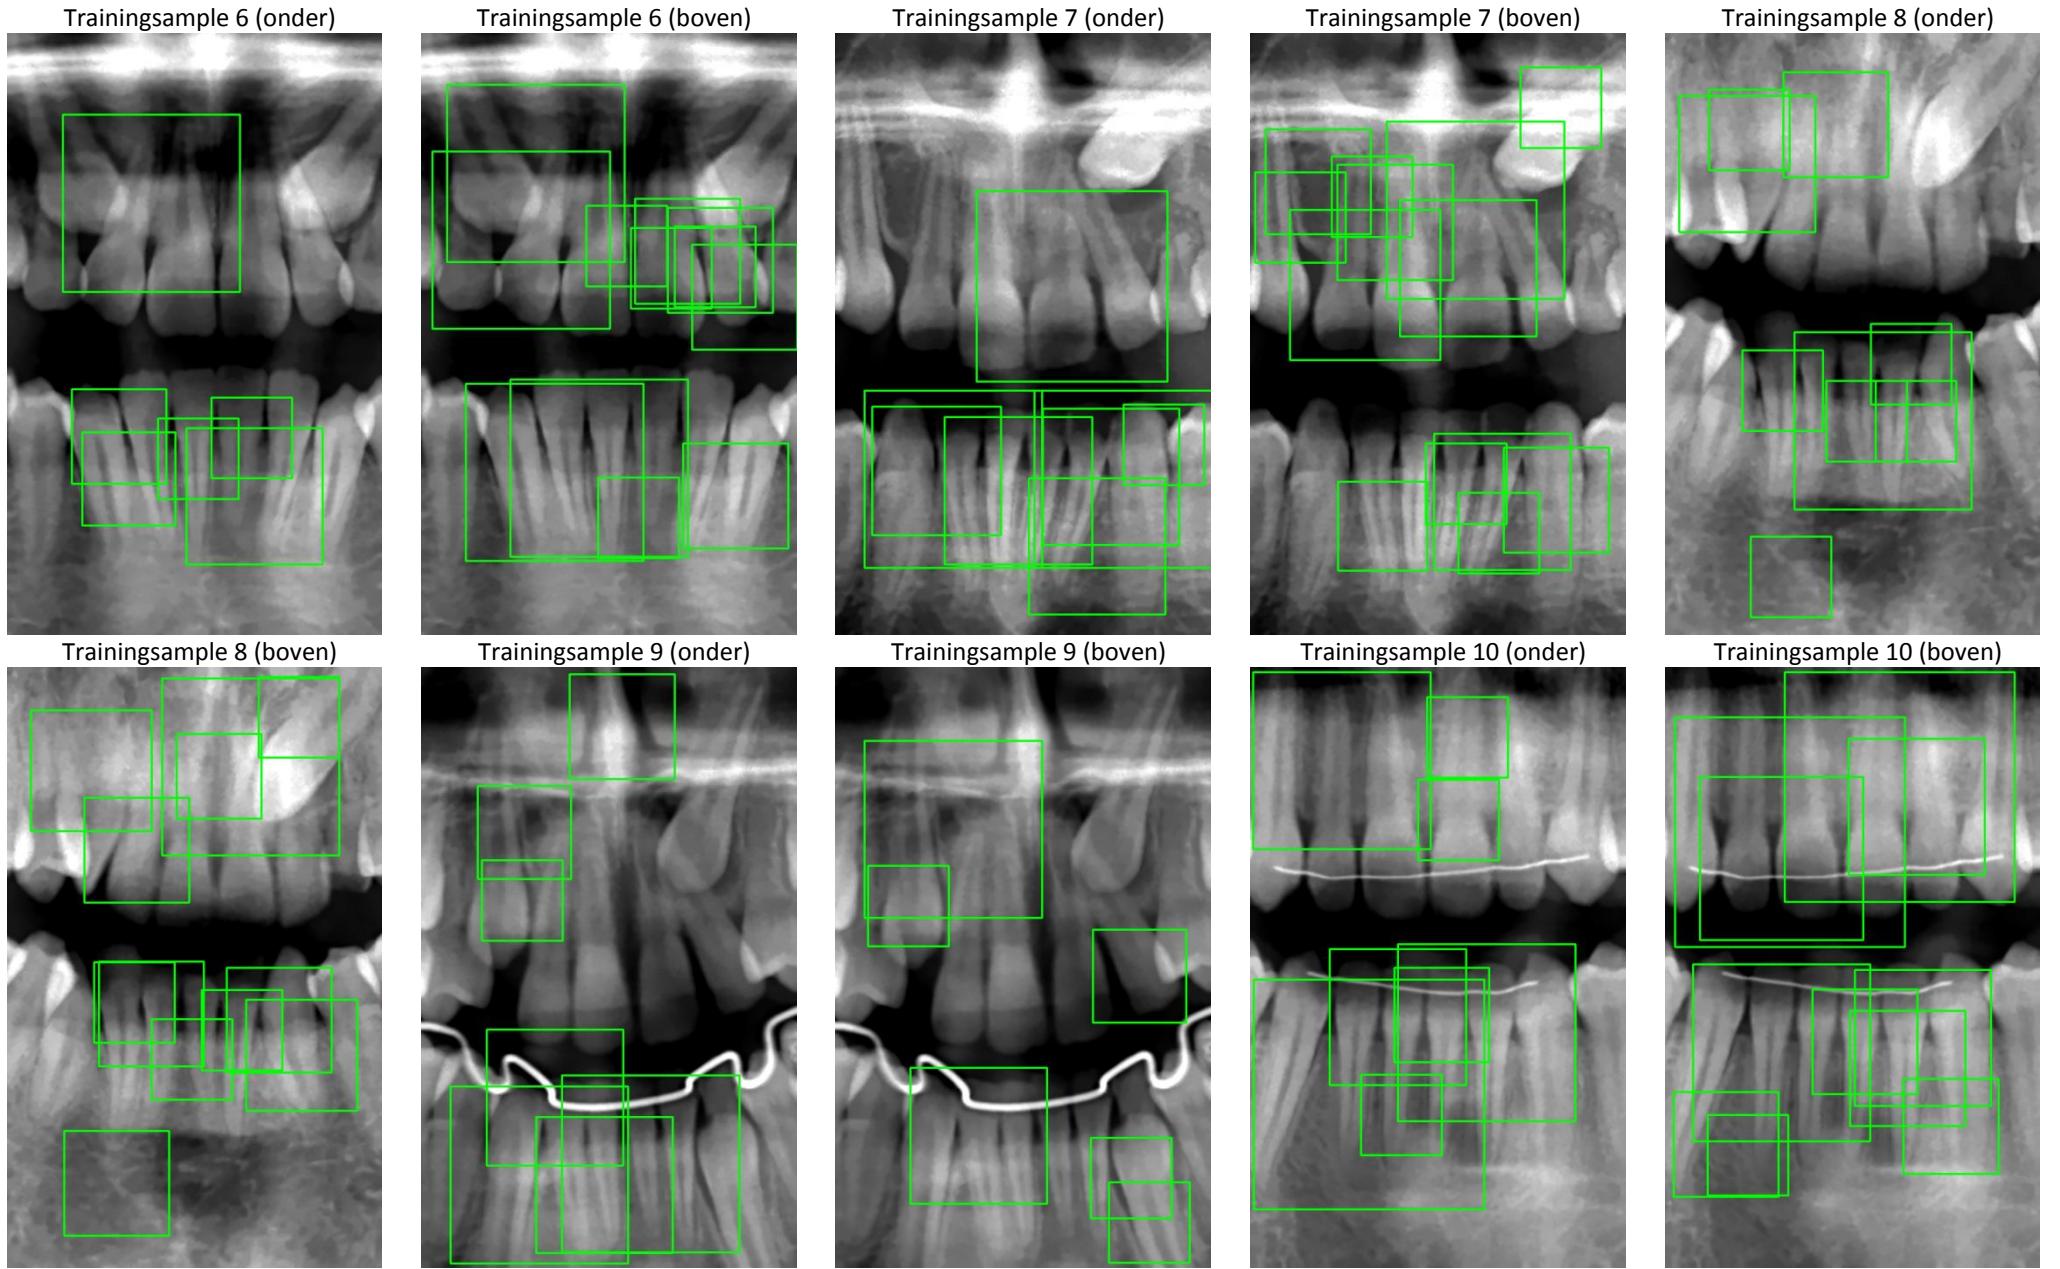
$\#levels = 3, k = 4, m = 8$

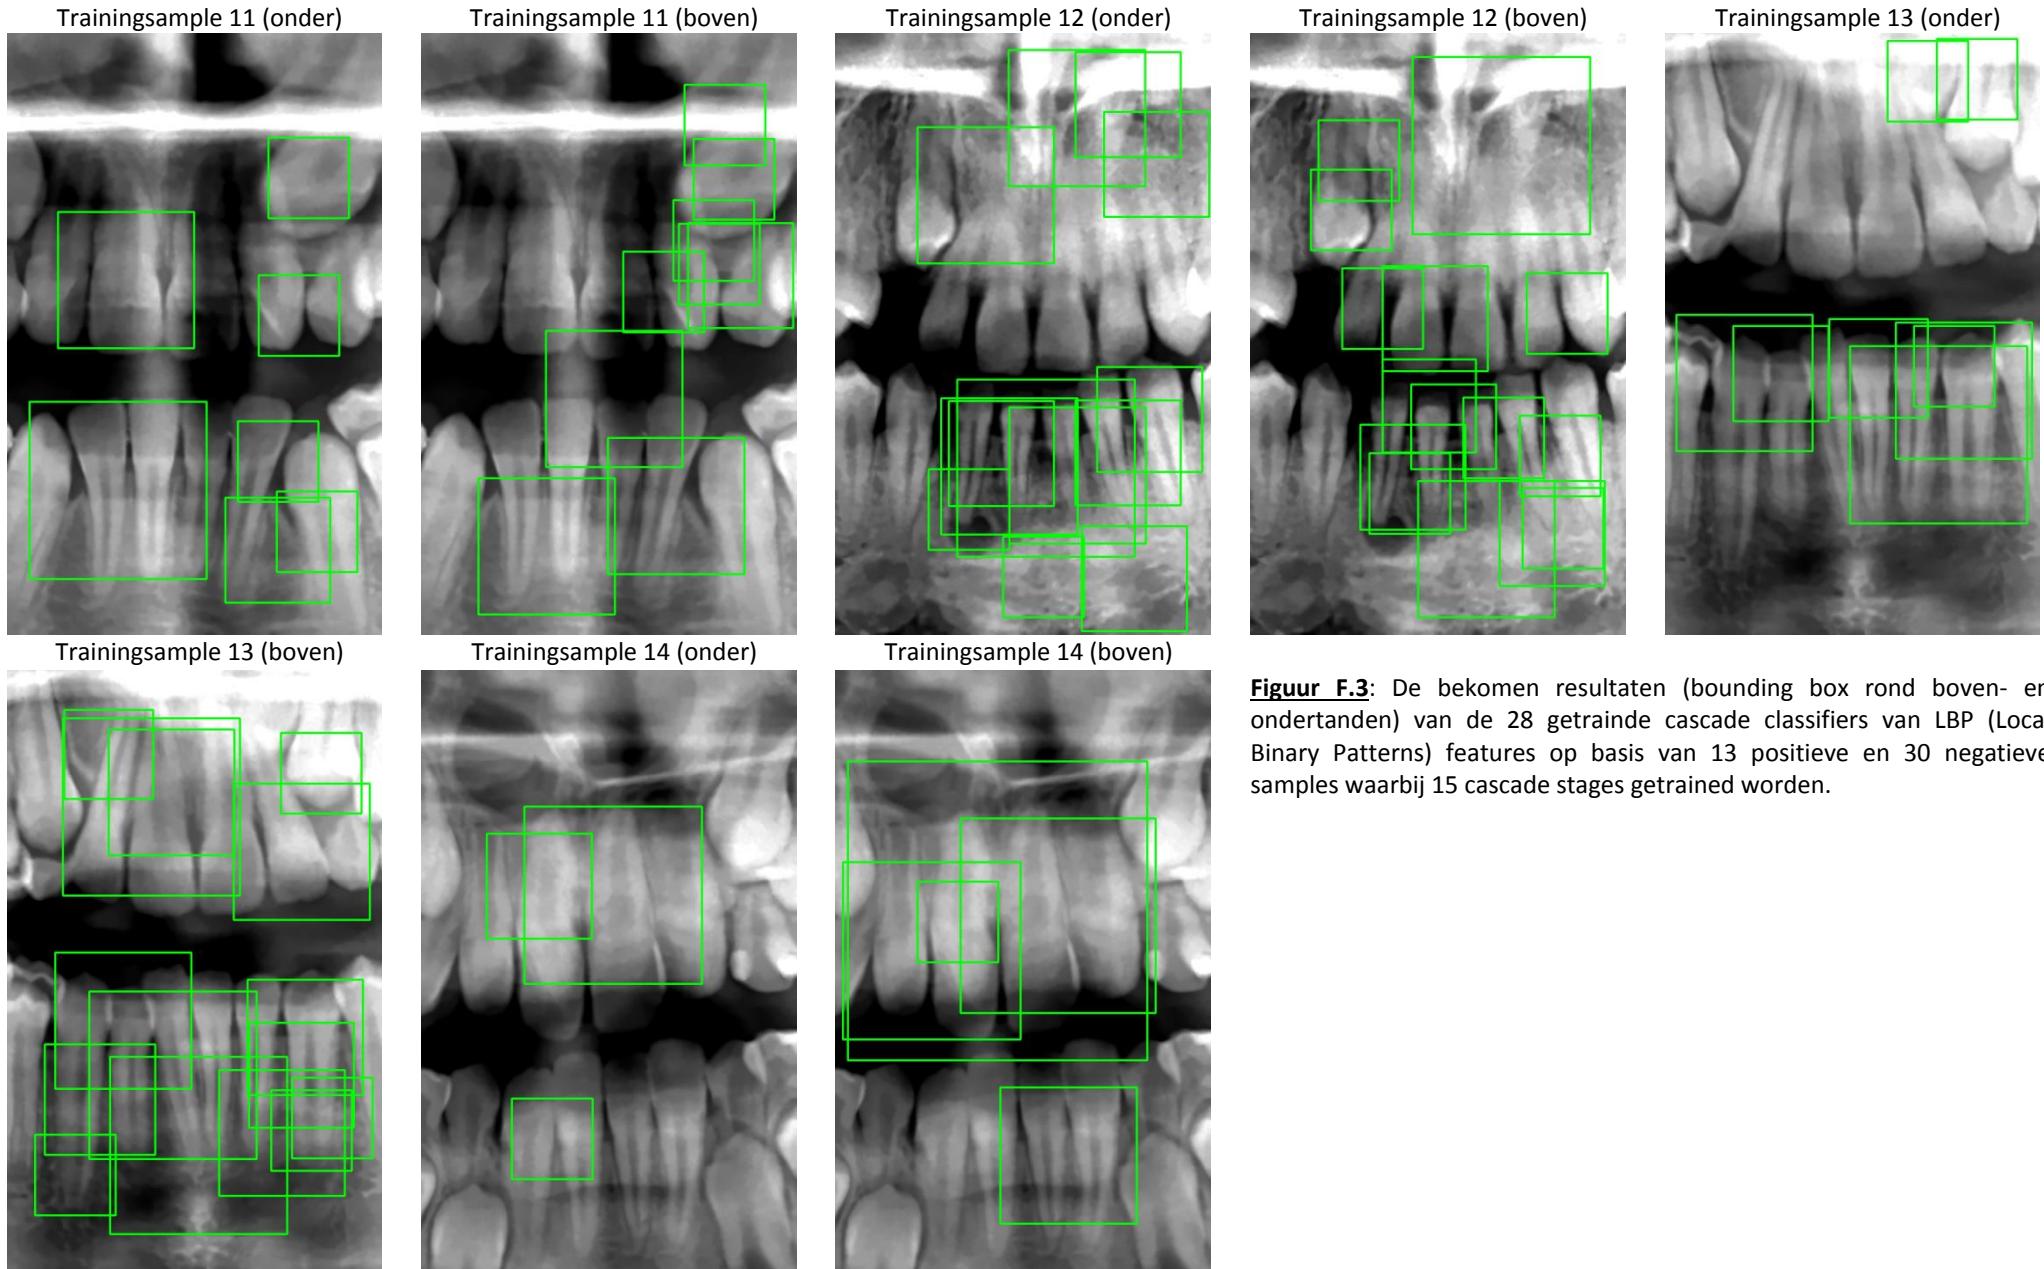




Figuur F.2: De 30 negatieve samples voor het trainen van de cascade classifiers van LBP (Local Binary Patterns) features.

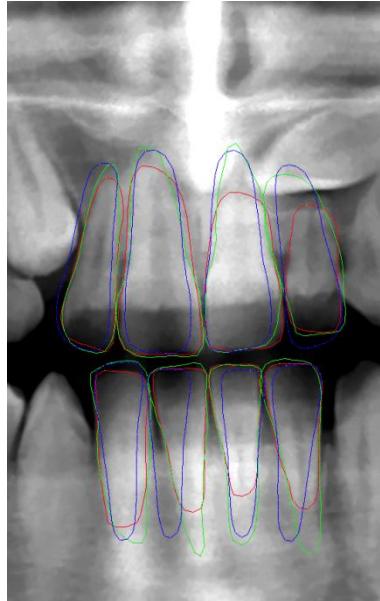




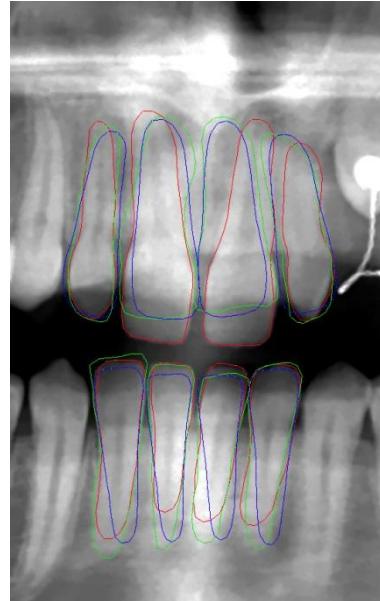


Figuur F.3: De bekomen resultaten (bounding box rond boven- en ondertanden) van de 28 getrainde cascade classifiers van LBP (Local Binary Patterns) features op basis van 13 positieve en 30 negatieve samples waarbij 15 cascade stages getraind worden.

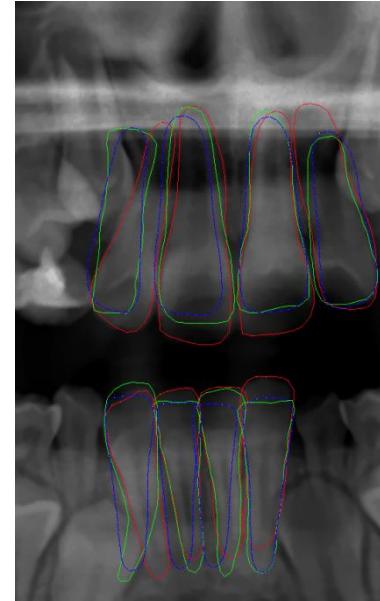
Trainingsample 1



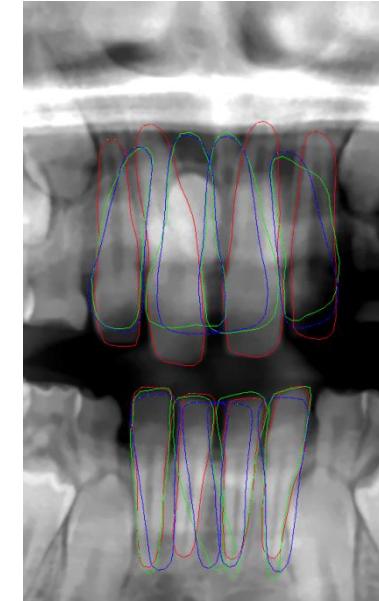
Trainingsample 2



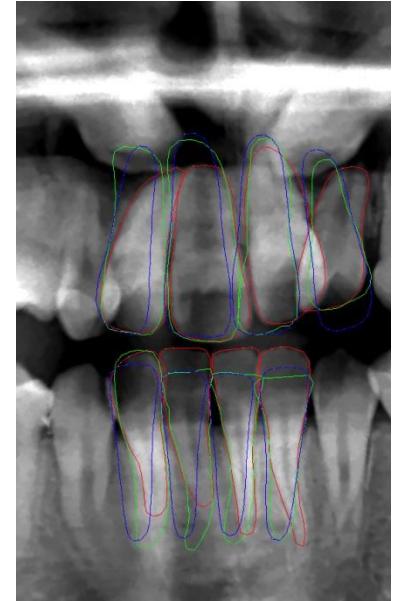
Trainingsample 3



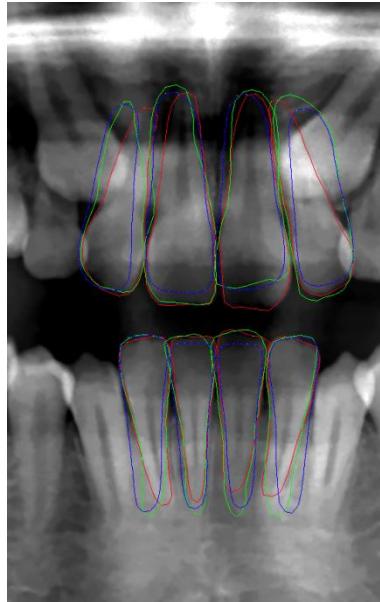
Trainingsample 4



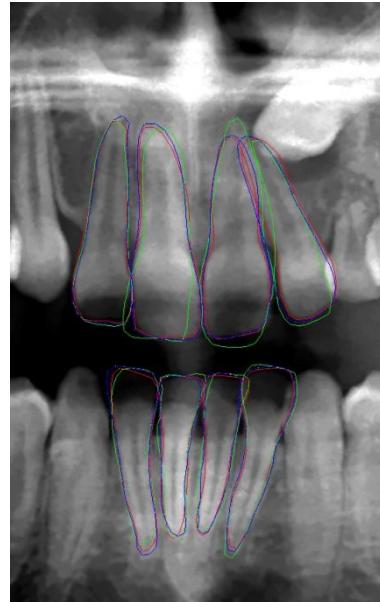
Trainingsample 5



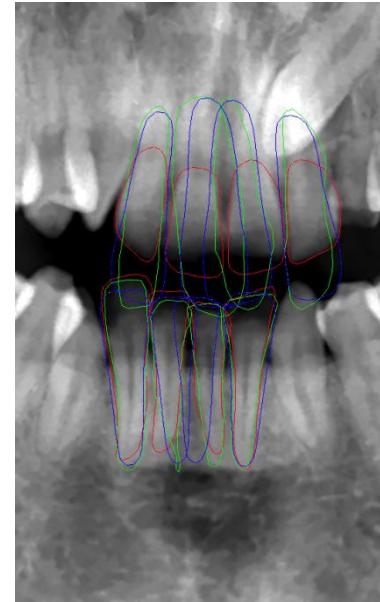
Trainingsample 6



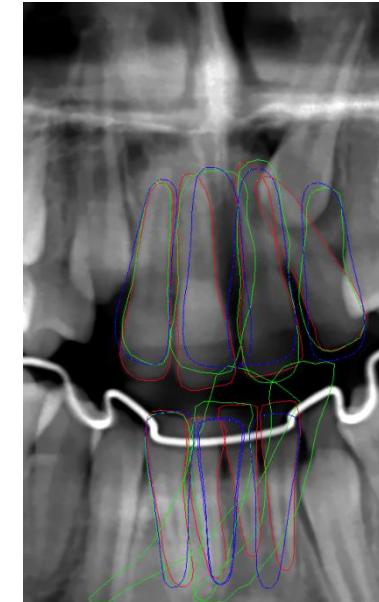
Trainingsample 7



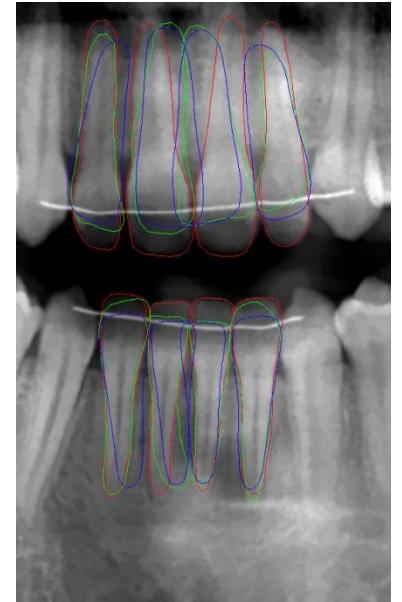
Trainingsample 8

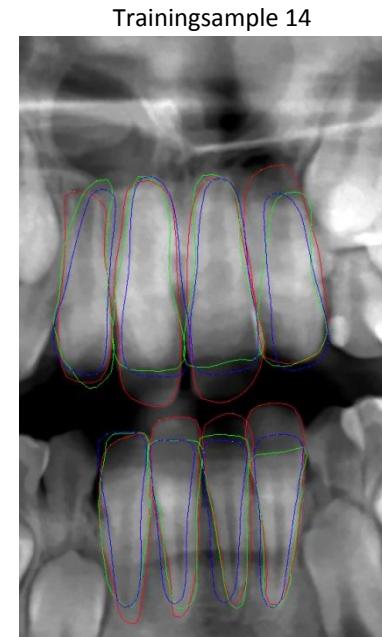
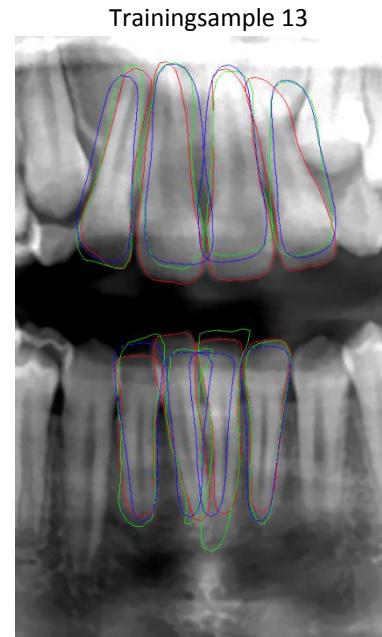
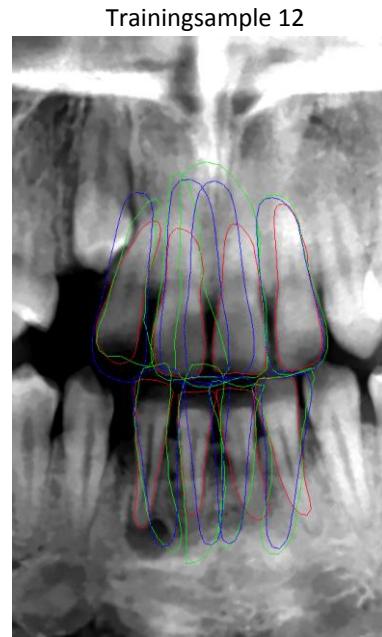
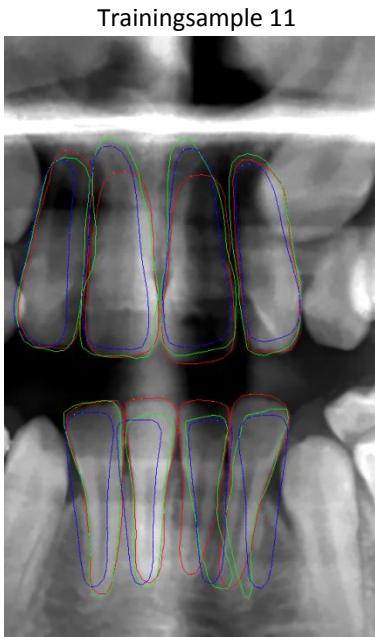


Trainingsample 9



Trainingsample 10





Figuur F.4: De modellandmarks en contouren gecentreerd in het zwaartepunt van het overeenkomstige kwartaal van de bouding box rond de boven- of ondertanden als initiële startoplossing weergegeven in het blauw samen met de bekomen resultaatlandmarks na toepassen van een multi-resolutie ASM fittingprocedure op basis van 13 trainingsamples met fitting functies die enkel het profiel normaal t.o.v. de modelranden in beschouwing nemen, weergegeven in het groen. De contouren van de referentie zijn weergegeven in het rood.

#levels = 3, k = 4, m = 8

Referenties

- [Cootes92] T.F. Cootes, C.J. Taylor, d.H. Cooper, and J.Graham, *Active Shape Models – Their Training and Application*, 1992
- [Cootes00] T.F. Cootes, *An Introduction to Active Shape Models*, 2000
- [Fisher00] R. Fisher, S. Perkins, A. Walker, and E. Wolfart, *Histogram Equalization*, Hypermedia Image Processing Reference (HIPR2), 2000
- R. Fisher, S. Perkins, A. Walker, and E. Wolfart, *Contrast Stretching*, Hypermedia Image Processing Reference (HIPR2), 2000
- [HaarClassifier13] T. Ball, <http://coding-robin.de/2013/07/22/train-your-own-opencv-haar-classifier.html>, 2013
- [OpenCV11] OpenCV, *Histogram Equalization*, OpenCV Tutorials: Image Processing, 2011
- [Pei10] J. Pei, *2D Statistical Models*, 2010